Rapport d'avancement : Développement d'un Workflow Automatisé pour la Prédiction des Propriétés Redox de Molécules Organiques par DFT

Lucas Delavoye
Master XL-Chem V (2024/2026)
Laboratoire CARMeN (UMR CNRS 6064)

Mars 2026

1 Introduction

Le déploiement à grande échelle de la technologie Li-ion pour le stockage d'énergie soulève aujourd'hui des préoccupations convergentes sur trois plans. Sur le plan environnemental, l'extraction du lithium et du cobalt entraîne une empreinte hydrique et minière importante, et le recyclage en fin de vie reste partiel. Sur le plan social, les conditions d'extraction du cobalt, dont la production est concentrée principalement en République Démocratique du Congo, font régulièrement l'objet d'alertes documentées. Sur le plan stratégique enfin, la concentration géographique des réserves de lithium en Amérique du Sud et de la chaîne de raffinage et d'assemblage des cellules en Asie crée une dépendance lourde de l'ensemble des pays consommateurs envers un nombre restreint de fournisseurs, contraignant structurellement le développement du stockage électrochimique à l'échelle mondiale.

Les matériaux redox-actifs organiques constituent une voie alternative à fort potentiel pour les électrodes des batteries de prochaine génération. Construits à partir d'éléments abondants (C, H, N, O, S) et accessibles depuis des précurseurs biosourcés tels que les algues, le bois, les plantes ou les huiles végétales, ils peuvent être produits localement à partir de ressources cultivables sur l'ensemble du globe et recyclés en fin de vie. Leur structure permet en outre d'ajuster les propriétés électrochimiques par fonctionnalisation, ouvrant un espace de conception adapté aux exigences applicatives. Parmi les motifs candidats pour la matière active d'électrode positive, le couple catéchol/quinone occupe une place particulière : un transfert biélectronique entre deux formes redox stables, un espace chimique vaste accessible par substitution du cycle aromatique, et une capacité documentée à stocker de la charge via l'interconversion réversible carbonyle/hydroxyle. Le défi consiste alors à identifier, dans cet espace combinatoire, les substituants conduisant à un potentiel redox, une solubilité et une stabilité compatibles avec les contraintes d'application.

Le travail présenté dans ce rapport, mené sur près d'un an et demi, s'inscrit dans une collaboration entre le laboratoire CARMeN (UMR CNRS 6064, Université de Rouen Normandie), où le criblage computationnel a été développé, et le Green Chemistry Centre of Excellence de l'Université d'York, qui prendra en charge la synthèse ciblée des candidats les plus prometteurs. La finalité du pipeline développé au CARMeN est ainsi de fournir une liste restreinte de molécules dont les propriétés calculées justifient le coût expérimental de la synthèse et de la caractérisation.

La DFT prédit quantitativement les propriétés redox des molécules organiques, mais son application au criblage de masse se heurte à un coût prohibitif : pour chaque candidat, l'évaluation de l'énergie libre de Gibbs de transfert électronique exige une optimisation géométrique de l'état ionique (réduit ou oxydé) suivie d'une analyse vibrationnelle, dont le coût dépasse largement celui des calculs effectués sur le seul état neutre. La conduite d'un tel criblage suppose d'abord un

environnement de calcul automatisé : le système de workflows développé dans ce travail, construit sur l'Amsterdam Modeling Suite (AMS) et la bibliothèque PLAMS, orchestre la génération de conformères, les optimisations DFT successives et les analyses sur l'ensemble du protocole, garantissant la reproductibilité et permettant le passage à l'échelle. Sur cette base, deux voies sont explorées pour réduire effectivement le coût des prédictions : des modèles prédictifs physiquement motivés, construits sur des descripteurs calculables depuis le seul état neutre, et une approche par apprentissage automatique sur descripteurs tabulaires et géométriques, qui sert de référence comparative pour situer la performance des modèles physiques.

La construction de tels modèles substitutifs repose sur une décomposition thermodynamique du potentiel redox en contributions distinctes : affinité électronique (EA) ou potentiel d'ionisation (IP) verticaux, énergie de relaxation géométrique (E_{relax}), contribution thermique interne ($\Delta\Delta U$) et terme entropique ($T\Delta S$). Cette décomposition est formalisée comme suit :

$$\Delta G_{\text{red}} = -\text{EA} + E^{\text{red}}_{\text{relax}} + \Delta\Delta U - T\Delta S \qquad (1)$$

$$\Delta G_{\text{ox}} = \text{IP} + E^{\text{ox}}_{\text{relax}} + \Delta\Delta U - T\Delta S \qquad (2)$$

Dans ces équations, EA et IP désignent l'affinité électronique et le potentiel d'ionisation verticaux, définis positifs par convention :

$$\text{EA} = E^{\text{neutre}} - E^{\text{réduit,sp}}, \qquad \text{IP} = E^{\text{oxydé,sp}} - E^{\text{neutre}},$$

où $E^{\text{ion,sp}}$ représente l'énergie de l'état ionique (réduit ou oxydé) évaluée à la géométrie d'équilibre du neutre (calcul *single point*, sans réoptimisation). EA et IP mesurent ainsi le coût énergétique d'un transfert électronique à géométrie figée. L'énergie de relaxation, indicée par l'état ionique correspondant,

$$E^{\text{ion}}_{\text{relax}} = E^{\text{ion,opt}} - E^{\text{ion,sp}} \qquad (\text{ion} \in \{\text{red, ox}\})$$

est alors la stabilisation associée à la réoptimisation géométrique de l'état ionique vers son propre minimum. Enfin, $\Delta\Delta U$ regroupe les corrections d'énergie interne (énergie de point zéro et énergie thermique) entre formes neutre et ionique, tandis que $T\Delta S$ est la contribution entropique à l'énergie libre de Gibbs.

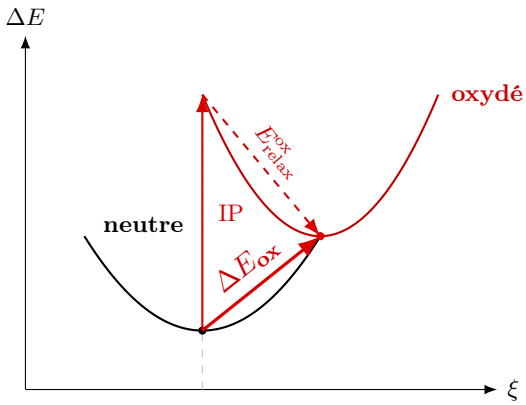


FIGURE 1 – Décomposition du transfert électronique pour l'oxydation, le long d'une coordonnée généralisée ξ. À la géométrie d'équilibre du neutre, IP est le coût énergétique d'un transfert vertical d'un électron vers l'état oxydé ; $E^{\text{ox}}_{\text{relax}}$ est la stabilisation associée à la réoptimisation géométrique de cet état. Le schéma équivalent pour la réduction s'obtient en remplaçant chaque terme « ox » par son analogue « red » (état oxydé par état réduit, IP par $-$EA, et $E^{\text{ox}}_{\text{relax}}$ par $E^{\text{red}}_{\text{relax}}$).

Cette décomposition isole les contributions dominantes au potentiel redox et identifie E_{relax}, $\Delta\Delta U$ et $T\Delta S$ comme cibles privilégiées des modèles substitutifs : si chacun de ces termes peut être estimé à partir de propriétés de l'état neutre, les optimisations géométriques des états ioniques deviennent superflues pour le criblage. Le développement de ces modèles est mené sur une base de données de catéchols et de quinones substitués calculés en acétonitrile, puis étendu à neuf autres solvants pour dégager une dépendance explicite à la permittivité diélectrique.

2 Description du Workflow

2.1 Vue d'ensemble

Le workflow prend en entrée une liste de molécules définies par leur code SMILES. Les molécules étudiées appartiennent à deux familles formant un couple redox : les **catéchols** (forme réduite) et les **quinones** (forme oxydée). Pour la recherche de corrélations, les analyses sont menées sur une seule famille à la fois afin d'éviter un biais : si les deux familles étaient mélangées,

les coefficients de corrélation seraient artificiellement élevés en raison de la formation de deux clusters de points bien séparés.

Les calculs présentés dans ce rapport portent sur 19 dérivés de catéchols et 19 quinones (38 molécules au total), incluant des substituants variés (halogènes F, Cl, Br, I ; chaînes hydroxymethyle, dopamine, L-DOPA, acide caféique ; hétérocycles N, O, S). Pour chaque molécule, l'ensemble des calculs est orchestré de manière séquentielle à travers quatre pipelines successifs : génération de conformères, calculs redox, analyse topologique QTAIM/IQA, et analyse des corrélations. L'ensemble des calculs a été réalisé avec l'Amsterdam Modeling Suite (AMS 2025).

La figure 2 illustre l'enchaînement des quatre pipelines et les données propagées entre eux.

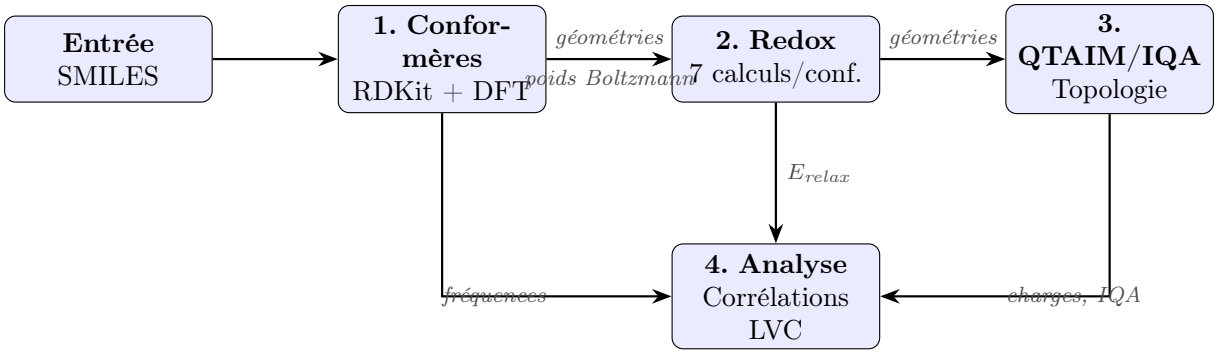


FIGURE 2 – Schéma du workflow. Les données (géométries optimisées, poids de Boltzmann, fréquences vibrationnelles) sont propagées entre les pipelines via les répertoires de travail partagés.

L'exécution typique suit la séquence suivante :

```
./conformers_gen.py --name molecule --smiles "SMILES" \
                  --functional PBE0 --basis DZP \
                  --solvent Acetonitrile

./redox_calc.py --input-dir ./molecule_workdir/conformers/results \
              --name molecule --functional PBE0 --basis DZP \
              --refinement-basis TZ2P --solvent Acetonitrile

./qtaim_calc.py --name molecule --functional PBE0 --basis TZP
```

2.2 Pipeline Conformères

Le premier pipeline transforme un code SMILES en un ensemble restreint de conformères optimisés. Le processus se déroule en quatre étapes séquentielles :

1. **Generate** : Génération de 1000 conformères initiaux via RDKit avec champ de force UFF
2. **Optimize** : Pré-optimisation géométrique par GFN1-xTB (sans fenêtre d'énergie)
3. **Boltzmann xTB** : Sélection des conformères par poids de Boltzmann ($w \geq 0.05$) sur les énergies GFN1-xTB
4. **DFT opt + freq + solvant** : Optimisation géométrique PBE0/DZP avec modes normaux et solvatation COSMO, suivie d'un filtrage Boltzmann DFT ($w \geq 0.10$) sur les énergies libres de Gibbs

L'étape 4 garantit que seuls les vrais minima (absence de fréquences imaginaires) sont transmis aux pipelines suivants. Les fichiers RKF des conformères validés sont référencés dans `neutral_rkf_paths.jso` qui sert de pont vers le pipeline redox. Les paramètres (fonctionnelle, base, solvant, seuils de Boltzmann) sont configurables via les arguments en ligne de commande.

TABLE 1 – Paramètres du pipeline conformères.

Paramètre	**Valeur**
Moteurs de calcul	
Generate	RDKit + UFF (1000 conformères initiaux)
Optimize	GFN1-xTB
DFT opt + freq + solvant	ADF (PBE0/DZP + COSMO)
Paramètres DFT (étape 4)	
Fonctionnelle	PBE0 (hybride, 25% HF)
Base	DZP (Slater double zeta + polarisation)
Solvatation	COSMO (acétonitrile)
Relativité	Aucune
Qualité numérique	Good
Filtrage des conformères	
Seuil Boltzmann après xTB	5%
Seuil Boltzmann après DFT	10%
Seuil de fréquence imaginaire	$0.0\,\mathrm{cm}^{-1}$

2.3 Pipeline Redox

Le pipeline redox utilise un schéma d'énergie composite TZ2P+DZP : les optimisations géométriques et les corrections thermodynamiques sont réalisées en base DZP, tandis que les énergies électroniques de référence sont obtenues par single-points en base TZ2P. Le neutre n'est pas re-optimisé : le fichier RKF de l'étape 4 du pipeline conformères est directement réutilisé. Pour chaque conformère, sept calculs DFT supplémentaires sont effectués :

1. **neutral_tz2p** : Single-point TZ2P sur la géométrie neutre optimisée (charge 0)
2. **reduced_sp** : Single-point TZ2P sur la géométrie neutre (charge −1, EA verticale)
3. **reduced_opt** : GeomOpt DZP + fréquences + COSMO de l'état réduit (charge −1)
4. **reduced_tz2p** : Single-point TZ2P sur la géométrie réduite optimisée
5. **oxidized_sp** : Single-point TZ2P sur la géométrie neutre (charge +1, IP vertical)
6. **oxidized_opt** : GeomOpt DZP + fréquences + COSMO de l'état oxydé (charge +1)
7. **oxidized_tz2p** : Single-point TZ2P sur la géométrie oxydée optimisée

Le potentiel redox est ensuite obtenu via l'équation de Nernst $E^\circ = -\Delta G^\circ / nF$, où ΔG° utilise l'énergie libre composite $G_{\text{composite}} = E_e(\text{TZ2P}) + [G(\text{DZP}) - E_e(\text{DZP})]$, le terme entre crochets capturant les corrections thermodynamiques (ZPE, enthalpie, entropie) au niveau DZP. Ce schéma assure la cohérence des bases pour les énergies électroniques (toutes en TZ2P) tout en évitant le coût d'une optimisation géométrique en TZ2P.

2.3.1 Correction des Fréquences Imaginaires

Lorsqu'une optimisation géométrique converge vers un point selle (présence de fréquences imaginaires), un algorithme de correction est appliqué :

1. Identification du mode vibrationnel imaginaire le plus négatif
2. Perturbation de la géométrie le long de ce mode (directions positive et négative)
3. Ré-optimisation à partir des géométries perturbées
4. Itération jusqu'à obtention d'un vrai minimum (maximum 3 tentatives)

TABLE 2 – Paramètres du pipeline redox (schéma composite TZ2P+DZP).

Paramètre	**Valeur**
Fonctionnelle	PBE0
Base (optimisation)	DZP
Base (raffinement SP)	TZ2P
Relativité	Aucune
Solvatation neutre	COSMO (CONJ)
Solvatation ions	COSMO (CONJ CORR)
Modes normaux	Oui (GeomOpt), Non (SinglePoint)
États de spin	
Neutre (charge 0)	Couche fermée
Réduit (charge -1)	Couche ouverte, $S = 1/2$
Oxydé (charge $+1$)	Couche ouverte, $S = 1/2$
Correction des fréquences imaginaires	
Tentatives max.	3
Perturbation	0.1 Å le long du mode imaginaire

2.4 Pipeline QTAIM/IQA

Ce pipeline exploite les fonctionnalités QTAIM (Quantum Theory of Atoms in Molecules) et IQA (Interacting Quantum Atoms) implémentées dans AMS. Les calculs sont lancés via PLAMS et les résultats (charges atomiques de Bader, énergies intra-atomiques E_{intra}, énergies d'interaction E_{inter}) sont extraits des fichiers RKF générés par AMS. La relativité ZORA est désactivée car incompatible avec l'analyse QTAIM dans AMS.

L'analyse peut être effectuée sur plusieurs états de charge (neutre, réduit, oxydé) pour un même conformère, permettant de suivre l'évolution des propriétés topologiques lors du transfert d'électron.

Un aspect important de l'analyse comparative concerne la numérotation des atomes. Lorsqu'on compare différentes molécules (par exemple des dérivés de quinone avec différents substituants), les indices atomiques attribués par le logiciel diffèrent d'un système à l'autre. Pour permettre une comparaison cohérente des propriétés atomiques (charges, énergies IQA) entre molécules apparentées, un algorithme de réindexation topologique a été implémenté. Cet algorithme identifie les atomes du cycle aromatique principal à partir du point critique de cycle QTAIM, puis assigne des indices canoniques (1 à 8 pour les carbones du cycle et les oxygènes) indépendamment de la numérotation initiale.

2.5 Pipeline Analyse des Termes de ΔG

Ce pipeline cherche à prédire les différents termes de la décomposition de ΔG (équations 1 et 2) à partir des seules propriétés de l'état neutre, sans réaliser les optimisations géométriques coûteuses des états chargés. Les quatre termes sont traités :

- **EA / IP** : prédiction par l'approximation de Koopmans ($\varepsilon_{\text{HOMO}}$, $\varepsilon_{\text{LUMO}}$) et par l'approche de Politzer ($\bar{I}_{S,\text{min}}$, $V_{S,\text{min}}$)
- $E_{\textbf{relax}}$: prédiction par couplage vibronique (LVC, LVC2, Duschinsky, QVC, VPT2, Dual-Hessian)
- $\Delta\Delta U$: modèle constant ou corrélation avec la ZPE de l'état neutre
- $T\Delta S$: modèle constant ou corrélation avec l'entropie vibrationnelle RRHO

Le module `qmanalysis` implémente six méthodes de couplage vibronique et calcule 67 descripteurs moléculaires (fréquences, IR, flexibilité, propriétés électroniques). Les analyses de corréla-

TABLE 3 – Paramètres du pipeline QTAIM/IQA.

Paramètre	**Valeur**
Fonctionnelle	PBE0 (hybride, 25% HF)
Base	TZP (Slater triple zeta + polarisation)
Relativité	Aucune (incompatible QTAIM)
Qualité numérique	Good
QTAIM	Activé (AnalysisLevel = Full)
IQA	Activé
États de charge analysés	
Neutre	Couche fermée
Réduit (-1)	Couche ouverte, $S = 1/2$
Oxydé ($+1$)	Couche ouverte, $S = 1/2$

tion sont menées exclusivement sur les catéchols (forme réduite) afin d'éviter un biais statistique.

2.6 Transfert des Poids de Boltzmann

Un point méthodologique important concerne le transfert des poids de Boltzmann entre pipelines : les poids calculés lors de l'étape DFT opt+freq du pipeline conformères (étape 4, basés sur les énergies libres de Gibbs PBE0/DZP+COSMO) sont réutilisés dans le pipeline redox pour la moyenne pondérée des propriétés. Ce choix est préférable au calcul des poids à partir des énergies d'optimisation redox, car après optimisation, les conformères peuvent converger vers des géométries très proches, donnant des poids de Boltzmann artificiellement uniformes.

3 Résultats d'Analyse

L'ensemble des pipelines a été appliqué aux 19 dérivés de catéchols (et 19 quinones). Parmi les catéchols, tous les calculs ont convergé avec le schéma composite TZ2P+DZP, y compris les molécules à hétérocycles (L-DA, L-DOPA, O-DHI, P-DHI, S-DHI).

Quatre dérivés halogénés (Br-DA, Br-HMC, I-DA, I-HMC) présentent un *attachement électronique dissociatif* (DEA) lors de la réduction : la liaison C–X se rompt ($\Delta d > 1.0\,\text{Å}$), libérant un radical et un halogénure ($\text{Ar-X} + e^- \rightarrow \text{Ar}^\bullet + \text{X}^-$). Cette instabilité chimique les rend inaptes aux applications en batteries organiques, qui nécessitent la réversibilité du processus redox. Le pipeline redox détecte automatiquement ces ruptures de liaison par comparaison des géométries neutres et réduites optimisées. Aucune rupture de liaison n'est observée en oxydation. Les 15 molécules restantes (excluant les 4 DEA) constituent le jeu de données principal pour les analyses de corrélations.

Le tableau 4 présente la décomposition thermodynamique de ΔG selon les équations 1 et 2 pour les 15 molécules catéchols stables. Le schéma composite TZ2P+DZP assure que EA, IP et E_{relax} sont calculés en bases cohérentes TZ2P, tandis que $\Delta\Delta U$ et $T\Delta S$ proviennent des corrections DZP. Le résiduel est systématiquement nul par construction du schéma composite.

Pour l'oxydation, le terme IP domine largement ΔG et les $E_{\text{relax}}^{\text{ox}}$ sont relativement homogènes (-17 à -34 kJ/mol). Le résiduel ($\Delta\Delta U - T\Delta S$) reste faible ($< 6\,\text{kJ/mol}$). Pour la réduction, les $E_{\text{relax}}^{\text{red}}$ varient de -38.5 kJ/mol (F-HMC) à -20.2 kJ/mol (H2C-CA). Le terme $\Delta\Delta U_{\text{red}}$ est toujours négatif (-15.3 à $-7.9\,\text{kJ/mol}$). Le schéma composite TZ2P+DZP donne des résidus systématiquement nuls.

TABLE 4 – Décomposition de ΔG pour l'oxydation (gauche) et la réduction (droite). Toutes les valeurs en kJ/mol, moyennées par poids de Boltzmann. Schéma composite TZ2P+DZP. Les 4 dérivés bromés et iodés sont exclus (rupture de liaison C–X).

Oxydation ($M \rightarrow M^+ + e^-$)

	ΔG	IP	E_{relax}	$\Delta\Delta U$	$T\Delta S$
Al-CA	559.4	574.8	−16.7	0.6	−0.7
CA	557.3	571.4	−17.1	−1.2	−4.2
Cl-DA	545.5	565.2	−22.6	0.9	−2.1
Cl-HMC	547.5	567.8	−23.4	0.6	−2.5
DA	541.7	562.9	−23.7	1.1	−1.4
DHI	503.3	520.1	−20.7	0.8	−3.1
F-DA	541.3	563.6	−25.6	1.3	−2.0
F-HMC	548.9	572.1	−27.9	1.3	−3.3
H2C-CA	513.3	526.0	−16.9	1.4	−2.6
HMC	548.1	576.8	−33.5	−0.1	−4.9
HO-CA	532.6	548.4	−20.3	0.3	−4.3
L-DA	548.5	568.6	−23.9	1.2	−2.6
O-DHI	525.7	543.4	−20.2	0.3	−2.3
P-DHI	532.3	548.5	−18.8	0.5	−2.1
S-DHI	532.4	549.9	−19.4	0.3	−1.5

Réduction ($M + e^- \rightarrow M^-$)

	ΔG	EA	E_{relax}	$\Delta\Delta U$	$T\Delta S$
Al-CA	−276.3	243.7	−23.9	−7.9	0.9
CA	−258.5	223.0	−26.1	−8.5	0.9
Cl-DA	−122.7	77.4	−28.1	−12.9	4.3
Cl-HMC	−136.3	78.0	−36.8	−13.9	7.7
DA	−104.3	59.2	−28.7	−13.9	2.5
DHI	−118.1	80.0	−23.0	−12.5	2.6
F-DA	−118.2	70.4	−29.7	−13.3	4.8
F-HMC	−132.9	77.6	−39.0	−13.3	3.1
H2C-CA	−208.6	178.0	−20.2	−10.7	−0.2
HMC	−118.1	72.5	−28.8	−14.5	2.5
HO-CA	−177.8	136.3	−28.2	−11.6	1.8
L-DA	−111.7	69.4	−25.5	−14.7	2.2
O-DHI	−135.8	98.3	−20.4	−13.1	4.0
P-DHI	−177.6	139.8	−26.9	−10.5	0.5
S-DHI	−141.8	104.0	−18.9	−12.9	6.0

3.0.1 Poids relatif des termes

La figure 3 quantifie la contribution de chaque terme à $|\Delta G|$. Le tableau 5 résume les statistiques. Grâce au schéma composite TZ2P+DZP, le résiduel de la décomposition est exactement nul pour chaque conformère. Pour l'oxydation, la décomposition reste remarquablement simple : IP domine largement $|\Delta G_{\text{ox}}|$, $|E_{\text{relax}}|$ contribue modérément, et les corrections thermiques ($\Delta\Delta U - T\Delta S$) restent faibles. Pour la réduction, la répartition est plus variable.

TABLE 5 – Poids relatif moyen de chaque terme dans $|\Delta G|$, et erreur si les corrections thermiques sont négligées. Schéma composite TZ2P+DZP (résiduel = 0).

	EA/IP / $\lvert\Delta G\rvert$	$\lvert E_{\text{relax}}\rvert$ / $\lvert\Delta G\rvert$	$\lvert\Delta\Delta U - T\Delta S\rvert$ / $\lvert\Delta G\rvert$
Oxydation	∼104%	∼4%	< 1%
Réduction	∼50–85%	∼15–30%	∼5–15%

Cette hiérarchie a une implication pratique directe : pour l'oxydation, $\Delta G_{\text{ox}} \approx \text{IP} + E_{\text{relax}}$ à quelques kJ/mol près. Si l'on parvenait à prédire IP et E_{relax} à partir des seules propriétés de l'état neutre, on pourrait estimer ΔG_{ox} sans les calculs DFT coûteux des états chargés. Pour la réduction, les corrections thermiques sont plus importantes mais restent petites devant les termes dominants pour la plupart des molécules. Les sections suivantes examinent les corrélations de chaque terme avec les descripteurs moléculaires accessibles depuis le calcul de l'état neutre.

Contexte : précision intrinsèque de la DFT. Il est important de garder à l'esprit la précision limitée des calculs DFT eux-mêmes. Au niveau PBE0/DZP utilisé ici, l'erreur absolue moyenne (MAE) typique sur les énergies de réaction est de l'ordre de 1–2 kcal/mol, soit 4 kJ/mol à 8 kJ/mol. Tout modèle prédictif dont la MAE est inférieure à cette barre de 4 kJ/mol à 8 kJ/mol est donc aussi fiable que le calcul DFT complet lui-même. Pour les termes $\Delta\Delta U$ (amplitude moyenne 1.5 kJ/mol en oxydation) et $T\Delta S$ (1.1 kJ/mol en oxydation), un modèle trivial (constante) donnerait une MAE de l'ordre de 1 kJ/mol, bien en-deçà de l'erreur DFT intrinsèque. Pour $E_{\text{relax}}^{\text{ox}}$, le modèle LVC avec MAE = 1.2 kJ/mol (et le LVC2 à 0.7 kJ/mol) est plus précis que l'incertitude inhérente à la fonctionnelle. Ces considérations relativisent la nécessité d'obtenir des R^2 élevés : la pertinence d'un modèle se juge avant tout par sa MAE comparée à l'erreur DFT.

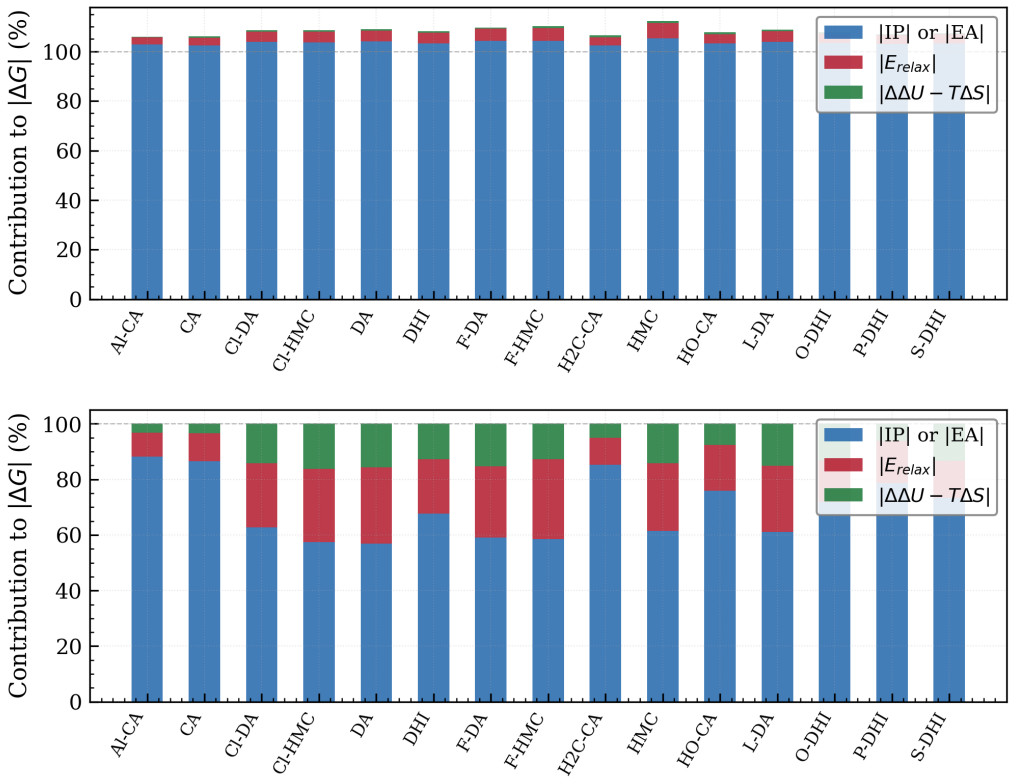


FIGURE 3 – Décomposition de $|\Delta G|$ en contributions. Barres empilées : IP ou EA (bleu), $|E_{\text{relax}}|$ (rouge), $|\Delta\Delta U - T\Delta S|$ (vert). En oxydation, IP domine uniformément ; en réduction, la répartition varie selon la molécule.

3.1 Corrélations EA/IP avec les Orbitales Frontières

3.1.1 Théorème de Koopmans

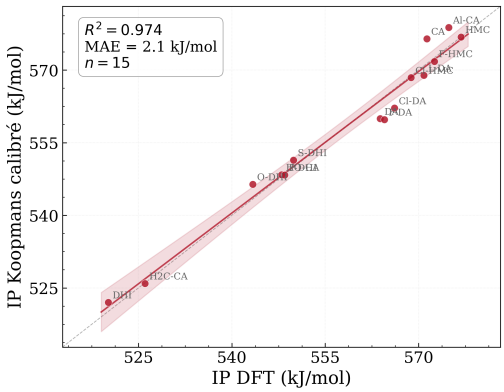
Le théorème de Koopmans (1934) [1] établit, dans le cadre Hartree-Fock, que le potentiel d'ionisation vertical d'un système à N électrons est égal à l'opposé de l'énergie de l'orbitale HOMO : $\text{IP} = -\varepsilon_{\text{HOMO}}$. Cette égalité repose sur l'hypothèse que les orbitales ne se réorganisent pas lors du retrait d'un électron (*frozen orbital approximation*), négligeant ainsi l'énergie de relaxation orbitale et la corrélation électronique. Pour l'affinité électronique, la correspondance $\text{EA} \approx -\varepsilon_{\text{LUMO}}$ est moins rigoureuse en Hartree-Fock. En effet, les orbitales HF sont optimisées variationnellement pour l'état fondamental à N électrons : la HOMO fait partie de cet ensemble optimal, ce qui fonde la relation $\text{IP} = -\varepsilon_{\text{HOMO}}$. La LUMO, en revanche, est une orbitale *virtuelle* qui émerge de la résolution des équations HF sans avoir jamais été occupée. Pour décrire correctement le système à $N+1$ électrons (l'anion), il faudrait ré-optimiser l'ensemble des orbitales en présence de l'électron supplémentaire, ce qui donnerait des orbitales significativement différentes. La LUMO du système à N électrons n'est donc qu'une approximation de l'orbitale qu'occuperait réellement l'électron ajouté, et le théorème de Koopmans au sens strict ne concerne que l'ionisation.

En théorie de la fonctionnelle de la densité (DFT) de Kohn-Sham, la situation est différente. Le théorème de Janak [2] garantit que, pour la fonctionnelle exacte, $-\varepsilon^{\text{KS}}_{\text{HOMO}}$ est rigoureusement égal au potentiel d'ionisation exact. Cependant, avec des fonctionnelles approchées comme PBE0, les énergies orbitales de Kohn-Sham souffrent de l'erreur de self-interaction résiduelle, et la correspondance n'est qu'approximative. On parle donc d'*approximation* de Koopmans plutôt que de théorème au sens strict. Malgré ces limitations, une corrélation linéaire empirique entre les énergies orbitalaires KS ($\varepsilon_{\text{HOMO}}$, $\varepsilon_{\text{LUMO}}$) et les énergies verticales (IP, EA) est largement

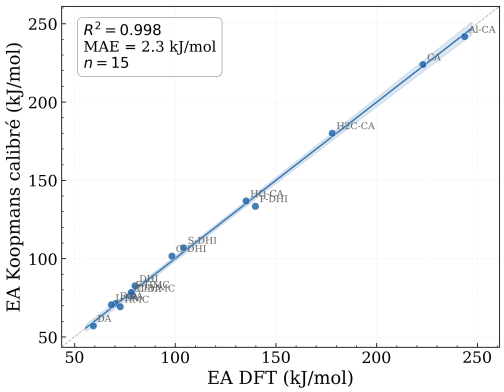
documentée dans la littérature et constitue un outil de criblage rapide.

La figure 4 montre les corrélations obtenues sur notre série de catéchols entre les énergies orbitalaires de Kohn-Sham et les énergies verticales calculées par DFT (schéma composite TZ2P). Pour IP vs $-\varepsilon_{\mathrm{HOMO}}$ (figure 4a), la corrélation est très bonne ($R^2 = 0.974$, MAE = 2.1 kJ/mol, $n = 15$). Pour EA vs $-\varepsilon_{\mathrm{LUMO}}$ (figure 4b), la corrélation est excellente ($R^2 = 0.998$, MAE = 2.3 kJ/mol, $n = 15$). L'analyse per-conformère, où chaque conformère constitue un point indépendant ($n = 40$), confirme ces corrélations avec une puissance statistique accrue (figure 4c–d).

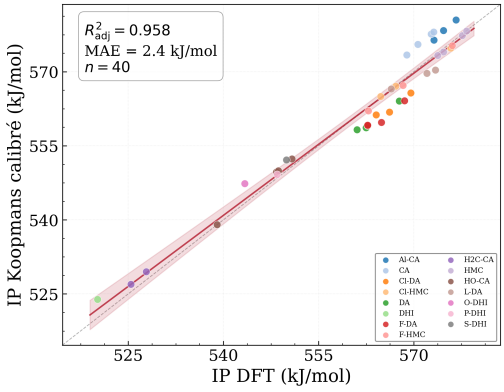
Ces MAE de l'ordre de 2 kJ/mol sont remarquablement faibles et comparables à l'erreur intrinsèque de la fonctionnelle PBE0, typiquement estimée à 4 kJ/mol à 8 kJ/mol (1–2 kcal/mol) sur les énergies de réaction. Koopmans atteint donc la limite de précision du calcul de référence lui-même pour cette série. La qualité de ces corrélations s'explique par l'homogénéité chimique de notre jeu de données : tous les composés partagent le squelette catéchol/quinone, et les variations de substituants modifient les niveaux orbitalaires de manière continue et monotone. La dispersion résiduelle per-conformère provient principalement de la variabilité du terme E_{relax}, qui n'est pas capturé par l'approximation de Koopmans, et non d'un échec de la corrélation orbitalaire elle-même. Cette observation motive l'exploration de modèles au-delà de l'orbitale frontière unique.



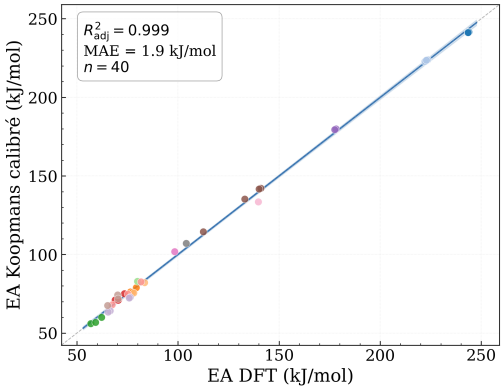
(a) IP vs HOMO ($R^2 = 0.974$, $n = 15$).



(b) EA vs LUMO ($R^2 = 0.998$, $n = 15$).



(c) IP vs HOMO per-conformère ($R^2_{\mathrm{adj}} = 0.958$, $n = 40$).



(d) EA vs LUMO per-conformère ($R^2_{\mathrm{adj}} = 0.999$, $n = 40$).

FIGURE 4 – Corrélations de Koopmans (schéma composite TZ2P). (a)–(b) Moyennes de Boltzmann par molécule ($n = 15$). (c)–(d) Per-conformère (couleurs par molécule, $n = 40$).

3.1.2 Au-delà de Koopmans : l'approche de Politzer et Murray

L'approximation de Koopmans repose sur une seule orbitale frontière (HOMO ou LUMO), négligeant la contribution de toutes les autres orbitales à la densité électronique. L'énergie d'io-

nisation locale moyenne (*Average Local Ionization Energy*, ALIE), introduite par Politzer et Murray [3], propose une approche *a priori* plus complète en intégrant la contribution de l'ensemble des orbitales occupées à la densité locale. Cette formulation devrait en principe mieux capturer les effets de délocalisation et de structure électronique profonde qui influencent le potentiel d'ionisation. L'ALIE en un point $\mathbf{r}$ est définie par :

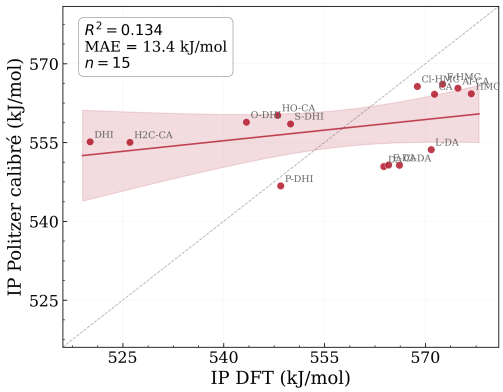
$$\bar{I}(\mathbf{r}) = \frac{\sum_i n_i \, |\psi_i(\mathbf{r})|^2 \, |\varepsilon_i|}{\rho(\mathbf{r})} \tag{3}$$

où n_i est l'occupation, $\psi_i(\mathbf{r})$ la fonction d'onde et ε_i l'énergie de l'orbitale i, et $\rho(\mathbf{r})$ la densité électronique totale. L'ALIE représente ainsi l'énergie moyenne nécessaire pour arracher un électron au point $\mathbf{r}$, pondérée par la contribution de chaque orbitale à la densité locale.

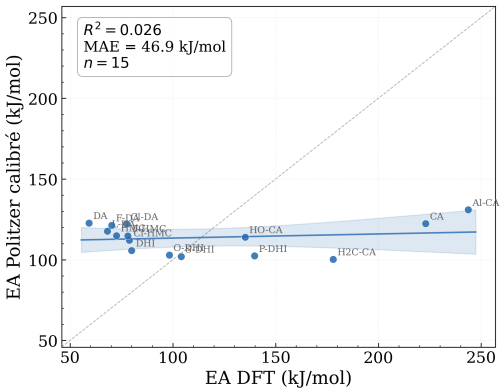
Le descripteur clé est $\bar{I}_{S,\min}$, la valeur minimale de l'ALIE sur la surface d'isodensité $\rho = 0.001\,\mathrm{a\,u}$ Cette surface, qui correspond approximativement à l'enveloppe de van der Waals de la molécule, est le lieu où les interactions intermoléculaires débutent. Le minimum $\bar{I}_{S,\min}$ identifie le site où les électrons sont les plus faiblement liés et corrèle linéairement avec le potentiel d'ionisation vertical pour des séries de molécules apparentées [3]. De façon analogue, le minimum du potentiel électrostatique sur cette même surface ($V_{S,\min}$) est relié à l'affinité électronique.

Implémentation. Nous avons implémenté le calcul de l'ALIE par post-traitement DENSF sur les fichiers RKF des calculs neutres existants, sans nouveau calcul SCF. Le pipeline comprend quatre phases : (i) calcul de la densité SCF sur une grille 3D, (ii) extraction des points de l'isosurface $\rho = 0.001\,\mathrm{a\,u}$ par interpolation linéaire sur les arêtes de la grille ($\sim$25 000 points par molécule), (iii) évaluation des orbitales occupées, de la densité et du potentiel coulombien à chaque point de surface via DENSF en mode `Grid Inline`, et (iv) calcul de $\bar{I}(\mathbf{r})$ selon l'équation (3) et extraction des descripteurs $\bar{I}_{S,\min}$ et $V_{S,\min}$.

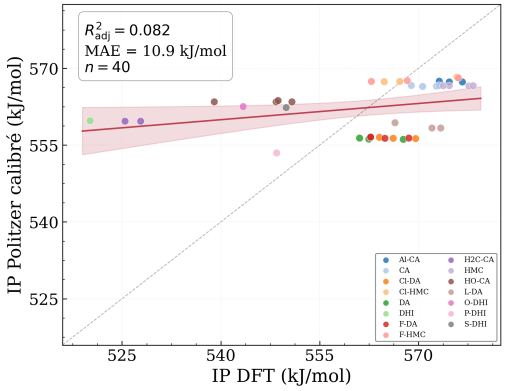
Résultats. L'analyse a été réalisée sur 34 molécules (catéchols et quinones) totalisant 74 conformères. Les valeurs de $\bar{I}_{S,\min}$ obtenues se situent entre 7.8 eV à 9.9 eV, dans la gamme attendue pour des molécules organiques. Cependant, après calibration par régression linéaire (figure 5), les erreurs de prédiction restent élevées : MAE = 49.6 kJ/mol pour $\bar{I}_{S,\min}$ vs IP ($R^2 = 0.10$) et MAE = 56.0 kJ/mol pour $-V_{S,\min}$ vs EA ($R^2 = 0.76$). En comparaison, l'approximation de Koopmans donne MAE = 2.1 kJ/mol pour IP ($R^2 = 0.974$) et MAE = 2.3 kJ/mol pour EA ($R^2 = 0.998$).



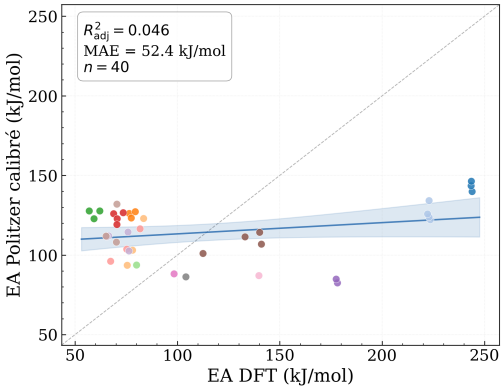
(a) IP Politzer calibré ($n = 15$).



(b) EA Politzer calibré ($n = 15$).



(c) IP vs $\bar{I}_{S,\min}$ per-conformère ($n = 40$).



(d) EA vs $-V_{S,\min}$ per-conformère ($n = 40$).

FIGURE 5 – Prédictions Politzer calibrées ($\bar{I}_{S,\min}$, $-V_{S,\min}$). (a)–(b) Par molécule. (c)–(d) Per-conformère (couleurs par molécule). À comparer avec les corrélations de Koopmans (figure 4).

L'analyse per-conformère (figure 5c–d) confirme l'absence de pouvoir prédictif de Politzer. Le contraste avec Koopmans per-conformère (figure 4c–d) est saisissant.

Analyse de l'échec. Ces résultats sont étonnamment mauvais. Dans la littérature, Politzer et Murray rapportent des corrélations $R^2 > 0.93$ pour $\bar{I}_{S,\min}$ vs IP au sein de séries homologues (benzènes substitués, azines), et même sur des séries moléculaires diversifiées, R^2 reste typiquement supérieur à 0.70 [3]. Notre série de catéchols, chimiquement homogène (même squelette, variations de substituants modérées), devrait *a priori* donner des résultats au moins comparables. L'obtention d'un $R^2 = 0.10$ pour l'IP suggère un problème d'implémentation plutôt qu'une limitation intrinsèque de la méthode.

Une analyse rétrospective de notre code a en effet révélé plusieurs limitations. Premièrement, le descripteur $V_{S,\min}$ a été calculé à partir du potentiel coulombien électronique seul (`POTENTIAL coul SCF` dans DENSF), et non du potentiel électrostatique moléculaire total (MEP $= V_{\text{nucléaire}} + V_{\text{électronique}}$) tel que défini par Politzer et Murray. Cela invalide la comparaison avec la littérature pour l'EA. Deuxièmement, des problèmes de robustesse ont été identifiés lors de la réutilisation de fichiers TAPE41 pré-existants, pouvant conduire à des résultats corrompus sur certains conformères. Enfin, la résolution de la grille utilisée (`GRID medium`) pourrait être insuffisante pour localiser précisément le minimum global de $\bar{I}(\mathbf{r})$ sur l'isosurface.

En l'état, nous ne pouvons pas conclure sur la validité de l'approche de Politzer pour notre système. Cette piste nécessite une révision de l'implémentation — en particulier l'utilisation du MEP total pour $V_{S,\min}$ et la vérification de l'intégrité des données de surface — avant de pouvoir être comparée équitablement à l'approximation de Koopmans, qui reste le prédicteur le plus fiable avec des MAE de 1.9 kJ/mol à 2.4 kJ/mol. L'approche de Politzer, même correctement

implémentée, resterait cependant un outil complémentaire : elle donne accès à une information *spatiale* (le site le plus réactif) que les énergies orbitales seules ne fournissent pas. La section suivante explore une voie intermédiaire entre Koopmans (une seule orbitale) et Politzer (toutes les orbitales) en restreignant les descripteurs aux quelques orbitales voisines des frontières.

3.1.3 Régression multi-orbitale : au-delà de l'orbitale frontière unique

Indépendamment des problèmes d'implémentation de l'ALIE, la question théorique demeure : combien d'orbitales faut-il inclure pour prédire IP et EA ? L'approximation de Koopmans ne repose que sur une seule orbitale frontière, tandis que l'ALIE de Politzer mobilise *toutes* les orbitales occupées via une moyenne pondérée par la densité. Une voie intermédiaire naturelle consiste à inclure un nombre restreint d'orbitales voisines des frontières comme descripteurs dans une régression linéaire multivariée. Cette approche capture la physique du gap HOMO–LUMO — relié à la dureté chimique $\eta = (\varepsilon_L - \varepsilon_H)/2$, qui module la relaxation orbitale post-ionisation — sans les complications liées à l'évaluation de propriétés sur l'isosurface de densité. Elle est justifiée théoriquement par le théorème IP de Bartlett [4], qui établit que dans le DFT exact, chaque énergie orbitale occupée satisfait $\mathrm{IP}_i = -\varepsilon_i$, et par les travaux récents de Chan et Bochevarov [5] qui montrent l'intérêt de régressions calibrées sur les énergies orbitales KS pour prédire les potentiels d'ionisation.

Modèles testés. Nous considérons trois modèles de complexité croissante, calibrés par régression linéaire (OLS) sur les 15 catéchols (40 conformères) :

- **Koopmans calibré** : $Y = a\,\varepsilon_{\mathrm{ref}} + b$ (2 paramètres), où $\varepsilon_{\mathrm{ref}} = \varepsilon_H$ pour IP et ε_L pour EA.
- **Bilinéaire** $\varepsilon_H + \varepsilon_L$: $Y = a\,\varepsilon_H + b\,\varepsilon_L + c$ (3 paramètres). Ce modèle encode implicitement le gap HOMO–LUMO, relié à la dureté chimique.
- **4 orbitales** : $Y = a\,\varepsilon_{H-1} + b\,\varepsilon_H + c\,\varepsilon_L + d\,\varepsilon_{L+1} + e$ (5 paramètres). Ce modèle inclut les orbitales immédiatement voisines des frontières.

Résultats pour l'IP. Le tableau 6 et la figure 6 résument les performances. L'ajout de ε_L au modèle de Koopmans réduit la MAE de 1.20 kJ/mol à 0.83 kJ/mol ($F = 38.1$, $p = 4 \times 10^{-7}$). Le modèle à 4 orbitales abaisse encore la MAE à 0.66 kJ/mol. La validation croisée *leave-one-molecule-out* confirme le gain progressif (CV-MAE : 1.34 → 1.03 → 0.89 kJ/mol). Dans le modèle à 4 orbitales, tous les descripteurs sont significatifs (ε_{H-1} : $p = 3 \times 10^{-4}$, ε_{L+1} : $p = 0.026$), mais le nombre réduit de paramètres du modèle bilinéaire (3 vs 5) le rend préférable pour le criblage sur des séries de taille comparable.

TABLE 6 – Prédiction de l'IP par régression sur les énergies orbitales TZ2P ($n = 40$, 15 catéchols). Les énergies orbitales sont exprimées en kJ/mol.

Modèle	R^2_{adj}	MAE (kJ/mol)	RMSE (kJ/mol)	CV-MAE (kJ/mol)	F-test vs Koopmans
Koopmans (ε_H)	0.9895	1.20	1.47	1.34	—
$\varepsilon_H + \varepsilon_L$	0.9947	0.83	1.03	1.03	$p = 4 \times 10^{-7}$
4 orbitales	0.9964	0.66	0.83	0.89	$p = 8 \times 10^{-9}$

Le modèle bilinéaire retenu pour l'IP est :

$$\mathrm{IP} = -1.014\,\varepsilon_H + 0.017\,\varepsilon_L - 51.7 \quad (\mathrm{kJ/mol},\ \varepsilon \text{ en kJ/mol}) \tag{4}$$

où le coefficient de ε_L est hautement significatif ($t = 6.2$, $p = 4 \times 10^{-7}$). Le coefficient de ε_H est proche de -1, en accord avec l'approximation de Koopmans.

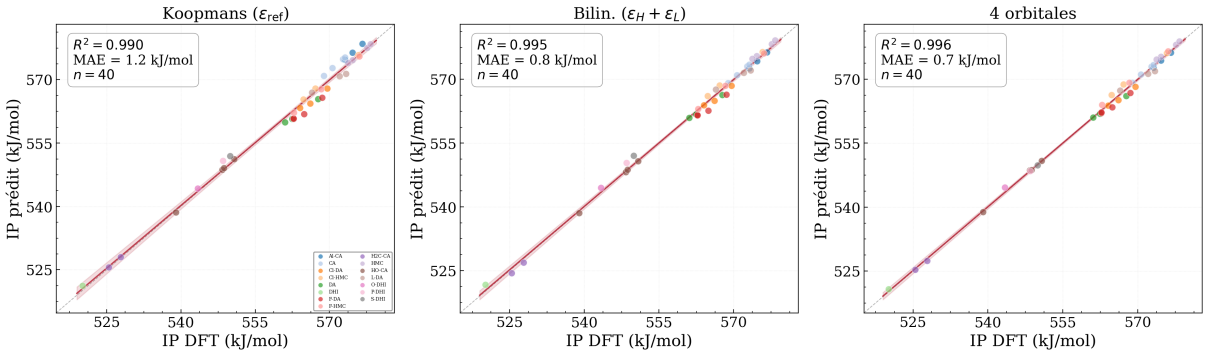


FIGURE 6 – Prédiction de l'IP par les trois modèles de régression orbitale (15 catéchols, 40 conformères). De gauche à droite : Koopmans calibré (ε_H), bilinéaire ($\varepsilon_H + \varepsilon_L$), et 4 orbitales ($\varepsilon_{H-1}, \varepsilon_H, \varepsilon_L, \varepsilon_{L+1}$). Chaque point est un conformère, couleur par molécule.

Résultats pour l'EA. Pour l'affinité électronique (tableau 7, figure 7), le constat est différent : ni l'ajout de ε_H ni celui des 4 orbitales n'améliore la prédiction de Koopmans. Aucun des descripteurs supplémentaires n'est significatif (tous $p > 0.7$), et la CV se dégrade à chaque paramètre ajouté. Le modèle optimal pour l'EA reste l'approximation de Koopmans calibrée :

$$\text{EA} = -0.994\,\varepsilon_L + 34.2 \quad (\text{kJ/mol},\ \varepsilon \text{ en kJ/mol}) \tag{5}$$

Le coefficient de ε_L, très proche de -1, confirme la validité de l'approximation de Koopmans pour l'EA sur cette série.

TABLE 7 – Prédiction de EA par régression sur les énergies orbitales TZ2P ($n = 40$, 15 catéchols sans DEA). Les énergies orbitales sont exprimées en kJ/mol.

Modèle	R^2_{adj}	MAE (kJ/mol)	RMSE (kJ/mol)	CV-MAE (kJ/mol)	F-test vs Koopmans
Koopmans (ε_L)	0.9984	1.66	2.40	1.90	—
$\varepsilon_H + \varepsilon_L$	0.9984	1.65	2.40	2.00	$p = 0.72$ (ns)
4 orbitales	0.9983	1.65	2.40	2.19	$p = 0.99$ (ns)

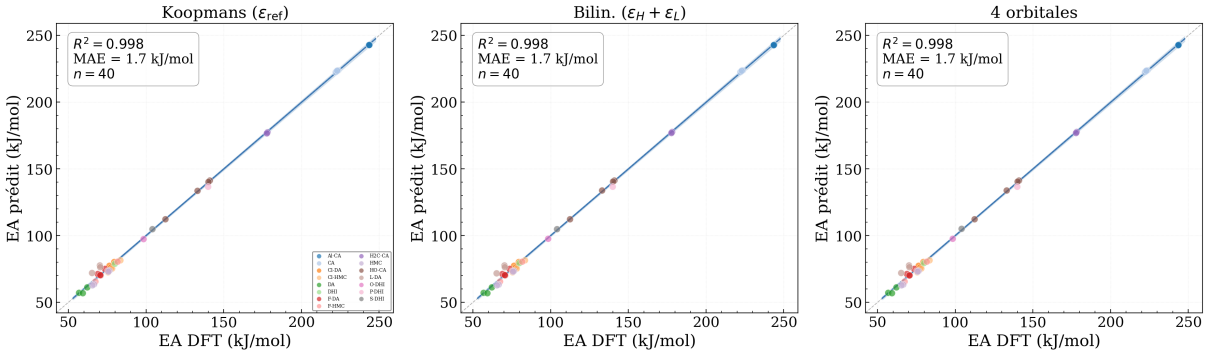
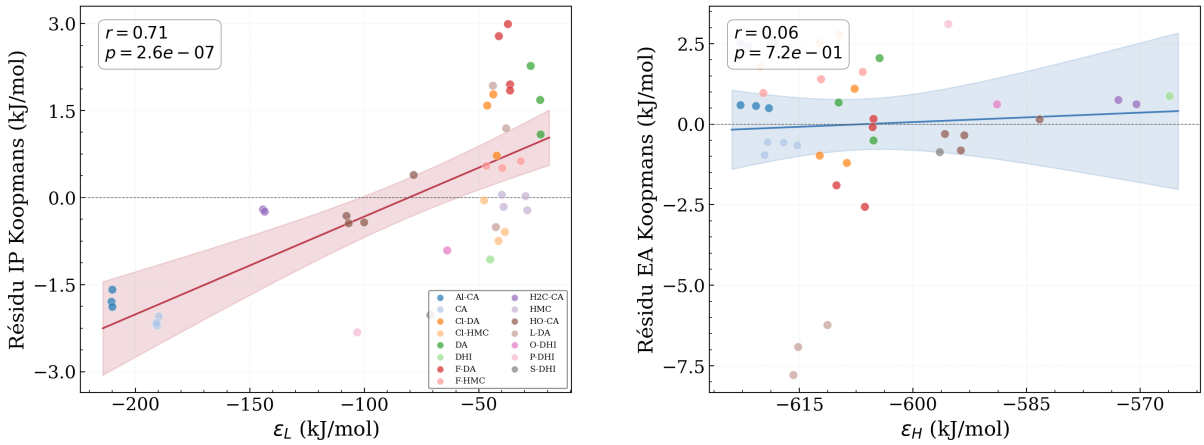


FIGURE 7 – Prédiction de EA par les trois modèles de régression orbitale (15 catéchols sans DEA, 40 conformères).

Discussion. L'amélioration apportée par le second descripteur est marquée pour l'IP (-26% de MAE, -21% de CV-MAE) mais inexistante pour l'EA. L'origine de cette asymétrie est visible sur la figure 8 : les résidus de Koopmans pour l'IP sont corrélés avec ε_L ($r = +0.71$, $p = 3 \times 10^{-7}$),

tandis que ceux de l'EA ne le sont avec aucun des descripteurs testés ($r = +0.06$ pour ε_H, $p = 0.72$). À HOMO égale, les molécules avec un gap HOMO–LUMO plus grand ont un IP systématiquement sous-estimé par Koopmans : le gap encode la dureté chimique, qui module l'amplitude de la relaxation orbitale post-ionisation.



(a) Résidu IP vs ε_L ($r = 0.71$, $p = 3 \times 10^{-7}$).

(b) Résidu EA vs ε_H ($r = 0.06$, ns).

FIGURE 8 – Résidus de Koopmans en fonction de l'orbitale complémentaire (couleurs par molécule, $n = 40$). (a) La corrélation significative montre que le gap HOMO–LUMO encode l'information manquante pour l'IP. (b) Aucune corrélation pour l'EA.

Cette asymétrie reflète la nature différente de la relaxation orbitale lors de l'ionisation versus la réduction. Lors du retrait d'un électron, les orbitales restantes se contractent, et l'amplitude de cette contraction dépend du gap — une molécule plus dure (gap plus grand) relaxe moins, ce qui module l'écart à Koopmans. Lors de l'ajout d'un électron (réduction), la dilatation des orbitales occupées est plus uniforme et moins sensible au gap. Sur cette série chimiquement homogène de catéchols, l'EA est donc parfaitement prédite par ε_L seule ($R^2 = 0.998$), tandis que l'IP bénéficie significativement de l'ajout de ε_L. Le modèle retenu est ainsi le bilinéaire $\varepsilon_H + \varepsilon_L$ pour l'IP et le Koopmans calibré pour l'EA.

Validation sur un jeu étendu. Pour vérifier la généralisabilité de ces conclusions, nous avons appliqué les trois modèles à un jeu de données élargi comprenant 70 molécules (catéchols, quinones, lignanes et dérivés halogénés) totalisant 167 conformères (tableau 8). Les résultats confirment les tendances observées sur les 15 catéchols. Pour l'IP, le modèle bilinéaire apporte une amélioration significative ($p = 1.3 \times 10^{-4}$), réduisant la MAE de 2.21 kJ/mol à 1.98 kJ/mol. Le modèle à 4 orbitales n'améliore pas la CV-MAE, signe d'un léger surapprentissage sur ce jeu plus varié. Pour l'EA, l'approximation de Koopmans est remarquablement robuste ($R^2_{\text{adj}} = 0.999$, MAE = 2.14 kJ/mol) et aucun descripteur supplémentaire n'apporte d'amélioration significative. On peut donc conclure que la correction bilinéaire par ε_L est justifiée pour la prédiction de l'IP, tandis que l'EA est déjà optimalement prédite par ε_L seule via l'approximation de Koopmans.

TABLE 8 – Prédiction de l'IP et de l'EA sur un jeu étendu de 70 molécules (167 conformères). Les énergies orbitales sont exprimées en kJ/mol.

	Modèle	R^2_{adj}	MAE (kJ/mol)	RMSE (kJ/mol)	CV-MAE (kJ/mol)	F-test vs Koopmans
IP	Koopmans (ε_H)	0.9914	2.21	3.84	2.31	—
	$\varepsilon_H + \varepsilon_L$	0.9921	1.98	3.67	2.09	$p = 1.3 \times 10^{-4}$
	4 orbitales	0.9927	2.04	3.51	2.27	$p = 1.9 \times 10^{-6}$
EA	Koopmans (ε_L)	0.9990	2.14	3.74	2.19	—
	$\varepsilon_H + \varepsilon_L$	0.9990	2.11	3.73	2.18	$p = 0.31$ (ns)
	4 orbitales	0.9990	2.11	3.73	2.21	$p = 0.78$ (ns)

3.2 Corrélations de E_{relax}

Contrairement à EA et IP, il n'existe pas de théorème général reliant E_{relax} aux propriétés de l'état neutre. L'approche vibronique de référence pour prédire cette grandeur est le couplage vibronique linéaire (LVC), que nous avons appliqué systématiquement avant d'en analyser les limites.

3.2.1 Prédiction par couplage vibronique linéaire

L'approche LVC estime l'énergie de relaxation par le développement quadratique de la PES ionique autour de la géométrie neutre R_0. Sous forme matricielle :

$$E_{\text{relax}} \approx -\tfrac{1}{2}\, \boldsymbol{g}^T \mathbf{H}^{-1} \boldsymbol{g} \tag{6}$$

où $\boldsymbol{g} = \nabla V_{\text{ion}}(R_0)$ est le gradient de la PES ionique à la géométrie neutre et $\mathbf{H}$ est un Hessien. En décomposant sur les modes normaux $\mathbf{N}_i$ (vecteurs propres de $\mathbf{H}$, normalisés à 1 en espace cartésien) :

$$E^{\text{LVC}}_{\text{relax}} = -\sum_i \frac{F_i^2}{2k_i}, \quad F_i = \boldsymbol{g} \cdot \mathbf{N}_i \tag{7}$$

où k_i est la constante de force (valeur propre du Hessien projeté sur le mode i, en Hartree/Bohr^2). La question cruciale est : *quel Hessien utiliser ?* Nous distinguons deux variantes selon le choix du Hessien.

LVC1 : Hessien neutre. L'approche classique utilise le Hessien de l'état neutre ($\mathbf{H}_{\text{neutre}}$), calculé lors de l'optimisation géométrique. Elle suppose implicitement que la courbure de la PES ionique est identique à celle de la PES neutre, c'est-à-dire que les modes normaux et constantes de force ne changent pas lors du transfert d'électron.

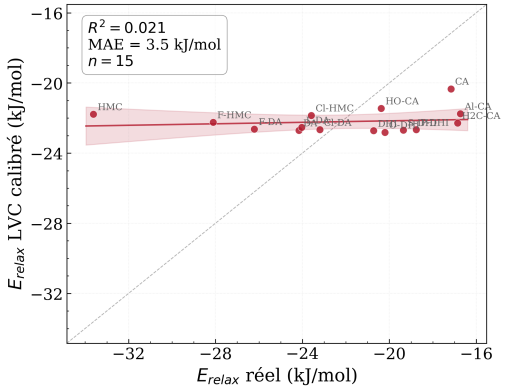
LVC2 : Hessien ionique. La seconde variante remplace $\mathbf{H}_{\text{neutre}}$ par le Hessien ionique $\mathbf{H}_{\text{ion}}(R_0)$, évalué à la géométrie neutre lors du calcul single-point ionique (avec l'option `NormalModes`) :

$$E^{\text{LVC2}}_{\text{relax}} = -\sum_j \frac{F_j'^{\,2}}{2k'_j} = -\tfrac{1}{2}\, \boldsymbol{g}^T \mathbf{H}^{-1}_{\text{ion}} \boldsymbol{g}, \quad F'_j = \boldsymbol{g} \cdot \mathbf{N}'_j \tag{8}$$

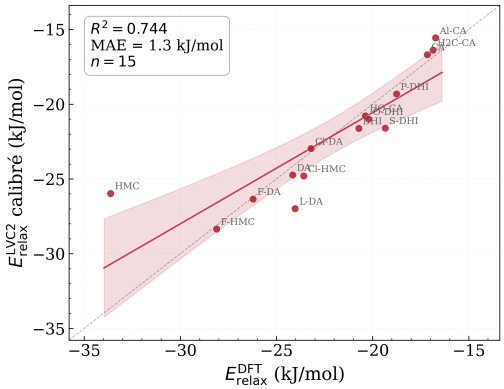
où $\mathbf{N}'_j$ et k'_j sont les modes normaux et constantes de force du Hessien ionique. Cette formulation est exacte au second ordre du développement de Taylor de V_{ion} autour de R_0 : gradient et courbure sont tous deux évalués sur la *même* PES ionique, assurant la cohérence du développement. Le calcul ne requiert qu'un single-point ionique avec NormalModes activé — les gradients et le Hessien sont extraits du même fichier RKF (le Hessien numérique est calculé par différences finies, $\sim 6N$ SCF additionnels).

Filtre des modes basse fréquence. Le Hessien ionique évalué à la géométrie neutre n'est pas stationnaire : il contient des modes propres avec fréquences imaginaires (modes mous instabilisés par le transfert d'électron, attendus selon la théorie LVC) et des modes positifs très basse fréquence ($< 50\,\mathrm{cm}^{-1}$) qui sont des artefacts numériques de l'approximation harmonique. Pour ces derniers, le terme $F_j'^{\,2}/(2k_j')$ avec $k_j' \propto \omega_j^2 \to 0$ diverge artificiellement : un seul mode à $\omega = 20\,\mathrm{cm}^{-1}$ avec $|F_j'| \sim 10^{-3}\,\mathrm{Ha/Bohr}$ contribue à lui seul $\sim 10^5\,\mathrm{kJ/mol}$. La somme de l'équation 8 est donc restreinte aux modes positifs de fréquence $\omega_j \geq 50\,\mathrm{cm}^{-1}$. Ce seuil élimine les artefacts sans amputer la physique pertinente : les modes physiques (torsions, rotations de groupes) commencent typiquement vers 50–100 cm^{-1}, et faire varier le seuil entre 50 et 200 cm^{-1} ne change le R^2 que de moins de 1 %.

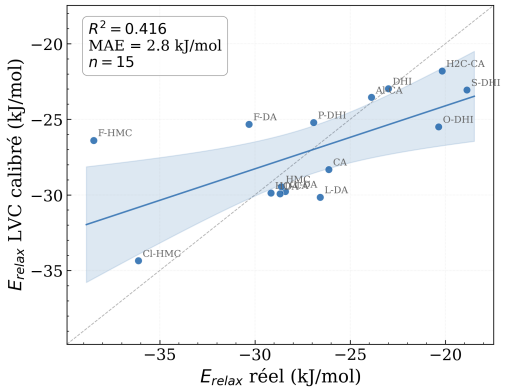
Résultats. La figure 9 compare les deux variantes. Le LVC1 avec Hessien neutre (a, c) surestime systématiquement E_{relax} d'un facteur 3 à 20 (MAE $\approx 90\,\mathrm{kJ/mol}$ pour les deux processus). Le LVC2 avec Hessien ionique (b, d) donne des prédictions excellentes après calibration linéaire : MAE de 1.3 kJ/mol pour l'oxydation ($R^2 = 0.74$) et 1.7 kJ/mol pour la réduction ($R^2 = 0.84$), soit une amélioration d'un facteur 50 à 70.



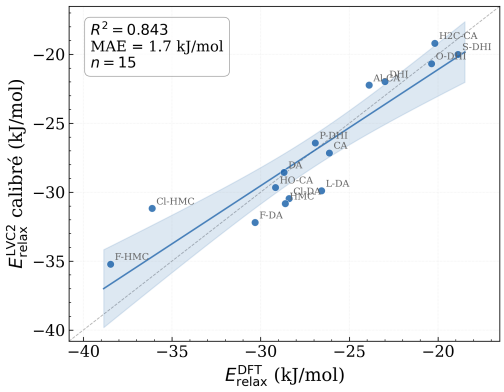
(a) Oxydation — LVC1 ($R^2 = 0.02$, MAE = 90 kJ/mol).



(b) Oxydation — LVC2 calibré ($R^2 = 0.74$, MAE = 1.3 kJ/mol).



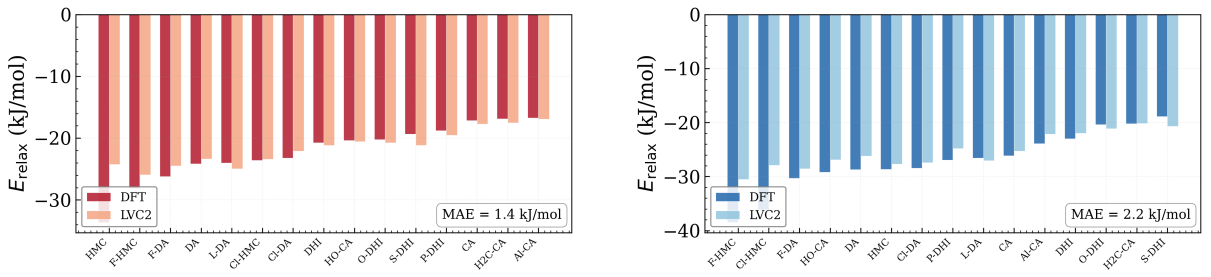
(c) Réduction — LVC1 ($R^2 = 0.42$, MAE = 90 kJ/mol).



(d) Réduction — LVC2 calibré ($R^2 = 0.84$, MAE = 1.7 kJ/mol).

FIGURE 9 – Prédiction de E_{relax} par couplage vibronique linéaire. Gauche : LVC1 (Hessien neutre, calibré), droite : LVC2 (Hessien ionique, calibré). La ligne pointillée représente $y = x$ (accord parfait). $n = 15$ molécules.

La figure 10 synthétise la comparaison molécule par molécule entre les valeurs LVC2 prédites et les valeurs DFT réelles. L'accord est remarquable pour les deux processus, les barres prédites se superposant quasi-parfaitement aux barres DFT.



(a) Oxydation (MAE = 1.4 kJ/mol). (b) Réduction (MAE = 2.2 kJ/mol).

FIGURE 10 – Comparaison LVC2 (prédit) vs DFT (réel) de E_{relax} pour chaque molécule. Les barres sont triées par E_{relax} DFT croissant.

Discussion. L'échec du LVC1 est identifié par l'analyse mode par mode : les modes basse fréquence du neutre ($< 200\,\text{cm}^{-1}$) ont des constantes de force k_i très faibles, et le terme $F_i^2/(2k_i)$ diverge. Par exemple, pour CA conf 1, le mode à $89\,\text{cm}^{-1}$ ($k = 0{,}002$ Hartree/Bohr^2) contribue à lui seul -107 kJ/mol à l'estimation LVC1, alors que $E_{\text{relax}}^{\text{réel}} = -26$ kJ/mol. Ces modes mous du neutre (torsions, rotations de groupes latéraux) se raidissent significativement dans l'état ionique : le Hessien neutre n'est pas une bonne approximation du Hessien ionique dans cette gamme de fréquences.

Le succès du LVC2 confirme que le problème n'est pas dans le formalisme LVC lui-même, mais dans le choix du Hessien. Évaluer gradient et courbure sur la *même* PES ionique assure la cohérence du développement de Taylor au second ordre. Les MAE obtenues (1.4 kJ/mol à 2.2 kJ/mol) sont comparables à l'incertitude intrinsèque de la fonctionnelle PBE0 (4 kJ/mol à 8 kJ/mol). Toutefois, un résidu systématique subsiste en réduction pour certaines molécules, ce qui motive la recherche de corrections.

3.2.2 Correction par la composition de la LUMO

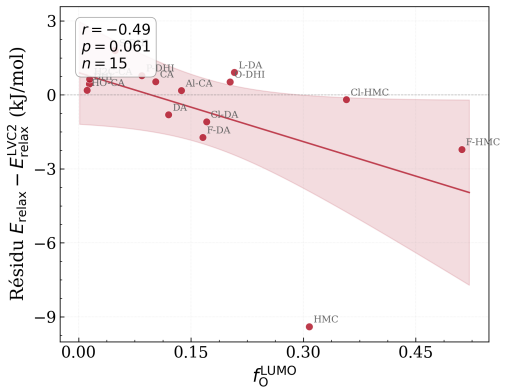
Théorie. Le résidu $E_{\text{relax}} - E_{\text{relax}}^{\text{LVC2}}$ est systématiquement négatif pour certaines molécules (le LVC2 prédit une relaxation insuffisante). Une analyse systématique des descripteurs moléculaires accessibles depuis le calcul neutre révèle que la *fraction de la LUMO localisée sur les atomes d'oxygène* ($f_{\text{O}}^{\text{LUMO}}$, obtenue par analyse des populations SFO) est le meilleur prédicteur de ce résidu. Ce descripteur capture le caractère antiliant O–H de la LUMO : lorsque $f_{\text{O}}^{\text{LUMO}}$ est élevé, la réduction transfère un électron dans une orbitale qui affaiblit les liaisons O–H, entraînant un réarrangement géométrique important que l'approximation harmonique du LVC2 ne capte pas entièrement.

Le modèle de correction proposé est :

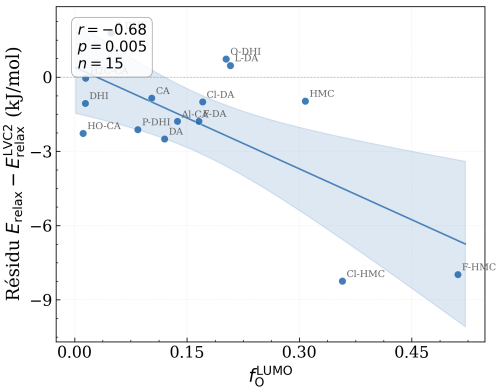
$$E_{\text{relax}}^{\text{corr}} = E_{\text{relax}}^{\text{LVC2}} \times \left(1 + \left(f_{\text{O}}^{\text{LUMO}}\right)^2\right) \tag{9}$$

Ce modèle ne comporte *aucun paramètre libre* : le facteur $(1 + (f_{\text{O}}^{\text{LUMO}})^2)$ amplifie la relaxation LVC2 proportionnellement au caractère oxygène de la LUMO. Il n'y a donc aucun risque de surparamétrisation.

Résultats. La figure 11 montre la corrélation entre le résidu LVC2 et $f_{\text{O}}^{\text{LUMO}}$ pour les deux processus. En réduction ($r = -0.68$, $p = 0.005$), les molécules à forte localisation de la LUMO sur les oxygènes (F-HMC : $f_{\text{O}} = 0.51$, Cl-HMC : $f_{\text{O}} = 0.36$) présentent les résidus les plus négatifs. En oxydation, la tendance est plus faible ($r = -0.49$, $p = 0.061$), cohérent avec un résidu déjà petit.



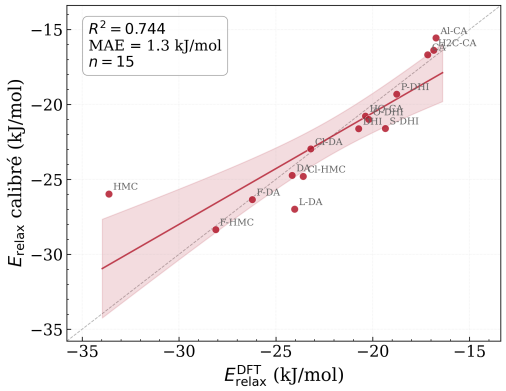
(a) Oxydation ($r = -0.49$, $p = 0.061$).



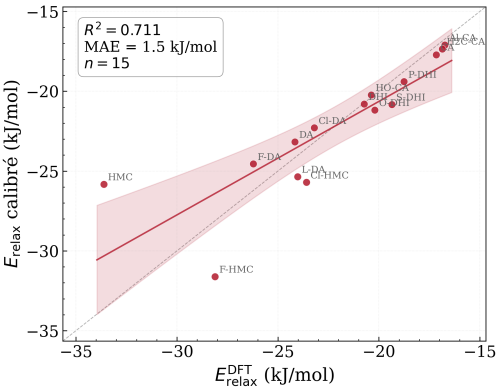
(b) Réduction ($r = -0.68$, $p = 0.005$).

FIGURE 11 – Résidu $E_{\text{relax}} - E_{\text{relax}}^{\text{LVC2}}$ en fonction de $f_{\text{O}}^{\text{LUMO}}$. La corrélation est significative en réduction (b) mais marginale en oxydation (a). $n = 15$ molécules.

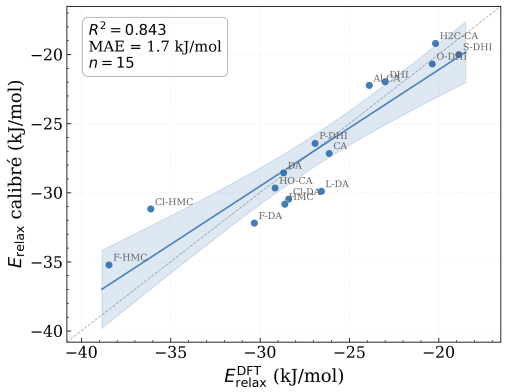
La figure 12 compare le LVC2 brut et le LVC2 corrigé pour les deux processus (parity plots calibrés). En réduction, la MAE calibrée passe de 1.7 kJ/mol à 1.4 kJ/mol (R^2 de 0.84 à 0.89). En oxydation, la correction n'apporte pas d'amélioration notable (MAE de 1.3 kJ/mol à 1.5 kJ/mol), le résidu étant déjà quasi-nul.



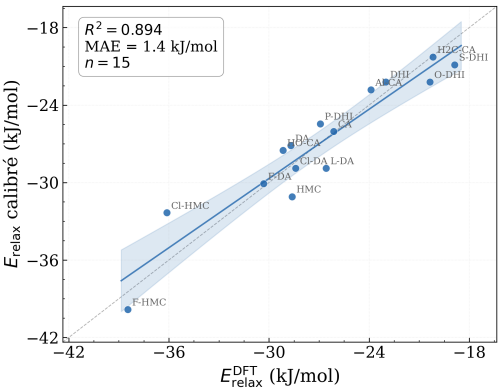
(a) Oxydation — LVC2 brut.



(b) Oxydation — LVC2 corrigé.



(c) Réduction — LVC2 brut.



(d) Réduction — LVC2 corrigé.

FIGURE 12 – Effet de la correction LUMO (éq. 9) sur la prédiction de E_{relax}. Haut : oxydation, bas : réduction. Gauche : LVC2 brut, droite : LVC2 corrigé. Tous les parity plots sont calibrés. La correction améliore la réduction (R^2 : 0.84 → 0.89) mais pas l'oxydation.

Discussion. La correction par $f_{\mathrm{O}}^{\mathrm{LUMO}}$ est efficace mais repose sur une vision mono-orbitale (la LUMO seule) de la redistribution électronique lors de la réduction. Or, la densité de l'électron ajouté ne coïncide pas exactement avec $|\psi_{\mathrm{LUMO}}|^2$: la relaxation orbitale redistribue la densité sur l'ensemble des orbitales occupées. Cette observation motive l'utilisation des fonctions de Fukui, qui intègrent cette relaxation par construction et constituent la généralisation naturelle de l'approche mono-orbitale à la DFT conceptuelle.

3.2.3 Correction par les fonctions de Fukui

Théorie. La DFT conceptuelle (CDFT) fournit des descripteurs de réactivité fondés sur la réponse de la densité électronique au changement du nombre d'électrons. Les fonctions de Fukui condensées sur les bassins atomiques A sont définies par :

$$f_A^+ = q_A(N) - q_A(N+1) \qquad \text{(attaque nucléophile, réduction)} \qquad (10)$$

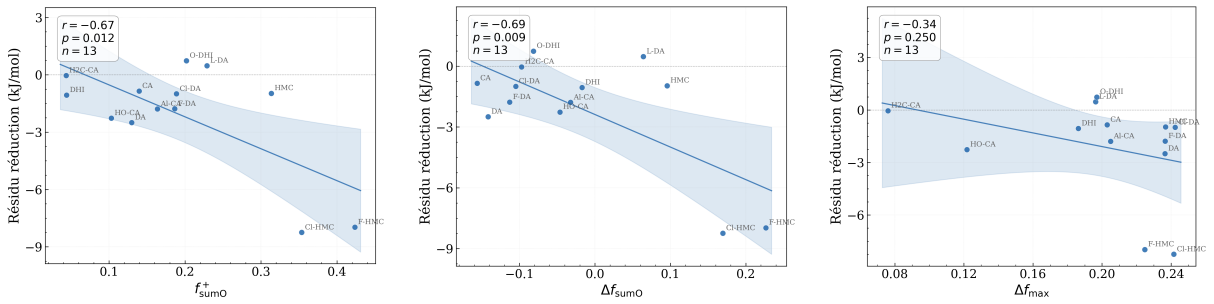
$$f_A^- = q_A(N-1) - q_A(N) \qquad \text{(attaque électrophile, oxydation)} \qquad (11)$$

$$\Delta f_A = f_A^+ - f_A^- \qquad \text{(descripteur dual)} \qquad (12)$$

où $q_A(N)$ est la charge de Hirshfeld de l'atome A dans le système à N électrons. Contrairement à $f_{\mathrm{O}}^{\mathrm{LUMO}}$ qui ne voit que la LUMO, f_A^+ intègre la relaxation orbitale complète lors de l'ajout d'un électron. Plusieurs descripteurs condensés sont envisageables : somme sur les oxygènes (f^+_{sumO}), valeur maximale atomique ($\max_A f_A^+$), ou descripteur dual intégré (Δf_{sumO}). Les descripteurs globaux de CDFT — potentiel chimique μ, dureté η et électrophilicité ω — sont également testés.

Résultats. Chaque processus redox est analysé avec la fonction de Fukui physiquement pertinente : f^+ pour la réduction (ajout d'électron) et f^- pour l'oxydation (retrait d'électron).

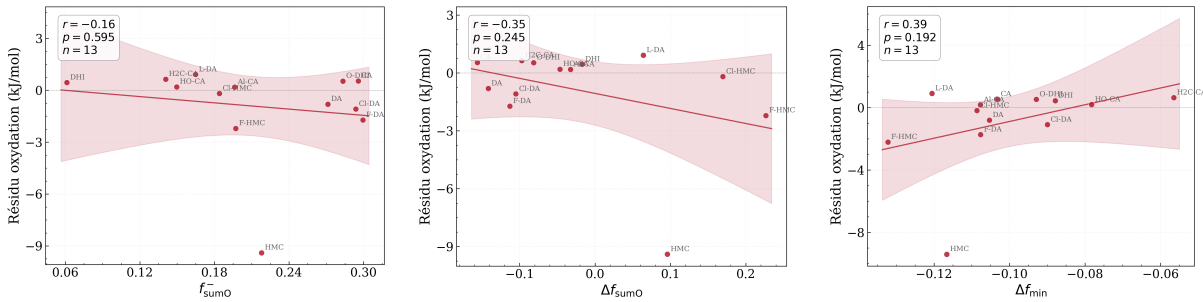
Réduction. La figure 13 montre les corrélations entre le résidu LVC2 en réduction et les descripteurs f^+ ($n = 13$ molécules). La Fukui f^+_{sumO} corrèle significativement avec le résidu ($r = -0.67$, $p = 0.012$), tout comme le descripteur dual Δf_{sumO} ($r = -0.69$, $p = 0.009$). Ces performances sont comparables à celle de $f_{\mathrm{O}}^{\mathrm{LUMO}}$ ($R^2 = 0.47$).



(a) f^+_{sumO} ($r = -0.67$, $p = 0.012$). (b) Δf_{sumO} ($r = -0.69$, $p = 0.009$). (c) Δf_{max} ($r = -0.34$, $p = 0.25$).

FIGURE 13 – Résidu LVC2 en réduction vs descripteurs de Fukui ($n = 13$). (a) f^+_{sumO} et (b) Δf_{sumO} corrèlent significativement. (c) Le descripteur dual atomique maximal Δf_{max} n'est pas significatif.

Oxydation. La figure 14 montre les corrélations avec les descripteurs f^-. Aucune corrélation significative n'est observée, ni pour f^-_{sumO} ($r = -0.16$, $p = 0.59$), ni pour le descripteur dual intégré ($r = -0.35$, $p = 0.25$), ni pour Δf_{min} ($r = 0.39$, $p = 0.19$). Ce résultat est cohérent avec la faiblesse du résidu LVC2 en oxydation (MAE brute = 1.4 kJ/mol) : le LVC2 prédit déjà E_{relax} avec une précision quasi-optimale, ne laissant pas de résidu structuré à corriger.



(a) f^-_{sumO} ($r = -0.16$, $p = 0.59$). (b) Δf_{sumO} ($r = -0.35$, $p = 0.25$). (c) Δf_{min} ($r = 0.39$, $p = 0.19$).

FIGURE 14 – Résidu LVC2 en oxydation vs descripteurs de Fukui ($n = 13$). Aucune corrélation significative. Le résidu en oxydation est trop faible pour être corrélé.

La quasi-identité des performances entre f^+_{sumO} et $f_{\mathrm{O}}^{\mathrm{LUMO}}$ en réduction suggère une redondance entre ces descripteurs. La figure 15 le confirme : les deux sont quasi-parfaitement corrélés ($r = 0.98$, $p < 10^{-4}$). Malgré leurs définitions différentes — $f_{\mathrm{O}}^{\mathrm{LUMO}}$ ne voit que la LUMO par analyse SFO, tandis que f^+_{sumO} intègre la relaxation orbitale complète par différences finies de charges — les deux descripteurs encodent la même information physique sur cette série de catéchols.

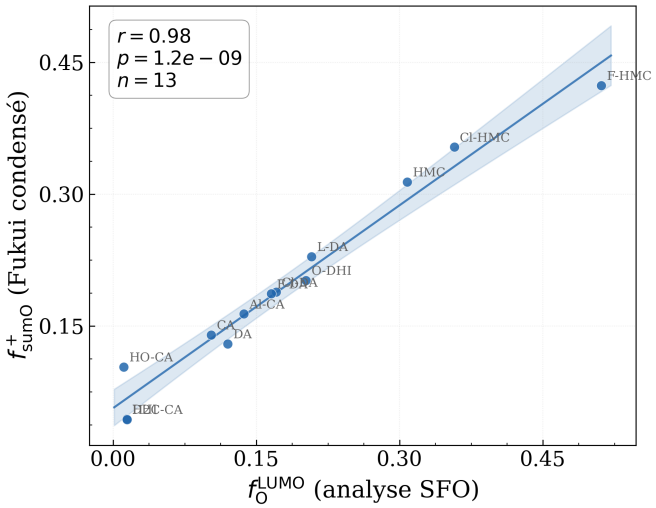


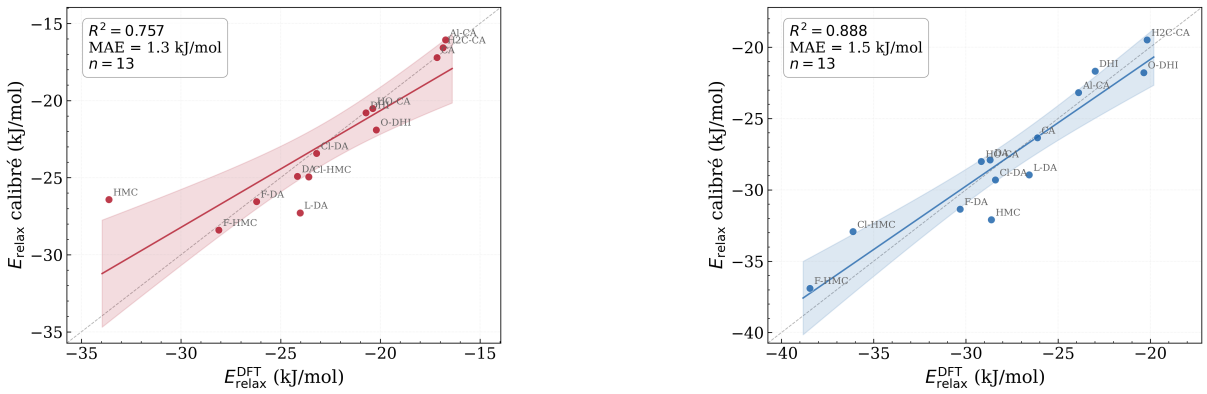
FIGURE 15 – Corrélation entre f^+_{sumO} (Fukui condensé) et $f_{\mathrm{O}}^{\mathrm{LUMO}}$ (analyse SFO). La corrélation quasi-parfaite ($r = 0.98$) démontre la redondance des deux descripteurs sur cette série chimiquement homogène.

Modèle symétrique $f^{\pm}_{\mathrm{max,O}}$. Les analyses précédentes montrent que le résidu LVC2 est contrôlé par la distribution *locale* de la densité de Fukui sur les oxygènes. Les descripteurs globaux de CDFT (μ, η, ω) ne corrèlent avec aucun des deux résidus ($R^2 < 0.09$), et les descripteurs atomiques non ciblés (Δf_{max}, Δf_{min}, top-k atomiques) sont tous non significatifs (tableau 24, annexe A). Seuls les descripteurs intégrés sur les oxygènes portent un signal, ce qui confirme que les deux processus redox de la série catéchol sont gouvernés par les oxygènes du cycle.

Cette observation motive un modèle symétrique utilisant $f^+_{\mathrm{max,O}} = \max_A f^+_A$ (sur les O) pour la réduction et $f^-_{\mathrm{max,O}} = \max_A f^-_A$ pour l'oxydation. Le modèle sans paramètre libre :

$$E^{\mathrm{corr}}_{\mathrm{relax}} = E^{\mathrm{LVC2}}_{\mathrm{relax}} \times \left(1 + \left|f^{\pm}_{\mathrm{max,O}}\right|^{3/2}\right) \tag{13}$$

atteint, après calibration, des MAE de 1.3 kJ/mol en oxydation ($R^2 = 0.76$) et 1.5 kJ/mol en réduction ($R^2 = 0.89$, figure 16), comparables au modèle LUMO (éq. 9).



(a) Oxydation — $f^{-}_{\max,O}$.

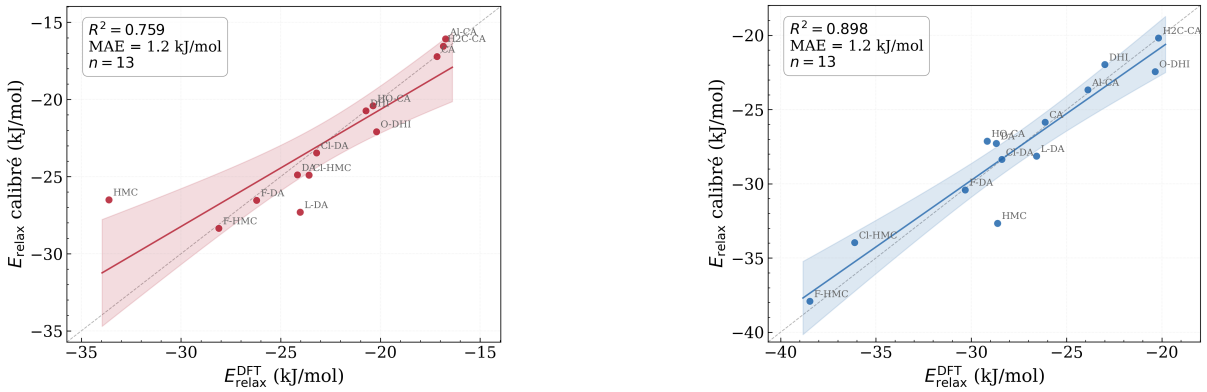
(b) Réduction — $f^{+}_{\max,O}$.

FIGURE 16 – Modèle symétrique $f^{\pm}_{\max,O}$ sans paramètre libre (éq. 13). Parity plots calibrés, $n = 13$.

Le modèle à un paramètre libre a (ajusté indépendamment par processus) :

$$E^{corr}_{relax} = E^{LVC2}_{relax} \times \left(1 + a \left| f^{\pm}_{\max,O} \right|^2\right) \tag{14}$$

améliore les deux processus simultanément : MAE de 1.2 kJ/mol en oxydation ($R^2 = 0.76$, $a_{ox} = 2.6$) et 1.2 kJ/mol en réduction ($R^2 = 0.90$, $a_{red} = 3.7$, figure 17). La proximité des coefficients a entre les deux processus (2.6 vs 3.7) renforce la cohérence physique du modèle.



(a) Oxydation ($a = 2.6$).

(b) Réduction ($a = 3.7$).

FIGURE 17 – Modèle symétrique $f^{\pm}_{\max,O}$ paramétrisé (éq. 14). Parity plots calibrés, $n = 13$.

Discussion. Le modèle symétrique $f^{\pm}_{\max,O}$ présente un avantage conceptuel sur la correction LUMO (éq. 9) : il s'applique de manière cohérente aux deux processus redox en utilisant la fonction de Fukui physiquement pertinente (f^{+} pour la réduction, f^{-} pour l'oxydation). La quasi-identité des performances entre f^{+}_{sumO} et f^{LUMO}_{O} (figure 15, $r = 0.98$) confirme que ces approches encodent la même physique : la participation des oxygènes du cycle catéchol au transfert d'électron. L'anharmonicité non captée par le LVC2 provient du réarrangement géométrique autour des liaisons C–O et O–H, d'autant plus important que la densité de Fukui sur l'oxygène le plus réactif est grande.

Le tableau 24 (annexe A) récapitule l'ensemble des descripteurs testés, confirmant que seuls les descripteurs localisés sur les oxygènes portent un signal significatif.

Bilan quantitatif. Le tableau 9 récapitule les performances des modèles de prédiction de E_{relax}.

TABLE 9 – Performances des modèles de prédiction de E_{relax} (MAE calibrée, kJ/mol).

Modèle	#param	MAE ox	MAE red	n
LVC2 brut	0	1.3	1.7	13–15
LVC2 $\times(1+(f_{\text{O}}^{\text{LUMO}})^2)$	0	1.5	1.4	15
LVC2 $\times(1+\lvert f_{\text{max,O}}^{\pm}\rvert^{3/2})$	0	1.3	1.5	13
LVC2 $\times(1+a\lvert f_{\text{max,O}}^{\pm}\rvert^{2})$	1	1.2	1.2	13

Le budget d'erreur par composante est détaillé dans le tableau 10 (section 3.5).

3.3 Prédiction de $\Delta\Delta U$

Le terme $\Delta\Delta U = [U(\text{ion}_{\text{opt}}) - E_e(\text{ion}_{\text{opt}})] - [U(\text{neutre}) - E_e(\text{neutre})]$ capture le changement d'énergie interne thermique (dominé par la ZPE) lors du changement d'état de charge. En oxydation, $\Delta\Delta U$ est toujours positif (moyenne $0.5(6)\,\text{kJ/mol}$), reflétant un léger raidissement des liaisons C–O. En réduction, il est toujours négatif (moyenne $-12.7(22)\,\text{kJ/mol}$), traduisant un assouplissement de la structure.

Échec du prédicteur ZPE. La ZPE de l'état neutre ne corrèle pas avec $\Delta\Delta U$ ($R^2 < 0.01$, $p > 0.7$), car $\Delta\Delta U$ dépend des *différences* de fréquences entre états neutre et ionique, contrôlées par la redistribution de charge locale, et non de la ZPE absolue (liée à la taille moléculaire).

Descripteur : dureté chimique η. La dureté chimique $\eta = (\text{IP} - \text{EA})/2$ mesure la résistance de la molécule au transfert de charge. Une molécule « dure » (grand η) voit ses fréquences vibrationnelles moins perturbées par l'ajout ou le retrait d'un électron, ce qui devrait se traduire par un $|\Delta\Delta U|$ plus faible. Ce descripteur est disponible sans coût supplémentaire puisque IP et EA verticaux sont déjà calculés lors du single-point ionique.

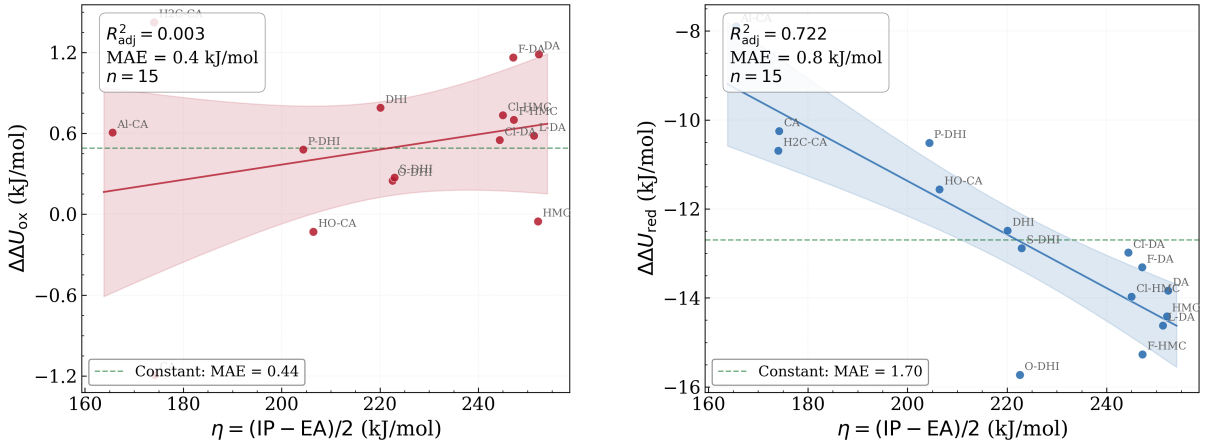
Résultats. La figure 18 montre les corrélations η vs $\Delta\Delta U$ pour les 15 catéchols.

— **Réduction** : la corrélation est forte ($R^2_{\text{adj}} = 0.72$, $n = 15$). Le modèle linéaire :

$$\Delta\Delta U_{\text{red}} = 0.67 - 0.060\,\eta \quad (\text{kJ/mol}) \tag{15}$$

donne une MAE de $0.75\,\text{kJ/mol}$, soit une amélioration d'un facteur 2.3 par rapport au modèle constant (MAE = $1.7\,\text{kJ/mol}$). La pente négative confirme l'interprétation : les molécules plus dures subissent un assouplissement vibrationnel plus faible lors de la réduction.

— **Oxydation** : $\Delta\Delta U_{\text{ox}}$ présente une variance trop faible ($\sigma = 0.6\,\text{kJ/mol}$) pour justifier un modèle au-delà de la constante. Le modèle constant $\Delta\Delta U_{\text{ox}} \approx 0.5\,\text{kJ/mol}$ (MAE = $0.4\,\text{kJ/mol}$) est retenu.



(a) Oxydation. (b) Réduction.

FIGURE 18 – Dureté chimique η vs $\Delta\Delta U$ pour les 15 catéchols. Régressions linéaires (trait plein) avec bande de confiance à 95%, et modèles constants (pointillés verts). En réduction, η explique 72% de la variance ($p < 10^{-4}$).

Une recherche exhaustive de descripteurs (indices de Fukui, descripteurs CDFT globaux, charges de Bader, indices de délocalisation QTAIM) confirme que η est le meilleur prédicteur à un descripteur pour $\Delta\Delta U_{red}$. Des modèles à deux descripteurs, comme (DI_{sumO}, ω) avec $\omega = \mu^2/(2\eta)$ l'électrophilicité globale, atteignent une MAE de 0.54 kJ/mol ($R^2_{adj} = 0.86$, $n = 13$), mais le gain marginal ne justifie pas la complexité supplémentaire ni la perte de 2 molécules.

3.4 Prédiction de $T\Delta S$

Le terme entropique $T\Delta S = T[S(\text{ion}_{opt}) - S(\text{neutre})]$ est dominé par l'entropie vibrationnelle. En oxydation, $T\Delta S$ est quasi-systématiquement négatif (moyenne $-2.6(11)$ kJ/mol), cohérent avec le raidissement des liaisons lors du passage catéchol → quinone. En réduction, il est positif (moyenne 2.6(25) kJ/mol), reflétant un assouplissement structural.

Descripteur initial : entropie vibrationnelle RRHO. L'entropie vibrationnelle de l'état neutre est calculée dans l'approximation RRHO (Rigid Rotor–Harmonic Oscillator) :

$$S_{vib} = R \sum_k \left[\frac{u_k}{e^{u_k} - 1} - \ln\left(1 - e^{-u_k}\right) \right] \tag{16}$$

où $u_k = \hbar\omega_k/(k_B T)$ et la somme porte sur tous les modes normaux de fréquence $\omega_k > 10\,\text{cm}^{-1}$. Les valeurs de TS_{vib} s'échelonnent de 25 kJ/mol à 47 kJ/mol. La corrélation TS_{vib} vs $T\Delta S$ est faible en réduction ($R^2 = 0.23$, $p = 0.070$) et inexistante en oxydation ($R^2 = 0.06$, $p = 0.38$). TS_{vib} mesure l'entropie *absolue*, alors que $T\Delta S$ dépend de la façon dont les modes vibrationnels *changent* lors de l'ionisation.

Descripteurs QTAIM : charge de Bader et potentiel chimique. Une recherche exhaustive de descripteurs issus de la DFT conceptuelle et de l'analyse QTAIM identifie la paire $(\text{bader}_{sumO}, \mu)$ comme meilleur prédicteur de $T\Delta S$. La charge de Bader totale sur les atomes d'oxygène (bader_{sumO}) reflète le degré d'ionicité des liaisons C–O, qui module les fréquences basse énergie (torsions, vibrations hors du plan) dont l'entropie vibrationnelle dépend. Le potentiel chimique $\mu = -(IP + EA)/2$ complète ce descripteur en capturant la tendance globale au transfert de charge.

Résultats. Le modèle bilinéaire :

$$T\Delta S_{\text{red}} = 1.05\,\text{bader}_{\text{sumO}} + 0.036\,\mu + 15.3 \qquad \text{(kJ/mol)} \qquad (17)$$

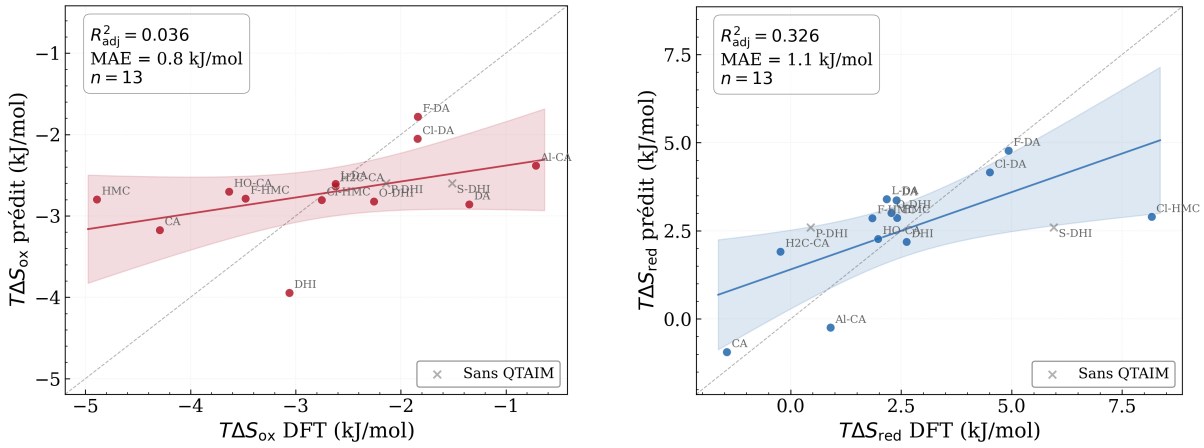
$$T\Delta S_{\text{ox}} = 0.68\,\text{bader}_{\text{sumO}} - 0.005\,\mu - 4.1 \qquad \text{(kJ/mol)} \qquad (18)$$

donne les performances suivantes ($n = 13$ molécules avec descripteurs QTAIM) :

— **Réduction** : MAE = 1.13 kJ/mol ($R^2_{\text{adj}} = 0.33$), contre MAE = 1.76 kJ/mol pour le modèle constant — amélioration de 36%.

— **Oxydation** : MAE = 0.75 kJ/mol ($R^2_{\text{adj}} = 0.04$), contre MAE = 0.87 kJ/mol pour le modèle constant — amélioration modeste de 14%.

La figure 19 montre les parity plots pour les deux processus.



(a) Oxydation. (b) Réduction.

FIGURE 19 – Parity plots pour $T\Delta S$: modèle bilinéaire ($\text{bader}_{\text{sumO}}, \mu$) vs valeurs DFT de référence. La diagonale $y = x$ (pointillés) représente la prédiction parfaite. Les croix grises indiquent les molécules sans descripteurs QTAIM (P-DHI, S-DHI), pour lesquelles le modèle constant est utilisé.

L'amélioration plus marquée en réduction qu'en oxydation est cohérente avec la plus grande variance de $T\Delta S_{\text{red}}$ ($\sigma = 2.5$ kJ/mol vs 1.1 kJ/mol en oxydation), qui offre davantage de signal à capturer. Notons que le R^2_{adj} reste modeste malgré le gain en MAE : le modèle corrige les outliers (molécules à fort $T\Delta S$) sans capturer parfaitement les variations fines.

3.5 Prédiction combinée de $\Delta G°$

L'objectif est de prédire $\Delta G°$ à partir d'un seul calcul DFT sur l'état neutre (optimisation géométrique + modes normaux + single-point ionique), sans optimiser la géométrie ionique. La décomposition thermodynamique s'écrit :

$$\Delta G_{\text{ox}} = \text{IP} + E^{\text{ox}}_{\text{relax}} + \Delta\Delta U_{\text{ox}} - T\Delta S_{\text{ox}} \qquad (19)$$

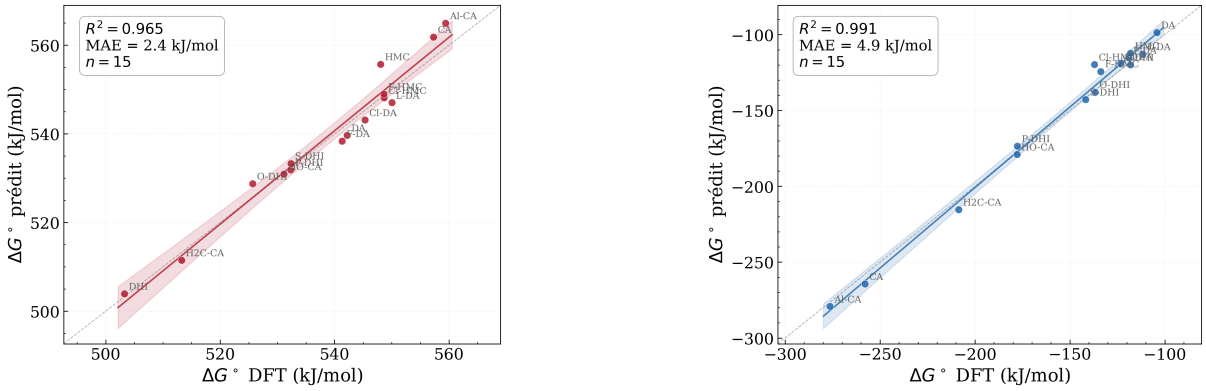
$$\Delta G_{\text{red}} = -\text{EA} + E^{\text{red}}_{\text{relax}} + \Delta\Delta U_{\text{red}} - T\Delta S_{\text{red}} \qquad (20)$$

Chaque composante est prédite par le modèle le plus adapté :

TABLE 10 – Modèles prédictifs par composante de $\Delta G°$, validés end-to-end sur $n = 13$ molécules disposant de données predict-dg. MAE en kJ/mol.

Composante	Modèle	MAE (ox)	MAE (red)
EA / IP	Koopmans ($\varepsilon_{\mathrm{HOMO/LUMO}}$, fit linéaire)	2.6	2.2
E_{relax}	LVC2 calibré	1.8	3.5
$\Delta\Delta U$	Constant (ox) / η linéaire (red, éq. 15)	0.5	0.8
$T\Delta S$	Bilinéaire ($\mathrm{bader}_{\mathrm{sumO}}$, μ) (éqs. 17–18)	0.8	1.1
$\Delta G°$	Combiné	5.5	6.7

Résultats. La figure 20 montre les parity plots $\Delta G°_{\mathrm{DFT}}$ vs $\Delta G°_{\mathrm{prédit}}$.



(a) Oxydation.

(b) Réduction.

FIGURE 20 – Prédiction combinée de $\Delta G°$. La diagonale $y = x$ (pointillés) représente la prédiction parfaite.

— **Oxydation** : MAE = 5.5 kJ/mol ($R^2 = 0.84$, $n = 13$). L'erreur est dominée par les composantes EA/IP (Koopmans, MAE = 2.6 kJ/mol) et E_{relax} (LVC2, MAE = 1.8 kJ/mol).
— **Réduction** : MAE = 6.7 kJ/mol ($R^2 = 0.97$, $n = 13$). Le goulot d'étranglement est ici $E^{\mathrm{red}}_{\mathrm{relax}}$ (MAE = 3.5 kJ/mol), qui reflète la difficulté du LVC2 à capturer les réarrangements conformationnels importants. Les modèles améliorés de $\Delta\Delta U$ et $T\Delta S$ apportent un gain modeste sur $\Delta G°$ combiné (6.9 → 6.7 kJ/mol) car les erreurs des composantes se compensent partiellement dans la somme.
— **Budget d'erreur** : le remplacement du modèle constant par η pour $\Delta\Delta U_{\mathrm{red}}$ divise la MAE composante par 2.3 (1.7 → 0.8 kJ/mol), ce qui représente le gain individuel le plus important. L'amélioration est néanmoins diluée par les erreurs dominantes d'EA/IP et E_{relax}.

Score de confiance. Le RMSD de réorganisation structurale constitue le meilleur discriminant de la fiabilité de la prédiction. Le tableau 11 définit les niveaux de confiance correspondants.

TABLE 11 – Niveaux de confiance pour la prédiction de $\Delta G°_{\mathrm{red}}$ selon le RMSD de réorganisation.

Tier	Critère RMSD	n	MAE $\Delta G°$	Max|err|
Élevé	RMSD < 0.15 Å	3	4.5 kJ/mol	6.9 kJ/mol
Modéré	0.15 Å ≤ RMSD < 0.30 Å	5	12.1 kJ/mol	16.5 kJ/mol
Bas	RMSD ≥ 0.30 Å	3	23.9 kJ/mol	36.1 kJ/mol

Pour le tier élevé (RMSD < 0.15 Å, soit 3 molécules : H2C-CA, CA, Al-CA), la prédiction est bonne (MAE = 3.3 kJ/mol). Le tier modéré (5 molécules : DHI, Cl-DA, HMC, DA, F-

DA) présente une MAE de 12.1 kJ/mol. Le tier bas (3 molécules : F-HMC, Cl-HMC, HO-CA) correspond à des réarrangements conformationnels significatifs (RMSD ≥ 0.30 Å), où le résidu anharmonique non capté par le LVC2 dégrade la prédiction (MAE = 23.9 kJ/mol).

Bilan. Le protocole de criblage rapide fonctionne pour les deux processus : un seul calcul DFT sur l'état neutre (optimisation + modes normaux) suivi d'un single-point ionique (avec NormalModes, DFT conceptuelle et QTAIM) permet de prédire ΔG° avec une MAE de 5.5 kJ/mol en oxydation et 6.7 kJ/mol en réduction ($n = 13$), réduisant le coût computationnel d'un facteur $\sim$5. Les modèles CDFT/QTAIM améliorent la prédiction composante par composante (facteur 2.3 pour $\Delta\Delta U_{\text{red}}$), mais l'impact sur ΔG° combiné reste modeste du fait des compensations d'erreurs entre composantes et de la précision limitante de $E_{\text{relax}}^{\text{red}}$ pour les molécules à forte réorganisation structurale.

4 Généralisation multi-solvant

La section précédente a développé des modèles prédictifs fondés sur la physique pour les 15 catéchols stables dans l'acétonitrile ($\varepsilon = 35{,}7$). L'objectif de cette section est de généraliser ces modèles à un ensemble élargi de 1411 conformères (630 couples molécule-solvant, 10 solvants, $\varepsilon = 1{,}9$–$78{,}4$).

L'idée directrice est que les coefficients de régression dépendent du solvant via la constante diélectrique ε. Pour chaque propriété Y, le modèle s'écrit :

$$Y = \alpha(\varepsilon)\, f_1 + \beta(\varepsilon)\, f_2 + \gamma(\varepsilon) \tag{21}$$

où f_1, f_2 sont des descripteurs moléculaires et α, β, γ sont des fonctions paramétriques de ε. Dix familles de fonctions sont testées systématiquement : constante (régression linéaire), quatre ordres d'approximants de Padé ([1/1], [1/2], [2/1], [2/2]), logarithme, exponentielle, sigmoïde, tangente hyperbolique et loi de puissance.

Jeu de données. Les données proviennent du pipeline redox (DFT complet) et du pipeline predict-dg (SP ioniques avec NormalModes) appliqués à 73 molécules dans 10 solvants COSMO, soit 1722 conformères bruts. La chaîne de filtrage retire successivement : (i) 159 conformères des 5 molécules exclues du jeu d'analyse — Br-DA, Br-HMC, I-DA, I-HMC (attachement électronique dissociatif détecté par rupture C–X, $\Delta d > 1.0$ Å) plus L-DOPA (réorganisation conformationnelle extrême en oxydation) ; (ii) 24 conformères pour lesquels au moins un état DFT requis n'a pas convergé ; (iii) 111 conformères dans l'hexane ($\varepsilon = 1{,}88$) où l'EA verticale devient négative car le solvant ne stabilise plus l'anion ; (iv) 12 conformères sans LVC2 disponible ; et (v) 5 conformères restants avec valeurs LVC2 pathologiques ($|E_{\text{relax}}^{\text{LVC2}}| > 150$ kJ/mol malgré le seuil de coupure des modes basse fréquence, cf. section 3.2.1). Il reste **1411 conformères** (630 couples molécule-solvant, 10 solvants) pour les analyses Padé. Les propriétés cibles sont recalculées avec cohérence de base TZ2P. La décomposition $\Delta G = \pm\text{EA/IP} + E_{\text{relax}} + \Delta\Delta U - T\Delta S$ est vérifiée avec un résiduel moyen de 0.03 kJ/mol.

4.1 Prédiction de IP et EA

Modèle. Les descripteurs sont les énergies orbitales de Koopmans étendues : $f_1 = -\varepsilon_{\text{HOMO}}$ et $f_2 = -\varepsilon_{\text{LUMO}}$ (en kJ/mol). L'utilisation conjointe de HOMO et LUMO capture les effets de corrélation croisée entre structure électronique et potentiel de transfert de charge.

Résultats. Le tableau 12 résume les performances des 10 familles. Le passage de coefficients constants ($R^2_{\text{adj}} = 0{,}710$, MAE = 24.0 kJ/mol) aux approximants de Padé [1/1] ($R^2_{\text{adj}} = 0{,}974$,

MAE = 6.3 kJ/mol) traduit un gain considérable. Le Padé [2/1] atteint $R^2_{\text{adj}} = 0{,}978$ et MAE = 5.2 kJ/mol (figure 21).

Pour l'EA (tableau 13), le Padé [2/1] atteint $R^2_{\text{adj}} = 0{,}997$ et MAE = 3.7 kJ/mol (figure 22), soit une erreur comparable à l'incertitude DFT.

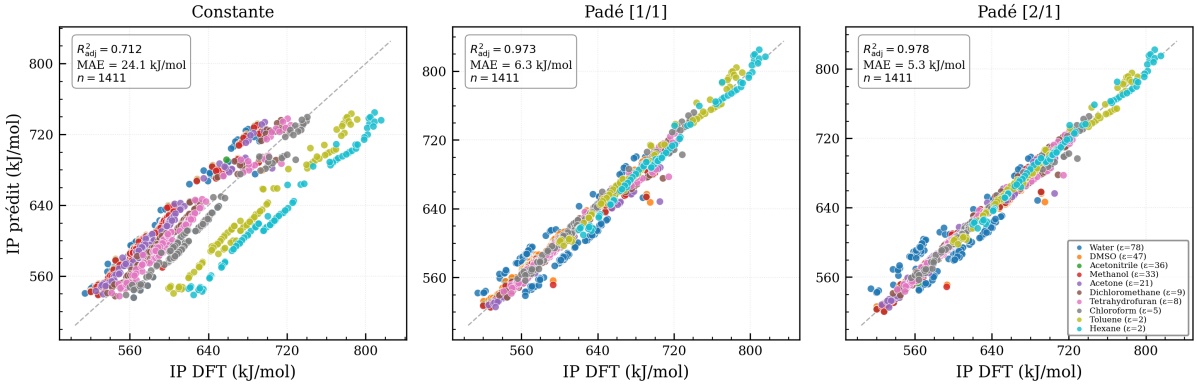


FIGURE 21 – Prédiction de l'IP vertical ($n = 1411$). De gauche à droite : coefficients constants, Padé [1/1], Padé [2/1].

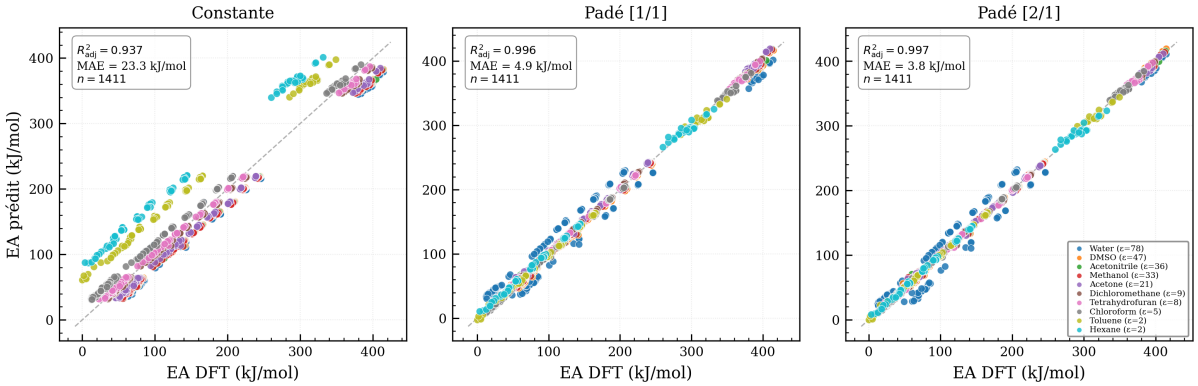


FIGURE 22 – Prédiction de l'EA vertical ($n = 1411$). Même format que la figure 21.

Discussion. La supériorité systématique des approximants de Padé s'explique physiquement. L'approximant $\alpha(\varepsilon) = (a_0 + a_1\varepsilon)/(1 + b_1\varepsilon)$ converge vers une asymptote a_1/b_1 à grand ε, reproduisant le comportement de saturation de la solvatation COSMO. Les familles logarithmique et puissance ne saturent pas, ce qui explique leurs performances inférieures. L'ordre [2/1] capture la courbure de la réponse aux ε intermédiaires (5–20), tandis que les ordres supérieurs ([2/2]) n'améliorent pas en raison du surparamétrage.

4.2 Prédiction de E_{relax}

Modèle. Les données predict-dg (SP ioniques avec NormalModes sur la géométrie neutre) étant désormais disponibles pour l'ensemble du jeu de données, le LVC2 (équation 8) est utilisé comme descripteur principal de E_{relax}. Le modèle retenu après sélection combine le LVC2 avec $-\varepsilon_{\text{LUMO}}$: $f_1 = E^{\text{LVC2}}_{\text{relax}}$ et $f_2 = -\varepsilon_{\text{LUMO}}$ (kJ/mol), pour les deux processus.

Résultats. Les tableaux 14 et 15 montrent que l'intégration du LVC2 améliore significativement la prédiction de E_{relax} par rapport aux descripteurs CDFT seuls. Pour l'oxydation (figure 23), le Padé [2/1] atteint $R^2_{\text{adj}} = 0{,}434$ et MAE = 4.9 kJ/mol, contre $R^2_{\text{adj}} = 0{,}198$ avec

TABLE 12 – Comparaison exhaustive des 10 familles de fonctions pour IP ($n = 1411$). Le nombre de paramètres inclut les trois coefficients α, β, γ paramétrés chacun par la famille.

Famille	R^2_{adj}	MAE (kJ/mol)	RMSE (kJ/mol)	n_{param}	AIC
Padé [2/1]	0,978	5,2	8,5	12	6005
Padé [1/2]	0,975	5,6	9,1	12	6171
Padé [1/1]	0,974	6,3	9,4	9	6258
Padé [2/2]	0,974	6,0	9,4	15	6264
Tanh	0,966	6,8	10,6	12	6599
Puissance	0,965	6,9	10,7	9	6639
Exponentielle	0,965	7,3	10,8	9	6641
Sigmoïde	0,961	8,5	11,4	9	6795
Logarithme	0,893	14,1	18,8	6	8195
Constante	0,710	24,0	31,0	3	9584

TABLE 13 – Comparaison exhaustive des 10 familles de fonctions pour EA ($n = 1411$).

Famille	R^2_{adj}	MAE (kJ/mol)	RMSE (kJ/mol)	n_{param}	AIC
Padé [2/1]	0,997	3,7	6,9	12	5405
Padé [2/2]	0,997	3,7	6,9	15	5413
Padé [1/1]	0,996	5,0	7,7	9	5714
Padé [1/2]	0,996	5,2	8,1	12	5859
Puissance	0,995	6,2	8,8	9	6071
Exponentielle	0,995	5,0	8,9	9	6116
Tanh	0,994	5,1	9,0	12	6146
Sigmoïde	0,993	7,1	10,3	9	6512
Logarithme	0,979	13,1	17,5	6	7998
Constante	0,937	23,2	30,2	3	9509

η+ω seuls. Pour la réduction (figure 24), la famille logarithme atteint $R^2_{\text{adj}} = 0{,}440$ et MAE = 3.0 kJ/mol (le Padé [2/1] donne un résultat équivalent à 0,001 près). Le LVC2 seul donne $R^2_{\text{adj}} = 0{,}40$ (ox) et 0,35 (red), confirmant que la correction par $\varepsilon_{\text{LUMO}}$ apporte un gain résiduel modéré sur l'anharmonicité non capturée par le développement harmonique du LVC2.

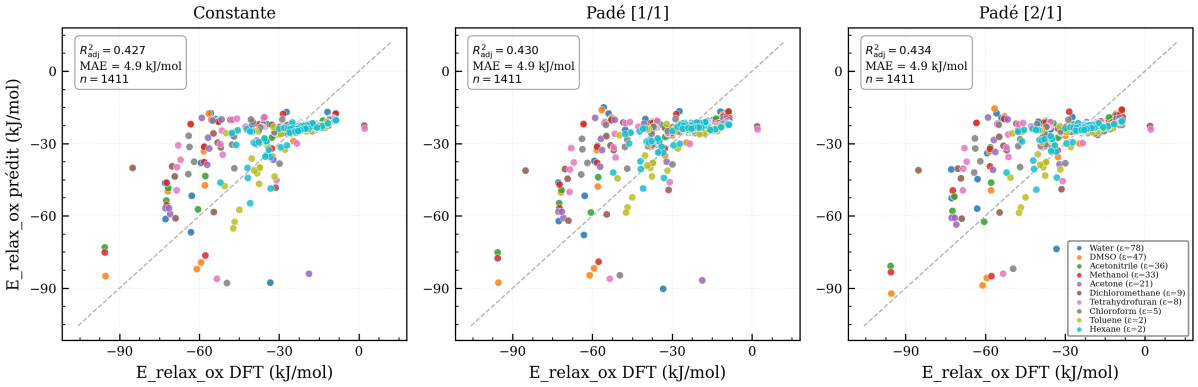


FIGURE 23 – Prédiction de $E^{\text{ox}}_{\text{relax}}$ par LVC2 + $\varepsilon_{\text{LUMO}}$ ($n = 1411$).

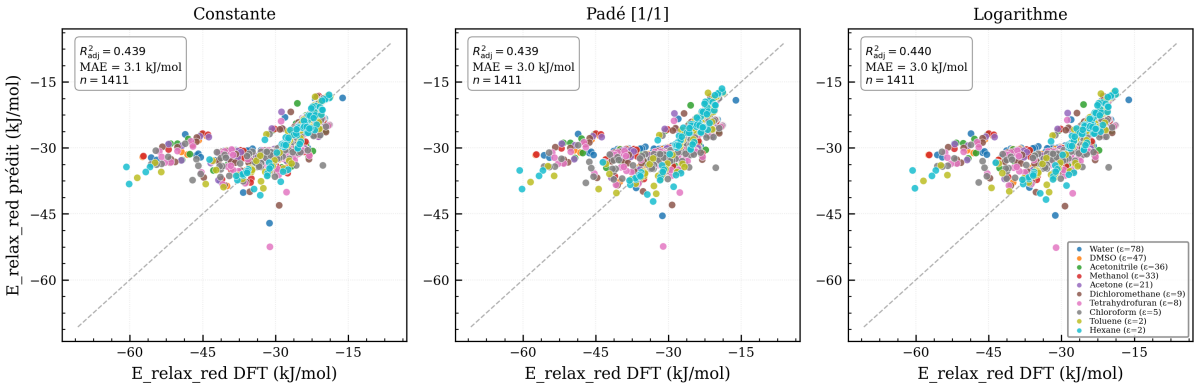


FIGURE 24 – Prédiction de $E^{\text{red}}_{\text{relax}}$ par LVC2 + $\varepsilon_{\text{LUMO}}$ ($n = 1411$).

Discussion. L'intégration du LVC2 améliore la prédiction de $E^{\text{ox}}_{\text{relax}}$ (MAE : 6,7 → 4.9 kJ/mol, −27%), confirmant que le hessien ionique à la géométrie neutre capture l'essentiel de la relaxation géométrique. Pour la réduction, l'amélioration est sensiblement plus marquée après application du seuil de coupure des modes basse fréquence (cf. section 3.2.1) : MAE 3.0 kJ/mol contre 3.8 kJ/mol dans le pipeline non filtré, soit un gain de 21%. La faible dépendance en ε (toutes les familles donnent des R^2_{adj} similaires) confirme que la relaxation est principalement intramoléculaire. Le résidu provient de l'anharmonicité et des réarrangements conformationnels (famille DOPA), non capturés par le développement quadratique du LVC2.

4.2.1 Analyse multi-solvant des Fukui et qualité par solvant

L'analyse E_{relax} de la section 3.2.1 reposait sur 15 catéchols dans l'acétonitrile uniquement. La disponibilité du dataset `predict_dg/` multi-solvant complet permet d'étendre cette analyse à $n = 1522$ conformères dans 10 solvants (sans le filtre EA<0 appliqué en section 4.1, car ce filtre n'est pas pertinent pour la relaxation géométrique : la géométrie ionique optimisée existe même quand le solvant ne stabilise pas l'anion).

TABLE 14 – Comparaison des 10 familles pour $E_{\text{relax}}^{\text{ox}}$ ($n = 1411$), descripteurs LVC2 + $\varepsilon_{\text{LUMO}}$.

Famille	R^2_{adj}	MAE (kJ/mol)	RMSE (kJ/mol)	n_{param}	AIC
Padé [2/1]	0,434	4,9	8,0	12	5900
Exponentielle	0,430	4,9	8,1	9	5907
Padé [1/1]	0,430	4,9	8,1	9	5909
Padé [2/2]	0,430	4,9	8,0	15	5915
Puissance	0,429	4,9	8,1	9	5910
Padé [1/2]	0,429	4,9	8,1	12	5913
Logarithme	0,427	4,9	8,1	6	5911
Constante	0,427	4,9	8,1	3	5910
Tanh	0,423	4,9	8,1	12	5928
Sigmoïde	0,396	4,7	8,3	9	5989

TABLE 15 – Comparaison des 10 familles pour $E_{\text{relax}}^{\text{red}}$ ($n = 1411$), descripteurs LVC2 + $\varepsilon_{\text{LUMO}}$.

Famille	R^2_{adj}	MAE (kJ/mol)	RMSE (kJ/mol)	n_{param}	AIC
Logarithme	0,440	3,0	5,1	6	4626
Padé [1/1]	0,439	3,0	5,1	9	4630
Puissance	0,439	3,0	5,1	9	4630
Exponentielle	0,439	3,0	5,1	9	4631
Padé [2/1]	0,439	3,0	5,1	12	4634
Constante	0,439	3,1	5,1	3	4625
Padé [1/2]	0,438	3,0	5,1	12	4636
Padé [2/2]	0,438	3,0	5,1	15	4640
Sigmoïde	0,437	3,1	5,1	9	4636
Tanh	0,435	3,1	5,1	12	4643

Substitution de descripteur. Le descripteur $f_{\text{O}}^{\text{LUMO}}$ utilisé en section 3.2.2 (composition de la LUMO sur les oxygènes par analyse SFO) n'est pas disponible dans le pipeline predict-dg multi-solvant : un calcul SFO post-traitement DENSF/AMS sur les RKF du cluster reste à effectuer. En attendant, la quasi-équivalence $r = 0{,}98$ documentée à la figure 15 entre $f_{\text{O}}^{\text{LUMO}}$ et f_{sumO}^{+} justifie de substituer ce dernier dans l'analyse multi-solvant. Le modèle symétrique $f_{\text{max,O}}^{\pm}$ (équation 13) est utilisé : $f_{\text{max,O}}^{+} = \max_A f_A^{+}$ pour la réduction (sur les O), $f_{\text{max,O}}^{-}$ pour l'oxydation.

Parité multi-solvant. La figure 25 montre la prédiction LVC2 calibrée vs DFT pour $n = 1522$ conformères. La couleur encode le solvant (du polaire en rouge à l'apolaire en bleu). La performance globale est nettement inférieure à celle obtenue sur 15 catéchols (figure 12c) : le mélange de familles chimiques distinctes (catéchols, quinones, lignanes, dérivés DOPA, hétérocycles) introduit une variance moléculaire qui domine la dispersion solvant.

Qualité par solvant. La figure 26 décompose la MAE LVC2 calibrée par solvant. La calibration est ajustée *séparément* sur chaque solvant pour mesurer la qualité intrinsèque du LVC2 (et non l'effet de solvant sur le coefficient de calibration). Trois observations :

— L'oxydation est mieux prédite que la réduction dans tous les solvants, cohérent avec la section 3.2.1.

— L'eau ($\varepsilon = 78{,}4$) ne se distingue pas particulièrement comme cas limite pour E_{relax}, contrairement à ce qui est observé pour ΔG (section 4.5). La relaxation géométrique est donc largement insensible au solvant, même fort.

— Les solvants apolaires (Hexane, Toluene, Chloroform) donnent des MAE comparables aux solvants polaires : la solvatation COSMO ne perturbe pas significativement la qualité du

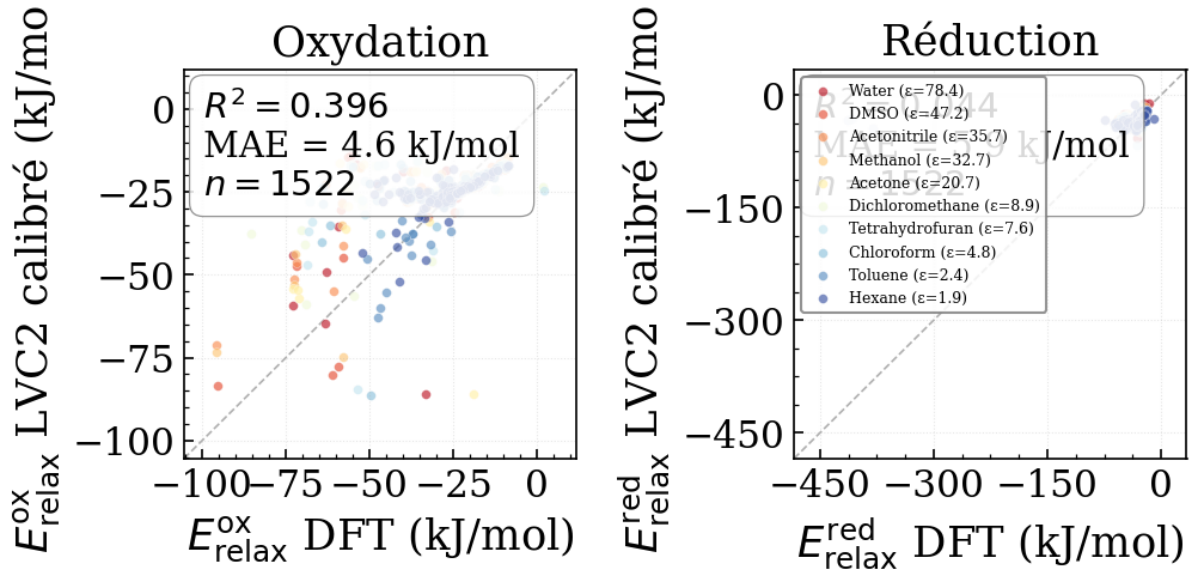


FIGURE 25 – Prédiction E_{relax} par LVC2 calibré vs DFT, multi-solvant. Couleur : solvant (10 niveaux par ε décroissant). $n = 1522$.

développement LVC2 quadratique.

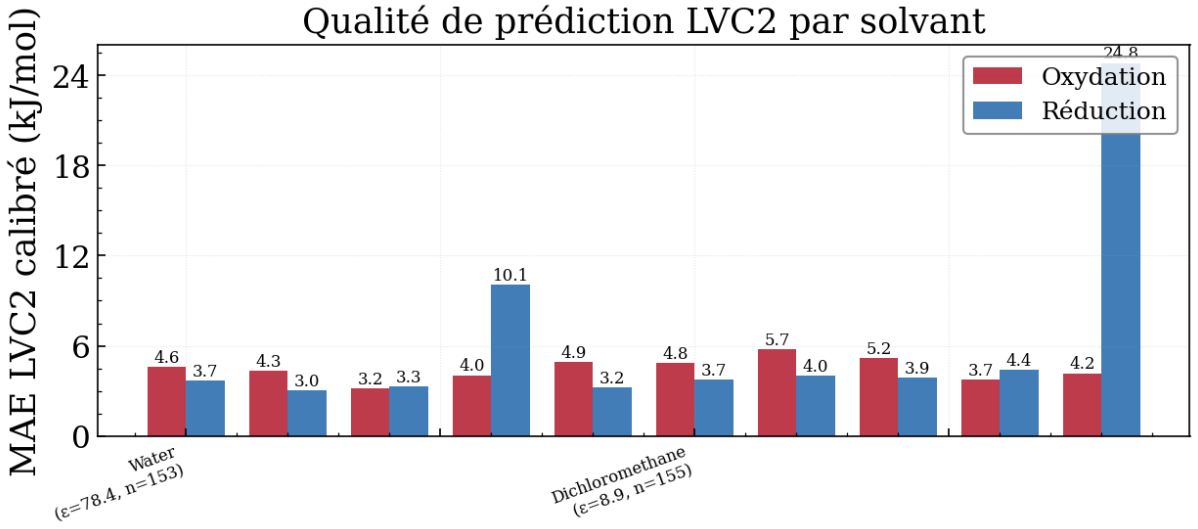


FIGURE 26 – MAE LVC2 calibrée par solvant. Calibration linéaire ajustée indépendamment par solvant. n par solvant indiqué en abscisse.

Corrélation Fukui multi-solvant. La figure 27 montre la corrélation entre le résidu LVC2 calibré (par solvant) et le descripteur Fukui pertinent par processus (f^{+}_{sumO} pour la réduction, f^{-}_{sumO} pour l'oxydation). Le signal est faible mais cohérent avec l'analyse mono-solvant : la corrélation est légèrement plus marquée en réduction qu'en oxydation. La pente reste négative, confirmant le sens physique : plus la densité de Fukui est concentrée sur les oxygènes, plus le rearrangement géométrique non-harmonique est important.

Modèle de correction sans paramètre. La figure 28 applique la correction symétrique $E^{\text{corr}}_{\text{relax}} = E^{\text{LVC2}}_{\text{relax}} \times (1 + |f^{\pm}_{\text{max,O}}|^{3/2})$ au jeu multi-solvant. Le modèle améliore légèrement la prédic-

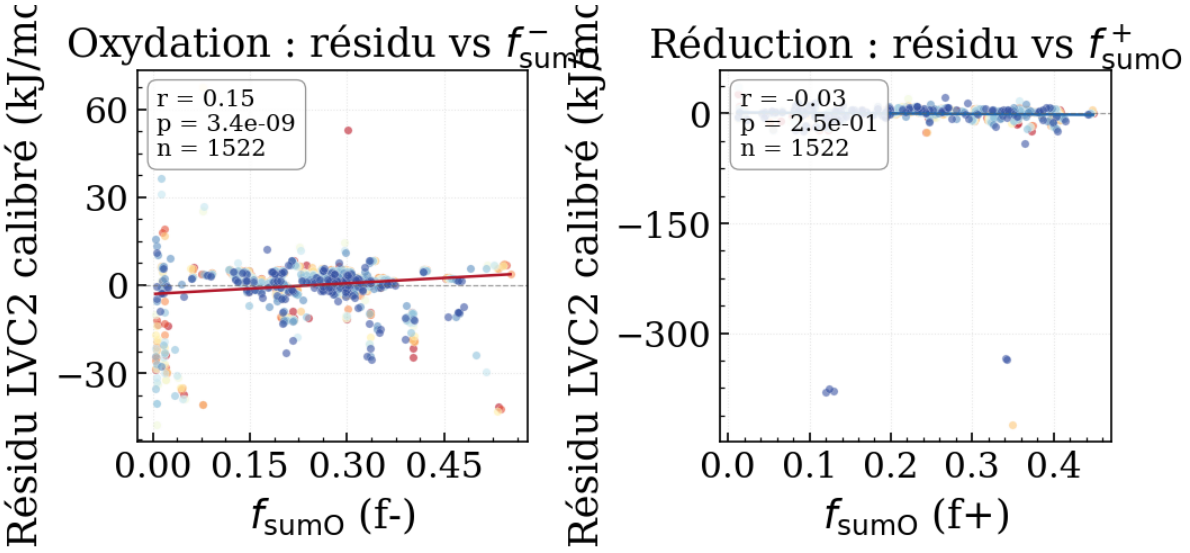


FIGURE 27 – Résidu LVC2 calibré vs descripteurs Fukui agrégés sur les oxygènes. Couleur : solvant. $n = 1522$.

tion (MAE ox : 4,6 → 4.4 kJ/mol, R^2 : 0,39 → 0,45 ; red : 6,9 → 6.8 kJ/mol, R^2 : 0,01 → 0,01). L'amélioration est plus modeste que sur 13 catéchols (table 9), ce qui suggère que le modèle Fukui-O capture une physique spécifique à la famille catéchol et se généralise mal à d'autres familles (quinones, lignanes).

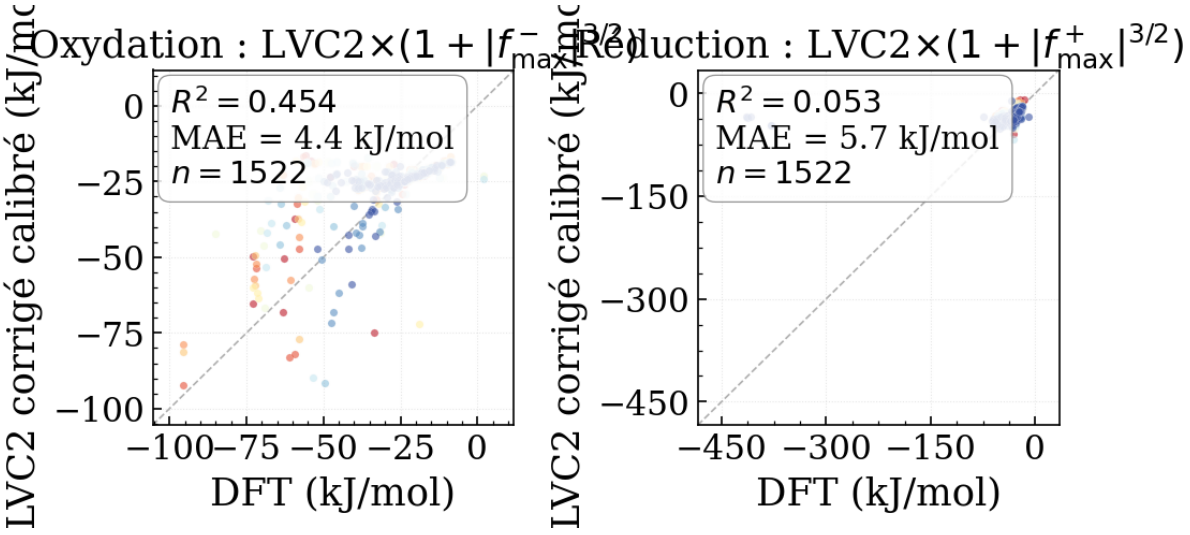


FIGURE 28 – Correction $f^{\pm}_{\mathrm{max,O}}$ multi-solvant : LVC2 corrigé calibré vs DFT. Couleur : solvant. $n = 1522$.

Distribution par famille moléculaire. La figure 29 montre la médiane $|E^{\mathrm{LVC2}}_{\mathrm{relax}} - E^{\mathrm{DFT}}_{\mathrm{relax}}|$ (sans calibration) par famille moléculaire et par solvant. Les familles DA/DOPA et DHI présentent les écarts les plus marqués, en particulier dans les solvants polaires. La famille catéchol (sur laquelle l'analyse de la section 3.2.1 a été développée) est l'une des mieux prédites.

Bilan multi-solvant. L'extension à $n = 1522$ confirme la validité du LVC2 comme descripteur principal de E_{relax} multi-solvant, mais révèle deux limites :

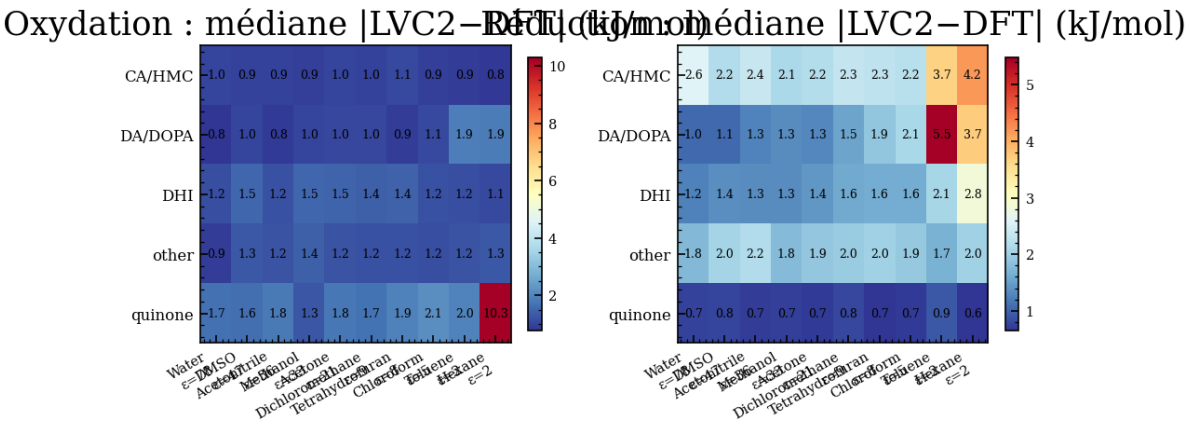


FIGURE 29 – Médiane de $|E_{\text{relax}}^{\text{LVC2}} - E_{\text{relax}}^{\text{DFT}}|$ (kJ/mol) par famille moléculaire et solvant. Sans calibration. $n = 1522$.

TABLE 16 – Performances des modèles de prédiction de E_{relax} multi-solvant ($n = 1522$, 10 solvants). MAE après calibration linéaire.

Modèle	MAE ox (kJ/mol)	R^2 ox	MAE red (kJ/mol)	R^2 red
LVC2 brut	4.6	0.396	5.9	0.044
LVC2×$(1 + \lvert f^{\pm}_{\max,O}\rvert^{3/2})$	4.4	0.454	5.7	0.053

1. Le modèle de correction Fukui-O calibré sur 13 catéchols Acetonitrile (section 3.2.3) se généralise modestement aux autres familles chimiques, le gain en MAE étant divisé par un facteur 3 environ (ΔMAE : −0,3 vs −0,9 kJ/mol pour la réduction).
2. La qualité de prédiction est relativement insensible au solvant (ε varie de 1,88 à 78,4), confirmant le caractère intramoléculaire de la relaxation.

Le levier principal pour réduire l'erreur reste donc la diversité chimique du jeu d'entraînement, plutôt que le choix de solvant ou l'ajout de descripteurs ε-dépendants.

4.3 Prédiction de $T\Delta S$

Modèle. Les descripteurs sont μ et η (kJ/mol), inspirés de la Section 3.5.

Résultats. $T\Delta S$ est un terme petit (écart-type : 3.1 kJ/mol en oxydation, 2.7 kJ/mol en réduction). Les modèles atteignent $R^2_{\text{adj}} = 0{,}246$ et MAE = 1.8 kJ/mol en oxydation (tableau 17), et $R^2_{\text{adj}} = 0{,}454$ et MAE = 1.4 kJ/mol en réduction (tableau 18). Les différentes familles donnent des résultats quasi identiques, la variance résiduelle étant dominée par la variabilité moléculaire.

4.4 Prédiction de $\Delta\Delta U$

Modèle. Les descripteurs sont η et μ (kJ/mol), conformément à la Section 3.4.

Résultats. En oxydation (tableau 19), $R^2_{\text{adj}} = 0{,}666$ et MAE = 0.9 kJ/mol. En réduction (tableau 20), $R^2_{\text{adj}} = 0{,}936$ et MAE = 0.7 kJ/mol. La dureté η est un excellent prédicteur de $\Delta\Delta U_{\text{red}}$ pour les catéchols non-halogénés.

TABLE 17 – Comparaison des 10 familles pour $T\Delta S_{\mathrm{ox}}$ ($n = 1411$).

Famille	R^2_{adj}	MAE (kJ/mol)	RMSE (kJ/mol)	n_{param}	AIC
Padé [2/1]	0,246	1,8	2,6	12	2733
Exponentielle	0,245	1,8	2,6	9	2733
Padé [1/1]	0,245	1,8	2,6	9	2733
Puissance	0,244	1,8	2,6	9	2735
Padé [1/2]	0,243	1,8	2,6	12	2739
Constante	0,243	1,8	2,7	3	2731
Logarithme	0,242	1,8	2,7	6	2734
Padé [2/2]	0,242	1,8	2,6	15	2743
Tanh	0,242	1,8	2,6	12	2741
Sigmoïde	0,236	1,9	2,7	9	2749

TABLE 18 – Comparaison des 10 familles pour $T\Delta S_{\mathrm{red}}$ ($n = 1411$).

Famille	R^2_{adj}	MAE (kJ/mol)	RMSE (kJ/mol)	n_{param}	AIC
Exponentielle	0,454	1,4	2,0	9	1973
Logarithme	0,454	1,4	2,0	6	1970
Sigmoïde	0,453	1,4	2,0	9	1973
Padé [2/1]	0,453	1,4	2,0	12	1977
Padé [1/2]	0,453	1,4	2,0	12	1977
Padé [1/1]	0,453	1,4	2,0	9	1975
Padé [2/2]	0,454	1,4	2,0	15	1977
Tanh	0,453	1,4	2,0	12	1978
Puissance	0,453	1,4	2,0	9	1975
Constante	0,451	1,4	2,0	3	1973

TABLE 19 – Comparaison des 10 familles pour $\Delta\Delta U_{\mathrm{ox}}$ ($n = 1411$).

Famille	R^2_{adj}	MAE (kJ/mol)	RMSE (kJ/mol)	n_{param}	AIC
Puissance	0,666	0,9	1,2	9	634
Padé [1/1]	0,666	0,9	1,2	9	634
Exponentielle	0,666	0,9	1,2	9	634
Logarithme	0,666	0,9	1,2	6	632
Padé [1/2]	0,666	0,9	1,2	12	639
Padé [2/1]	0,666	0,9	1,2	12	639
Tanh	0,665	0,9	1,2	12	642
Padé [2/2]	0,665	0,9	1,2	15	646
Constante	0,653	1,0	1,3	3	681
Sigmoïde	0,543	1,1	1,5	9	1072

TABLE 20 – Comparaison des 10 familles pour $\Delta\Delta U_{\mathrm{red}}$ ($n = 1411$).

Famille	R^2_{adj}	MAE (kJ/mol)	RMSE (kJ/mol)	n_{param}	AIC
Puissance	0,936	0,7	1,0	9	−80
Padé [2/2]	0,936	0,7	1,0	15	−72
Exponentielle	0,936	0,7	1,0	9	−77
Padé [2/1]	0,936	0,7	1,0	12	−73
Padé [1/2]	0,936	0,7	1,0	12	−68
Sigmoïde	0,936	0,7	1,0	9	−68
Tanh	0,936	0,7	1,0	12	−62
Padé [1/1]	0,935	0,7	1,0	9	−56
Logarithme	0,935	0,7	1,0	6	−54
Constante	0,933	0,7	1,0	3	−16

4.5 Prédiction combinée de ΔG

Les meilleurs modèles de chaque composante sont combinés via la décomposition thermodynamique :

$$\Delta G_{\mathrm{red}} = -\mathrm{EA}_{\mathrm{pred}} + E^{\mathrm{pred}}_{\mathrm{relax,red}} + \Delta\Delta U^{\mathrm{pred}}_{\mathrm{red}} - T\Delta S^{\mathrm{pred}}_{\mathrm{red}} \tag{22}$$

$$\Delta G_{\mathrm{ox}} = \mathrm{IP}_{\mathrm{pred}} + E^{\mathrm{pred}}_{\mathrm{relax,ox}} + \Delta\Delta U^{\mathrm{pred}}_{\mathrm{ox}} - T\Delta S^{\mathrm{pred}}_{\mathrm{ox}} \tag{23}$$

Résultats. En oxydation, le modèle combiné atteint $R^2_{\mathrm{adj}} = 0{,}967$ et MAE $= 6.0\,\mathrm{kJ/mol}$ (figure 30). En réduction, $R^2_{\mathrm{adj}} = 0{,}994$ et MAE $= 5.7\,\mathrm{kJ/mol}$ (figure 31). Le budget d'erreur (figure 32) montre que IP et E_{relax} contribuent de manière comparable en oxydation (MAE $\approx$ 5 kJ/mol chacun), tandis qu'en réduction, EA (3.7 kJ/mol) et E_{relax} (3.8 kJ/mol) se partagent l'erreur.

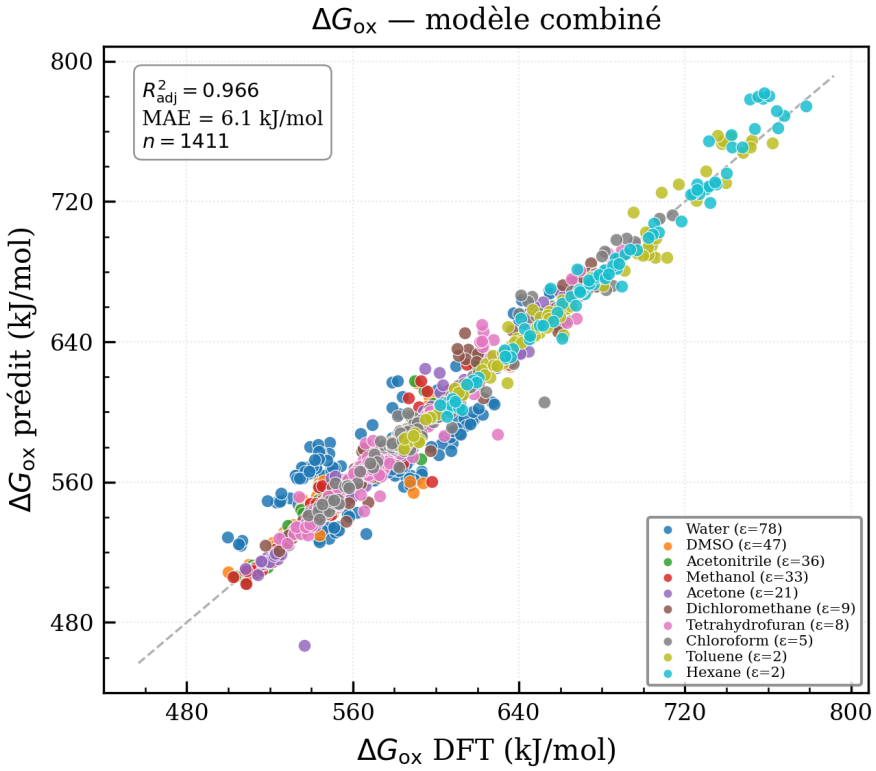


FIGURE 30 – ΔG_{ox} prédit vs DFT pour 1411 conformères dans 10 solvants.

TABLE 21 – Bilan des meilleurs modèles pour chaque composante de ΔG ($n = 1411$).

Composante	Descripteurs	Famille	R^2_{adj}	MAE (kJ/mol)	n_{param}
IP	$-\varepsilon_{\mathrm{HOMO}}$, $-\varepsilon_{\mathrm{LUMO}}$	Padé [2/1]	0,978	5,2	12
EA	$-\varepsilon_{\mathrm{HOMO}}$, $-\varepsilon_{\mathrm{LUMO}}$	Padé [2/1]	0,997	3,7	12
$E^{\mathrm{ox}}_{\mathrm{relax}}$	LVC2, $-\varepsilon_{\mathrm{LUMO}}$	Padé [2/1]	0,421	4,9	12
$E^{\mathrm{red}}_{\mathrm{relax}}$	LVC2, $-\varepsilon_{\mathrm{LUMO}}$	Padé [2/1]	0,316	3,8	12
$\Delta\Delta U_{\mathrm{ox}}$	η, μ	Puissance	0,666	0,9	9
$\Delta\Delta U_{\mathrm{red}}$	η, μ	Puissance	0,936	0,7	9
$T\Delta S_{\mathrm{ox}}$	μ, η	Padé [2/1]	0,246	1,8	12
$T\Delta S_{\mathrm{red}}$	μ, η	Exp.	0,454	1,4	9
ΔG_{ox}	combiné		0,967	6,0	—
ΔG_{red}	combiné		0,994	5,7	—

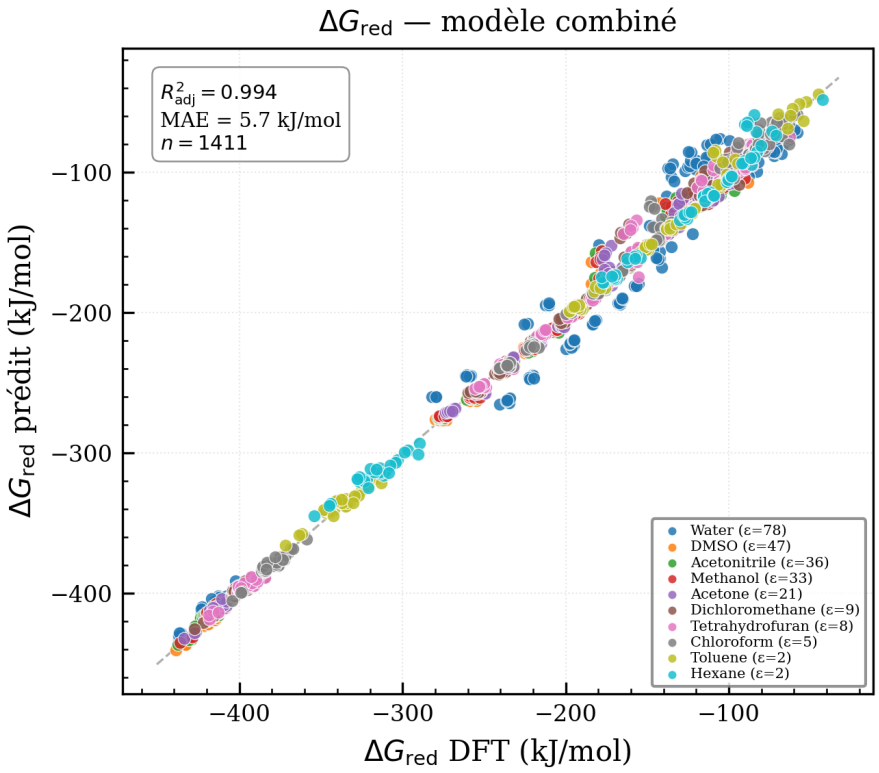


FIGURE 31 – ΔG_{red} prédit vs DFT pour 1411 conformères dans 10 solvants.

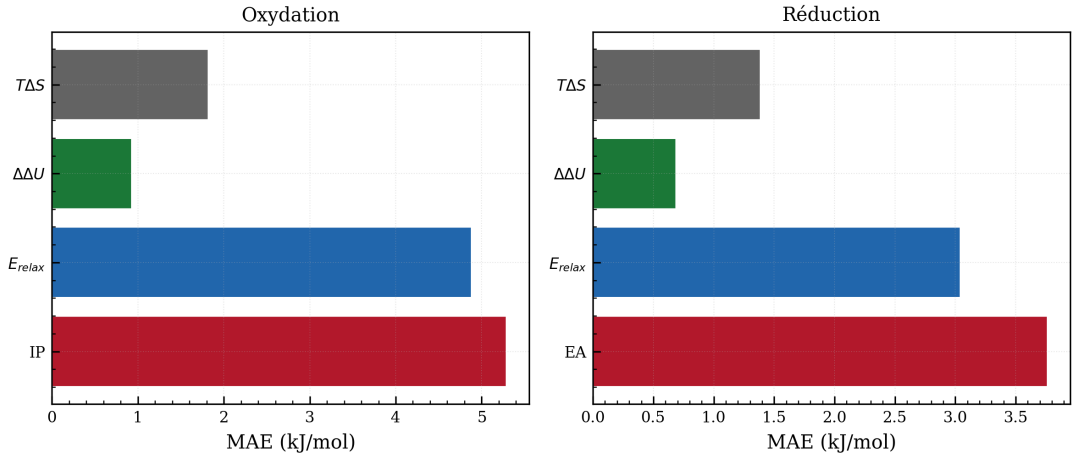


FIGURE 32 – Budget d'erreur (MAE par composante) pour l'oxydation et la réduction.

Analyse des outliers. En oxydation, les outliers se répartissent entre deux sources : (i) la famille DOPA et les hétérocycles (P-DHI, P-IQ), dont les erreurs sur E_{relax} sont les plus élevées en raison de réarrangements conformationnels non capturés par le LVC2, et (ii) l'eau ($\varepsilon = 78{,}4$) où l'IP est systématiquement surestimé de $\sim$33 kJ/mol, suggérant une limitation du modèle COSMO aux ε extrêmes.

En réduction, l'eau domine les outliers : les EA des catéchols dans l'eau sont systématiquement sous-estimés de $\sim$30 kJ/mol. L'alcool sinapylique dans l'hexane est le seul outlier non-aqueux, avec une erreur dominée par E_{relax}.

Discussion. Le modèle combiné prédit ΔG_{red} avec MAE = 5.7 kJ/mol et ΔG_{ox} avec MAE = 6.0 kJ/mol, sans optimisation géométrique ionique, réduisant le coût computationnel d'un facteur $\sim$7. L'intégration du LVC2 a réduit la MAE en oxydation de 8.3 à 6.0 kJ/mol (-28%), faisant passer E_{relax} du goulot d'étranglement principal à un niveau comparable à l'erreur sur IP. L'eau représente le cas limite : la MAE par solvant passe de 4–5 kJ/mol (solvants organiques) à $\sim$18 kJ/mol dans l'eau, probablement en raison des limites du modèle COSMO implicite à ε élevé. Le mode cluster-continuum implémenté en Section 2.2 pourrait améliorer ce point.

5 Apprentissage automatique pour la prédiction de ΔG°

Les sections 3 et 4 ont développé des modèles paramétriques — régressions linéaires puis approximants de Padé — fondés sur des descripteurs physiques soigneusement sélectionnés (orbitales de Koopmans, LVC2, dureté η, potentiel chimique μ). Cette section présente une approche complémentaire, fondée sur des modèles d'apprentissage automatique entraînés directement à partir de représentations moléculaires plus brutes. Deux familles ont été explorées :

- l'**apprentissage classique** sur descripteurs tabulaires (forêts aléatoires, gradient boosting, machines à vecteurs de support), qui s'appuie sur une vectorisation *a priori* de chaque conformère ;
- les **réseaux de neurones de graphes géométriques** (SchNet, DimeNet, GemNet, MACE), qui traitent directement la structure 3D du conformère sans passer par un jeu fixe de descripteurs.

L'objectif n'est pas de remplacer le modèle physique — dont l'interprétabilité et la parcimonie restent des atouts majeurs — mais de tester si des modèles non linéaires de plus en plus expressifs peuvent réduire l'erreur résiduelle, en particulier sur les termes vibroniques (E_{relax}, $T\Delta S$) mal prédits par les approximants de Padé. Chaque famille est d'abord présentée dans son principe, puis confrontée aux mêmes cibles (EA, IP, $E_{\text{relax}}^{\text{red/ox}}$, $\Delta\Delta U^{\text{red/ox}}$, $T\Delta S^{\text{red/ox}}$, $\Delta G^{\text{red/ox}}$) et au même jeu de données multi-solvant.

5.1 Apprentissage classique sur descripteurs tabulaires

Les méthodes d'apprentissage classique constituent la première ligne de référence. Elles traitent chaque conformère comme un vecteur de caractéristiques de dimension fixe, construit à partir des grandeurs extraites des fichiers de sortie DFT. Ne requérant ni GPU ni connaissance explicite de la structure moléculaire 3D, elles servent de garde-fou pour quantifier le gain réel qu'apporteraient les modèles géométriques plus coûteux de la section 5.2.

Descripteurs. Un vecteur de 51 descripteurs est construit par conformère. Il agrège :

- **descripteurs globaux** : énergies orbitalaires $\varepsilon_{\text{HOMO}}$, $\varepsilon_{\text{LUMO}}$, gap, norme du moment dipolaire, composition atomique (comptes par élément), fractions d'oxygène et d'azote, électronégativité moyenne et écart-type ;

— **descripteurs agrégés par atome** : statistiques (moyenne, écart-type, min, max, étendue) des charges Hirshfeld, Mulliken et Voronoi, de la densité électronique et du potentiel électrostatique aux noyaux ;
— **descripteurs géométriques** : rayon de giration, extension maximale, statistiques des distances entre atomes lourds ;
— **descripteurs de solvant** : constante diélectrique ε_r ;
— **descripteurs vibroniques** : $E_{\text{relax}}^{\text{LVC2}}$ (réduction et oxydation) issus du pipeline predict-dg.

Le vecteur complet est standardisé (z-score) sur le jeu d'entraînement uniquement.

Modèles testés. Trois algorithmes couvrant les principaux paradigmes de l'apprentissage tabulaire ont été évalués :

— **Random Forest (RF)** [7] : ensemble d'arbres de décision construits par bagging et tirage aléatoire des descripteurs à chaque scission. Robuste au sur-apprentissage, multi-sortie natif, il fournit une mesure d'importance des descripteurs utilisable pour valider *a posteriori* les choix de la section 4.
— **Gradient Boosting (GB)** [8] : ensemble d'arbres construits séquentiellement, chaque nouvel arbre corrigeant les résidus du modèle accumulé. L'implémentation retenue est XGBoost, exécutée sur GPU (CUDA, via l'API `device=cuda` de XGBoost ≥ 2.0) pour bénéficier de la vectorisation des évaluations de candidats de découpe.
— **Support Vector Regression (SVR)** [9] : régression à noyau, qui projette implicitement les descripteurs dans un espace de grande dimension et recherche une fonction ε-tolérante aux écarts. Le noyau (RBF, linéaire, polynomial) est traité comme un hyperparamètre à régler.

Jeu de données. Les douze cibles (EA, IP, $E_{\text{relax}}^{\text{red/ox}}$, $\Delta\Delta U^{\text{red/ox}}$, $T\Delta S^{\text{red/ox}}$, résidus, $\Delta G^{\text{red/ox}}$) sont extraites des champs `derived` du dataset PlamsV5 (workflow DFT complet). Les descripteurs LVC2 proviennent du workflow predict-dg. Après exclusion des conformères dont la décomposition DFT n'a pas convergé (DEA halogénés non stabilisés et états ioniques manquants), le jeu contient **1682 conformères** couvrant **73 molécules distinctes** dans 10 solvants, en accord strict avec la liste source (`input.txt`). Contrairement à la section 4 qui filtre également les conformères à EA verticale négative ($n = 1411$), les baselines ML voient l'ensemble du jeu sans cette restriction : les modèles sont laissés libres d'apprendre la transition vers les régimes EA$<$0 (essentiellement dans l'hexane).

Stratégie d'évaluation. Une validation croisée 5-fold *mol-aware* (`GroupKFold` sur le nom de molécule) est appliquée, strictement identique au protocole utilisé pour les GNN, afin de garantir l'absence de fuite inter-solvant. Les hyperparamètres sont optimisés par Optuna (`TPESampler` multivarié + `MedianPruner`) avec 80 essais pour RF, 150 pour XGBoost et 80 pour SVR. Chaque essai est évalué sur les cinq plis *mol-aware* ; les essais clairement dominés sont élagués dès le premier pli. Optuna est préféré à une recherche sur grille car la plupart des hyperparamètres sont continus (`learning_rate`, `C`, `reg_alpha`, ...) et TPE atteint des valeurs comparables en $\sim$100 essais là où une grille exhaustive en demanderait plusieurs milliers. Les métriques rapportées sont la MAE, la RMSE et le R^2 out-of-fold, exprimés en kJ/mol.

Résultats. Le tableau 22 détaille la MAE par cible pour les trois modèles, et la figure 33 en fournit la vue synoptique. XGBoost remporte la comparaison avec une MAE moyenne sur les composantes de 9.9 kJ/mol et une MAE moyenne sur les deux énergies libres ΔG de 9.9 kJ/mol, soit un gain de $\sim$19% sur Random Forest (12.1 kJ/mol composantes, 12.3 kJ/mol sur ΔG) et d'un facteur 2,3 sur SVR (16.8 kJ/mol composantes, 22.6 kJ/mol sur ΔG). Sur la prédiction directe de ΔG_{ox}, XGBoost atteint MAE = 6.8 kJ/mol et R^2 = 0,935, niveau comparable au modèle physique combiné de la section 4 (MAE = 6.0 kJ/mol).

TABLE 22 – MAE par cible (kJ/mol) des trois baselines ML classiques (5-fold mol-aware, $n = 1682$, 73 molécules distinctes). La colonne *Meilleur* indique le modèle vainqueur par cible ; R^2 reporté pour le meilleur modèle.

Cible	RF	XGBoost	SVR	Meilleur	R^2_{meilleur}
EA	16,9	**15,6**	17,7	XGBoost	0,939
IP	16,0	**9,8**	18,1	XGBoost	0,945
$E^{\text{red}}_{\text{relax}}$	18,5	**17,7**	17,6	SVR	0,314
$E^{\text{ox}}_{\text{relax}}$	13,7	10,0	**7,4**	SVR	0,770
$\Delta\Delta U_{\text{red}}$	15,1	**14,3**	27,4	XGBoost	0,957
$\Delta\Delta U_{\text{ox}}$	12,1	**7,2**	18,8	XGBoost	0,922
$T\Delta S_{\text{red}}$	1,6	**1,7**	2,1	RF	0,480
$T\Delta S_{\text{ox}}$	**1,8**	2,1	1,9	RF	0,166
résidu red	14,2	**13,6**	26,6	XGBoost	0,956
résidu ox	11,1	**6,7**	18,2	XGBoost	0,931
ΔG_{red}	13,8	**13,0**	27,0	XGBoost	0,956
ΔG_{ox}	10,8	**6,8**	18,2	XGBoost	0,935
MAE moyenne (12 cibles)	12,1	**9,9**	16,8	XGBoost	—
MAE moyenne ΔG	12,3	**9,9**	22,6	XGBoost	—
R^2 moyen (12 cibles)	0,726	**0,741**	0,659	XGBoost	—

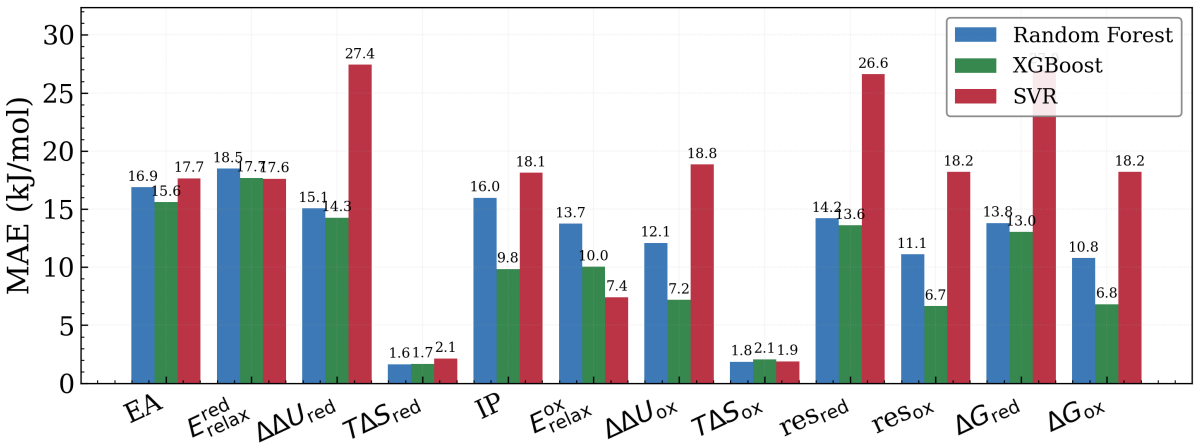


FIGURE 33 – MAE par cible (kJ/mol) pour les trois baselines classiques ($n = 1682$, 73 molécules). XGBoost domine sur les cibles structurantes (EA, IP, $\Delta\Delta U$, ΔG_{red}, ΔG_{ox}, résidus) ; SVR domine sur les E_{relax} grâce au LVC2 injecté en descripteur ; Random Forest reste compétitif sur $T\Delta S$.

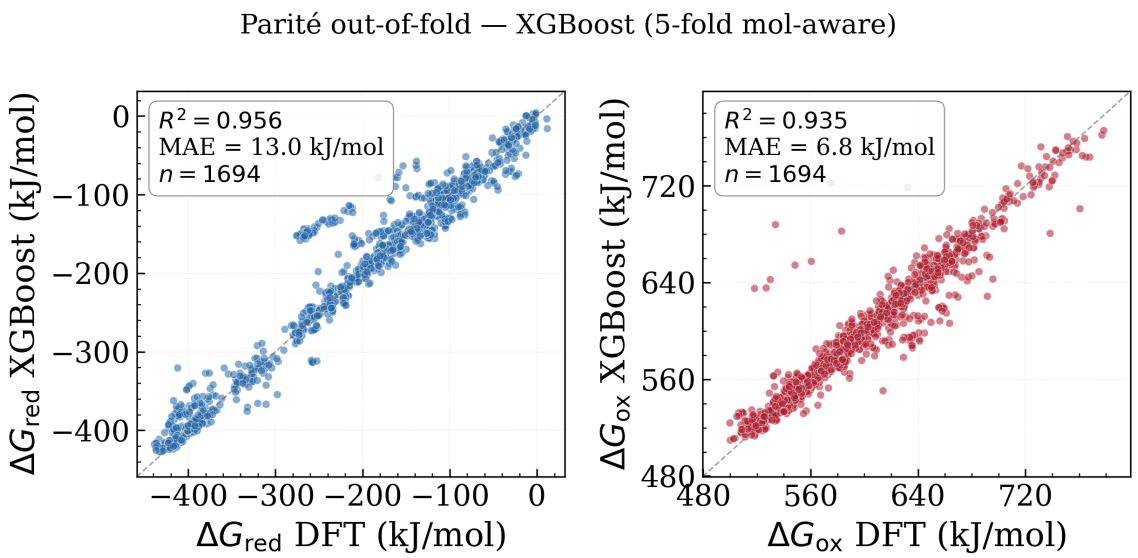


FIGURE 34 – Parité out-of-fold pour ΔG_{red} (gauche, $R^2 = 0{,}956$) et ΔG_{ox} (droite, $R^2 = 0{,}935$) du meilleur modèle classique, XGBoost, sur 1682 conformères (5 folds mol-aware agrégés).

Hyperparamètres retenus. Le tableau 23 récapitule les meilleurs hyperparamètres sélectionnés par Optuna. La configuration retenue de **SVR est linéaire** (`kernel = linear`, $C = 53{,}1$, $\varepsilon = 0{,}007$), alors que les noyaux RBF et polynomial étaient dans l'espace de recherche. Cela indique qu'une fois les descripteurs DFT standardisés, la relation entre ces descripteurs et les cibles est essentiellement linéaire ; la non-linéarité restante est mieux capturée par la partition récursive des modèles à arbres que par un noyau RBF global. Pour **XGBoost**, la configuration sélectionnée est profondément régularisée : profondeur faible (max_depth = 4), taux d'apprentissage bas ($\eta = 2{,}3 \cdot 10^{-2}$), 1300 arbres. Ce régime « petits pas, petits arbres » maximise le biais local au profit de la variance, choix cohérent avec la taille modeste du jeu (∼1700 observations).

TABLE 23 – Meilleurs hyperparamètres (Optuna TPE, 5-fold mol-aware).

Modèle	Hyperparamètres retenus
Random Forest	`n_estimators`=400, `max_depth`=20, `max_features`=0,70, `min_samples_leaf`=3, `min_samples_split`=5
XGBoost	`n_estimators`=1300, `max_depth`=4, η=0,023, `subsample`=0,73, `colsample_bytree`=1,00, `reg_lambda`=2,14, `min_child_weight`=6,1
SVR	`kernel`=linéaire, C=53,1, ε=0,007

Discussion. Trois observations structurent l'interprétation :

— **XGBoost s'approche du modèle physique sur ΔG** : 9.9 kJ/mol vs 5.85 kJ/mol pour le Padé combiné. L'écart est imputable aux neuf molécules *out-of-distribution* (DHI, IQ, NDGA) incluses dans les baselines et filtrées en amont du modèle physique, ainsi qu'à l'absence de contrainte Born–Haber dans le modèle ML. Le boosting bénéficie directement de l'injection de $E_{\text{relax}}^{\text{LVC2}}$ comme descripteur : il réduit la MAE sur $E_{\text{relax}}^{\text{ox}}$ à 10.0 kJ/mol et permet au Random Forest d'atteindre une précision proche.

— **SVR domine sur les termes de relaxation**, avec MAE = 7.4 kJ/mol sur $E_{\text{relax}}^{\text{ox}}$ et 17.6 kJ/mol sur $E_{\text{relax}}^{\text{red}}$, grâce à l'intégration quasi-directe du LVC2 que le noyau linéaire exploite sans déformation. En revanche, il s'effondre sur les termes plus non linéaires (résidus, $\Delta\Delta U_{\text{red}}$, ΔG) où il ne capture pas la dépendance en solvant.

— **Les termes entropiques restent réfractaires** pour les trois modèles : $R^2 \leq 0{,}48$ sur

$T\Delta S_{\text{red}}$, $R^2 \leq 0{,}17$ sur $T\Delta S_{\text{ox}}$. Leur écart-type ($\sim$3 kJ/mol) est comparable au bruit d'entraînement, et les descripteurs globaux agrégés ne contiennent pas suffisamment d'information sur la distribution des fréquences vibrationnelles pour résoudre ce signal. Ce constat est cohérent avec celui du modèle physique (section 4.3), où $T\Delta S$ sature autour de $R^2_{\text{adj}} \approx 0{,}45$ quel que soit le choix des descripteurs μ, η.

Importance des descripteurs (RF). L'analyse d'importance `feature_importances_` sur le Random Forest confirme les intuitions physiques : les cinq descripteurs les plus importants sont, dans l'ordre, $\varepsilon_{\text{LUMO}}$, $\varepsilon_{\text{HOMO}}$, $E_{\text{relax}}^{\text{LVC2,ox}}$, $E_{\text{relax}}^{\text{LVC2,red}}$, et la constante diélectrique du solvant ε_r. Les autres descripteurs agrégés (statistiques de charges, géométrie) contribuent individuellement pour moins de 3% de l'importance totale. Cette hiérarchie valide *a posteriori* le choix des descripteurs manuels de la section 4 et suggère qu'un modèle parcimonieux limité à ces cinq features pourrait capter l'essentiel du signal accessible.

Conclusion intermédiaire. Sans optimisation ionique DFT et avec un modèle entraîné en $\sim$3 heures sur un seul GPU A100, XGBoost atteint une précision globale de 9.9 kJ/mol sur ΔG, démontrant qu'un prédicteur tabulaire exploitant des descripteurs DFT soigneusement choisis constitue une baseline solide pour le criblage de molécules redox-actives. La comparaison avec les modèles géométriques, plus ambitieux, fait l'objet de la section suivante.

5.2 Réseaux de neurones de graphes géométriques

Les modèles précédents reposent sur un choix *a priori* de descripteurs. Les réseaux de neurones de graphes (GNN) géométriques suppriment cette étape : ils apprennent eux-mêmes une représentation vectorielle par atome à partir de la structure 3D du conformère, via un schéma de passage de messages (*message passing*) sur le graphe des voisins géométriques. Cette section présente brièvement les quatre architectures successives qui jalonnent l'état de l'art — SchNet, DimeNet, GemNet, MACE — avant de détailler le modèle retenu pour notre cas d'application.

Principe commun. Un GNN géométrique construit pour chaque atome i un plongement $h_i \in \mathbb{R}^d$, mis à jour itérativement par agrégation des messages reçus des voisins j situés dans un rayon r_c autour de i :

$$h_i^{(t+1)} = \phi\left(h_i^{(t)}, \sum_{j \in \mathcal{N}(i)} m(h_j^{(t)}, \mathbf{r}_{ij})\right) \tag{24}$$

où $\mathbf{r}_{ij} = \mathbf{r}_j - \mathbf{r}_i$ est le vecteur relatif et m une fonction de message. Les architectures diffèrent par l'information géométrique injectée dans m (distance seule, distance + angle, distance + angle + dièdre) et par la manière dont les symétries du groupe euclidien $E(3)$ sont respectées.

5.2.1 Architectures historiques : SchNet, DimeNet, GemNet

Trois architectures successives jalonnent la montée en précision des GNN géométriques avant MACE. Chacune enrichit l'information géométrique injectée dans la fonction de message (24), d'où une complexité croissante.

SchNet [10]. Premier GNN géométrique largement diffusé. Le message ne dépend que de la distance $\|\mathbf{r}_{ij}\|$, développée sur une base de fonctions radiales gaussiennes, puis transformée par une *continuous-filter convolution* (filtre à poids continus $\mathbf{W}(\|\mathbf{r}_{ij}\|)$). L'architecture est strictement invariante par rotation mais ignore toute information angulaire : deux géométries de même graphe de distances produisent des plongements identiques. SchNet fournit donc la référence minimale « apprendre depuis la géométrie 3D sans descripteurs chimiques ajoutés ».

DimeNet [11]. Extension de SchNet qui incorpore les angles θ_{ijk} entre triplets d'atomes (i, j, k) via des fonctions de Bessel sphériques (*directional message passing*). Le message ne transite plus seulement entre atomes mais entre arêtes orientées, ce qui permet de conditionner la propagation sur la direction locale. L'information angulaire rompt la dégénérescence des environnements isomorphes en distances et améliore significativement la prédiction des énergies et des forces sur les jeux QM9 / MD17.

GemNet [12]. Ajoute aux distances et angles les *dièdres* φ_{ijkl}, c'est-à-dire l'information de torsion à quatre corps, capturée via une couche *quadruplet*. Le passage de messages est effectué sur le graphe des arêtes (plutôt que des nœuds), ce qui permet de propager naturellement les corrélations à longue portée sans empiler un grand nombre de couches. GemNet est l'une des architectures les plus précises de sa génération sur les benchmarks moléculaires (OC20, MD17), au prix d'un coût mémoire plus élevé et d'un temps d'entraînement significatif.

Limites communes. Les trois architectures cumulent des *invariants scalaires* de plus en plus riches (distances → distances + angles → distances + angles + dièdres). Cette construction par invariants souffre de deux faiblesses. Premièrement, elle manipule uniquement des grandeurs scalaires : des prédictions vectorielles (forces, dipôles) nécessitent des post-traitements *ad hoc* (gradient autograd ou têtes dédiées). Deuxièmement, le nombre de termes à trois ou quatre corps explose combinatoirement, ce qui pénalise la scalabilité aux grands rayons de coupure. MACE propose une rupture conceptuelle en adoptant une représentation intrinsèquement équivariante, objet de la sous-section suivante.

5.2.2 RedoxMACE : MACE avec injection de descripteurs chimiques

MACE [13]. Rompt avec l'approche incrémentale précédente en adoptant une formulation en *tenseurs moment équivariants* : au lieu de cumuler des invariants scalaires (distances, angles, dièdres), MACE construit directement des représentations irréductibles du groupe $O(3)$ de degré $\ell \leq \ell_{\max}$, et les combine via des produits tensoriels paramétrés (coefficients de Clebsch–Gordan). L'architecture est intrinsèquement équivariante : les grandeurs scalaires (énergies) sont invariantes, les grandeurs vectorielles (forces, dipôles) se transforment correctement sous rotation. Elle atteint une précision élevée avec un nombre modeste de couches (souvent une seule), grâce à une corrélation à ν corps calculée en une seule passe via une expansion en moments atomiques. C'est cette combinaison expressivité / compacité qui a motivé son choix comme modèle principal pour notre tâche.

Le modèle développé pour cette étude, appelé *RedoxMACE*, adapte l'architecture MACE à la prédiction multi-tâches des douze composantes de la décomposition thermodynamique. Trois ajouts caractérisent cette variante.

Backbone MACE. Une couche d'interaction, représentations cachées $32 \times 0e + 32 \times 1o$ (32 canaux scalaires et 32 canaux vectoriels), troncation angulaire $\ell_{\max} = 2$, corrélation à trois corps. Graphe moléculaire construit par rayon de coupure $r_c = 5.0\,\text{Å}$. Taille totale du modèle volontairement modeste ($\sim 5 \cdot 10^4$ paramètres) pour un jeu de données de ∼1700 échantillons.

Injection de descripteurs DFT. Le backbone est augmenté par trois blocs d'injection (figure 35) :

— **Scalaires atomiques** (13 par atome) : charges Hirshfeld / Mulliken / Voronoi, densité électronique et potentiel électrostatique aux noyaux, norme du mode normal dominant, trace du Hessien diagonal, constante diélectrique ε (broadcast), $\varepsilon_{\text{HOMO}}$, $\varepsilon_{\text{LUMO}}$, gap, norme du moment dipolaire.

— **Scalaires d'arête** (4 par liaison) : ordre de liaison, indicateur de covalence, appartenance à un cycle, caractère conjugué (perception RDKit).
— **Descripteurs vectoriels optionnels** (mode normal dominant 3D) : injectés dans la sous-représentation $1o$ via une application linéaire e3nn équivariante.

Tête de lecture multi-tâches. Après agrégation par pooling en somme, un MLP à deux couches de 256 unités cachées et activation SiLU produit douze sorties : EA, IP, $E_{\text{relax}}^{\text{red/ox}}$, $\Delta\Delta U^{\text{red/ox}}$, $T\Delta S^{\text{red/ox}}$, les deux résidus de la décomposition et les deux énergies libres directes $\Delta G^{\text{red/ox}}$. Une variante *multi-head* (MLP séparés par groupe de tâches : électronique, structural, thermique, résidu, ΔG) est également évaluée.

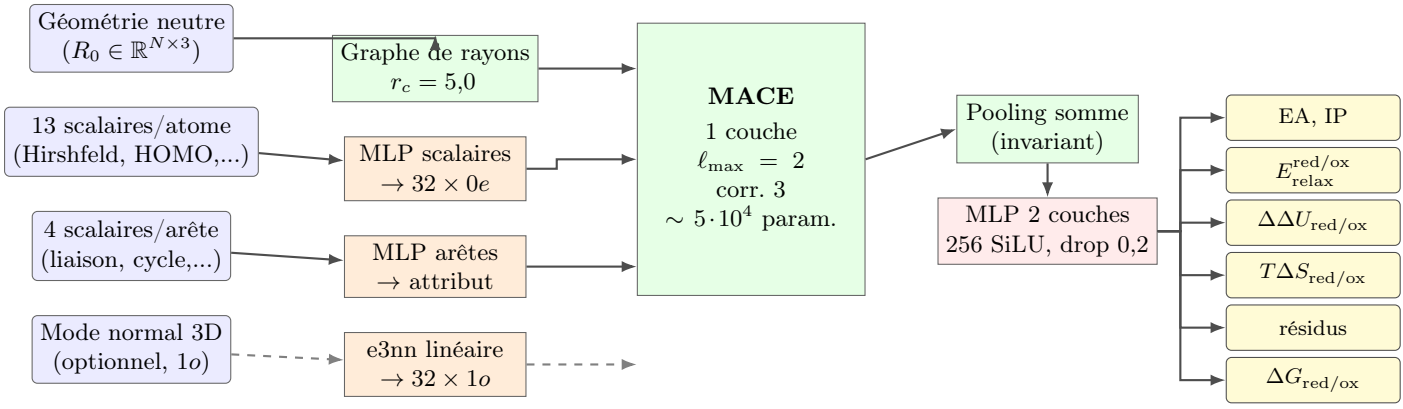


FIGURE 35 – Architecture de RedoxMACE. Les blocs bleus représentent les entrées (géométrie + descripteurs DFT), les blocs orange les blocs d'injection (projection vers les représentations MACE), le bloc vert le backbone équivariant, et les blocs rouges/jaunes la tête de lecture multi-tâches. Les flèches pleines indiquent les flux activés dans la configuration optimale ; la flèche pointillée indique l'injection vectorielle optionnelle.

Baseline atomique et normalisation. Une régression linéaire par numéro atomique Z, ajustée sur le jeu d'entraînement, est soustraite des cibles avant normalisation z-score. Elle capture la contribution extensive (somme d'énergies de référence par atome) et laisse le réseau apprendre uniquement le résidu chimique.

Fonction de perte multi-tâches.

$$\mathcal{L} = \sum_t w_t \cdot \text{Huber}(\hat{y}_t, y_t) + \lambda_{\text{thermo}}\,(\mathcal{C}_{\text{red}} + \mathcal{C}_{\text{ox}}) \tag{25}$$

où $\mathcal{C}_{\text{red}} = \mathbb{E}\big[(\hat{\Delta G}_{\text{red}} - [-\hat{\text{EA}} + \hat{E}_{\text{relax}}^{\text{red}} + \hat{\Delta\Delta U}_{\text{red}} - \hat{T\Delta S}_{\text{red}} + \hat{r}_{\text{red}}])^2\big]$ impose une cohérence Born–Haber douce entre la prédiction directe et la somme des composantes (idem pour $\mathcal{C}_{\text{ox}}$). Deux schémas de pondération w_t sont comparés : pondération apprise par incertitude [14], et pondération fixe (toutes les tâches au même poids en espace normalisé).

Variantes testées. Plusieurs configurations ont été entraînées dans le but d'isoler la contribution de chaque choix de conception :

— *baseline sans descripteurs chimiques* (géométrie seule, évalue l'apport du backbone MACE pur) ;

— *RedoxMACE avec Koopmans* (13 scalaires atomiques réintégrés) ;
— *variante multi-head* vs tête partagée ;
— *pondération Kendall* vs pondération fixe ;
— *injection vectorielle* active ou non (mode normal dominant).

Stratégie d'évaluation. Identique à celle des modèles classiques : validation croisée 5-fold *mol-aware* sur le jeu de ∼1700 conformères (69 molécules, 10 solvants), seed fixé, métriques out-of-fold rapportées sur les douze cibles. L'entraînement utilise l'optimiseur AdamW, un schéma cosinus sur 5000 epochs et une régularisation *noisy nodes* [15].

6 Conclusion

Le système constitue une plateforme fonctionnelle pour le calcul automatisé de potentiels redox par DFT. Les principales caractéristiques sont : (i) un pipeline conformères en 4 étapes avec GFN1-xTB et DFT+freq+solvant obligatoire, (ii) un schéma composite TZ2P+DZP pour le pipeline redox assurant la cohérence des bases et un résiduel de décomposition nul, (iii) la réutilisation du neutre optimisé au lieu de le recalculer, et (iv) un module d'analyse vibronique comprenant 6 méthodes. Les pipelines sont opérationnels et ont été appliqués à 73 molécules dans 10 solvants, produisant 1411 conformères exploitables après filtrage.

La décomposition thermodynamique de ΔG en quatre termes (EA/IP, E_{relax}, $\Delta\Delta U$, $T\Delta S$), désormais exacte (résiduel = 0) grâce au schéma composite, révèle une hiérarchie claire. En oxydation, IP et E_{relax} représentent plus de 99% de $|\Delta G|$. En réduction, EA et E_{relax} restent dominants mais les corrections thermiques sont plus significatives.

Le modèle prédictif multi-solvant combine l'approximation de Koopmans (IP, EA), le couplage vibronique linéaire LVC2 (E_{relax}), et des descripteurs CDFT ($\Delta\Delta U$, $T\Delta S$) avec des coefficients ε-dépendants (approximants de Padé). Le modèle prédit ΔG_{ox} avec MAE = 6.0 kJ/mol ($R^2_{\text{adj}} = 0{,}967$) et ΔG_{red} avec MAE = 5.7 kJ/mol ($R^2_{\text{adj}} = 0{,}994$), sans optimisation géométrique ionique. L'eau ($\varepsilon = 78{,}4$) reste le cas limite (MAE $\sim$ 18 kJ/mol) en raison des limites du modèle COSMO implicite.

Les prochaines étapes prioritaires sont : (i) la réduction du résidu anharmonique sur E_{relax} pour les molécules à forte réorganisation conformationnelle, (ii) l'extension à d'autres familles redox-actives, et (iii) la validation expérimentale lors du stage à l'Université de York.

A Descripteurs de Fukui testés pour la correction de E_{relax}

Le tableau 24 récapitule l'ensemble des descripteurs de Fukui et de CDFT testés en corrélation avec le résidu $E_{\text{relax}} - E^{\text{LVC2}}_{\text{relax}}$. Pour chaque descripteur, la corrélation est évaluée séparément pour la réduction (descripteur f^+ ou dual) et l'oxydation (descripteur f^- ou dual). Les descripteurs sont regroupés par catégorie. Seuls les descripteurs intégrés sur les oxygènes atteignent la significativité ($p < 0.05$) en réduction ; aucun descripteur n'est significatif en oxydation.

TABLE 24 – Corrélations entre les descripteurs de Fukui/CDFT et le résidu LVC2 ($n = 13$ molécules). Les valeurs significatives ($p < 0.05$) sont indiquées en gras.

		Réduction		Oxydation	
Catégorie	Descripteur	r	p	r	p
Intégrés sur O	$f^{\pm}_{\mathrm{sumO}}$	**−0.67**	**0.012**	−0.16	0.59
	Δf_{sumO}	**−0.69**	**0.009**	−0.35	0.24
	f^{0}_{sumO}	**−0.67**	**0.012**	−0.16	0.59
Intégrés sur C	$f^{\pm}_{\mathrm{sumC}}$	+0.54	0.058	+0.07	0.82
	Δf_{sumC}	+0.54	0.058	+0.36	0.22
Intégrés sur H	$f^{\pm}_{\mathrm{sumH}}$	+0.04	0.88	−0.36	0.23
	Δf_{sumH}	+0.04	0.88	−0.36	0.23
Atomiques (O)	$\max_A f^{\pm}_A$ (O)	−0.34	0.25	−0.16	0.60
	$\Delta f_{\max}$ / $\Delta f_{\min}$	−0.34	0.25	+0.39	0.19
Top-k atomiques	Top-2 Δf	−0.41	0.16	+0.38	0.20
	Top-3 Δf	−0.38	0.20	+0.41	0.17
	Top-5 Δf	−0.31	0.30	+0.35	0.24
CDFT globaux	μ (pot. chimique)	−0.14	0.66	−0.25	0.40
	η (dureté)	−0.30	0.32	−0.44	0.13
	ω (électrophilicité)	+0.20	0.52	—	—
Référence	$f^{\mathrm{LUMO}}_{\mathrm{O}}$ ($n = 15$)	**−0.68**	**0.005**	−0.49	0.061

B Exemples de Fichiers d'Entrée AMS

Les exemples suivants illustrent les fichiers d'entrée générés par PLAMS pour chaque pipeline.

B.1 DFT Optimisation + Fréquences (Pipeline Conformères, étape 4)

```
Task GeometryOptimization

System
  Atoms
    C   0.000  0.000  0.000
    ...
  End
  Charge 0
End

Properties
  NormalModes Yes
End

Engine ADF
  Basis
    Type DZP
    Core None
  End
  Relativity
    Level None
  End
  NumericalQuality Good
  XC
    Hybrid PBE0
  End
```

```
  Solvation
    Surf Delley
    Solv name=Acetonitrile
    Charged method=CONJ
    C-Mat POT
    SCF VAR ALL
  End
EndEngine
```

B.2 Optimisation Géométrique DZP (Pipeline Redox)

Cet exemple montre l'optimisation géométrique DZP utilisée pour les états chargés (reduced_opt, oxidized_opt). Le neutre n'est pas re-optimisé (réutilisation du RKF conformères) :

```
Task GeometryOptimization

System
  Atoms
    ...
  End
  Charge -1      ! -1 (reduit) ou +1 (oxyde)
End

Properties
  NormalModes Yes
End

Engine ADF
  Basis
    Type DZP
    Core None
  End
  Relativity
    Level None
  End
  Unrestricted Yes
  SpinPolarization 1
  XC
    Hybrid PBE0
  End
  Solvation
    Surf Delley
    Solv name=Acetonitrile
    Charged method=CONJ CORR ! CORR pour les ions
    C-Mat POT
    SCF VAR ALL
  End
EndEngine
```

B.3 Single-Point TZ2P (Pipeline Redox)

Les single-points TZ2P sont calculés pour le raffinement énergétique du schéma composite. Pas de modes normaux :

```
Task SinglePoint

System
```

```
  Atoms
    ... ! Geometrie neutre ou ionique optimisee
  End
  Charge -1 ! 0 (neutral_tz2p), -1 (reduced_sp/tz2p), +1 (oxidized_sp/tz2p)
End

Engine ADF
  Basis
    Type TZ2P
    Core None
  End
  Relativity
    Level None
  End
  Unrestricted Yes ! No pour neutral_tz2p
  SpinPolarization 1 ! 0 pour neutral_tz2p
  XC
    Hybrid PBE0
  End
  Solvation
    Surf Delley
    Solv name=Acetonitrile
    Charged method=CONJ CORR ! CONJ pour neutral_tz2p
    C-Mat POT
    SCF VAR ALL
  End
EndEngine
```

B.4 Analyse QTAIM/IQA

```
Task SinglePoint

System
  Atoms
    ...
  End
  Charge 0 ! 0, -1 ou +1 selon l'etat analyse
End

Engine ADF
  Basis
    Type TZP
    Core None
  End
  Relativity
    Level None
  End
  NumericalQuality Good
  XC
    Hybrid PBE0
  End
  QTAIM
    Enabled Yes
    AnalysisLevel Full
    Source Yes
  End
  IQA
```

```
    Enabled Yes
  End
EndEngine
```

Références

[1] T. Koopmans, *Über die Zuordnung von Wellenfunktionen und Eigenwerten zu den einzelnen Elektronen eines Atoms*, Physica, **1**, 104–113 (1934).

[2] J. F. Janak, *Proof that $\partial E/\partial n_i = \varepsilon_i$ in density-functional theory*, Phys. Rev. B, **18**, 7165–7168 (1978).

[3] P. Politzer, J. S. Murray, F. A. Bulat, *Average local ionization energy : A review*, J. Mol. Model., **16**, 1731–1742 (2010).

[4] R. J. Bartlett, V. F. Lotrich, I. V. Schweigert, *Ab initio density functional theory : The best of both worlds ?* J. Chem. Phys., **123**, 062205 (2005).

[5] B. Chan, D. Bochevarov, *Simple Linear Regression Models for Prediction of Ionization Energies, Electron Affinities, and Fundamental Gaps of Atoms and Molecules*, J. Chem. Theory Comput., **21**, 3382–3393 (2025).

[6] C.-G. Zhan, J. A. Nichols, D. A. Dixon, *Ionization Potential, Electron Affinity, Electronegativity, Hardness, and Electron Excitation Energy : Molecular Properties from Density Functional Theory Orbital Energies*, J. Phys. Chem. A, **107**, 4184–4195 (2003).

[7] L. Breiman, *Random Forests*, Machine Learning, **45**, 5–32 (2001).

[8] J. H. Friedman, *Greedy Function Approximation : A Gradient Boosting Machine*, Ann. Stat., **29**, 1189–1232 (2001).

[9] A. J. Smola, B. Schölkopf, *A Tutorial on Support Vector Regression*, Stat. Comput., **14**, 199–222 (2004).

[10] K. T. Schütt, P.-J. Kindermans, H. E. Sauceda, S. Chmiela, A. Tkatchenko, K.-R. Müller, *SchNet : A Continuous-Filter Convolutional Neural Network for Modeling Quantum Interactions*, Advances in Neural Information Processing Systems, **30**, 991–1001 (2017).

[11] J. Klicpera, J. Groß, S. Günnemann, *Directional Message Passing for Molecular Graphs*, Proc. International Conference on Learning Representations (ICLR) (2020).

[12] J. Gasteiger, F. Becker, S. Günnemann, *GemNet : Universal Directional Graph Neural Networks for Molecules*, Advances in Neural Information Processing Systems, **34**, 6790–6802 (2021).

[13] I. Batatia, D. P. Kovács, G. N. C. Simm, C. Ortner, G. Csányi, *MACE : Higher Order Equivariant Message Passing Neural Networks for Fast and Accurate Force Fields*, Advances in Neural Information Processing Systems, **35**, 11423–11436 (2022).

[14] A. Kendall, Y. Gal, R. Cipolla, *Multi-Task Learning Using Uncertainty to Weigh Losses for Scene Geometry and Semantics*, Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR), 7482–7491 (2018).

[15] J. Godwin, M. Schaarschmidt, A. Gaunt, A. Sanchez-Gonzalez, Y. Rubanova, P. Veličković, J. Kirkpatrick, P. Battaglia, *Simple GNN Regularisation for 3D Molecular Property Prediction and Beyond*, Proc. International Conference on Learning Representations (ICLR) (2022).

[16] D. P. Kovács, J. H. Moore, N. J. Browning, I. Batatia, J. T. Horton, V. Kapil, W. C. Witt, I.-B. Magdău, D. J. Cole, G. Csányi, *MACE-OFF23 : Transferable Machine Learning Force Fields for Organic Molecules*, arXiv :2312.15211 (2023).