Rapport d'avancement : Développement d'un Workflow Automatisé pour la Prédiction des Propriétés Redox de Molécules Organiques par DFT

Lucas Delavoye
Master XL-Chem V (2024/2026)
Laboratoire CARMeN (UMR CNRS 6064)

Mars 2026

1 Introduction

Le déploiement à grande échelle de la technologie Li-ion pour le stockage d'énergie soulève aujourd'hui des préoccupations convergentes sur trois plans. Sur le plan environnemental, l'extraction du lithium et du cobalt entraîne une empreinte hydrique et minière importante, et le recyclage en fin de vie reste partiel. Sur le plan social, les conditions d'extraction du cobalt, dont la production est concentrée principalement en République Démocratique du Congo, font régulièrement l'objet d'alertes documentées. Sur le plan stratégique enfin, la concentration géographique des réserves de lithium en Amérique du Sud et de la chaîne de raffinage et d'assemblage des cellules en Asie crée une dépendance lourde de l'ensemble des pays consommateurs envers un nombre restreint de fournisseurs, contraignant structurellement le développement du stockage électrochimique à l'échelle mondiale.

Les matériaux redox-actifs organiques constituent une voie alternative à fort potentiel pour les électrodes des batteries de prochaine génération. Construits à partir d'éléments abondants (C, H, N, O, S) et accessibles depuis des précurseurs biosourcés tels que les algues, le bois, les plantes ou les huiles végétales, ils peuvent être produits localement à partir de ressources cultivables sur l'ensemble du globe et recyclés en fin de vie. Leur structure permet en outre d'ajuster les propriétés électrochimiques par fonctionnalisation, ouvrant un espace de conception adapté aux exigences applicatives. Parmi les motifs candidats pour la matière active d'électrode positive, le couple catéchol/quinone occupe une place particulière : un transfert biélectronique entre deux formes redox stables, un espace chimique vaste accessible par substitution du cycle aromatique, et une capacité documentée à stocker de la charge via l'interconversion réversible carbonyle/hydroxyle. Le défi consiste alors à identifier, dans cet espace combinatoire, les substituants conduisant à un potentiel redox, une solubilité et une stabilité compatibles avec les contraintes d'application.

Le travail présenté dans ce rapport, mené sur près d'un an et demi, s'inscrit dans une collaboration entre le laboratoire CARMeN (UMR CNRS 6064, Université de Rouen Normandie), où le criblage computationnel a été développé, et le Green Chemistry Centre of Excellence de l'Université d'York, qui prendra en charge la synthèse ciblée des candidats les plus prometteurs. La finalité du pipeline développé au CARMeN est ainsi de fournir une liste restreinte de molécules dont les propriétés calculées justifient le coût expérimental de la synthèse et de la caractérisation.

La DFT prédit quantitativement les propriétés redox des molécules organiques, mais son application au criblage de masse se heurte à un coût prohibitif : pour chaque candidat, l'évaluation de l'énergie libre de Gibbs de transfert électronique exige une optimisation géométrique de l'état ionique (réduit ou oxydé) suivie d'une analyse vibrationnelle, dont le coût dépasse largement celui des calculs effectués sur le seul état neutre. La conduite d'un tel criblage suppose d'abord

un environnement de calcul automatisé : le système de workflows que nous avons développé, construit sur l'Amsterdam Modeling Suite (AMS) et la bibliothèque PLAMS, orchestre la génération de conformères, les optimisations DFT successives et les analyses sur l'ensemble du protocole, garantissant la reproductibilité et permettant le passage à l'échelle. Sur cette base, nous explorons deux voies pour réduire effectivement le coût des prédictions : des modèles prédictifs physiquement motivés, construits sur des descripteurs calculables depuis le seul état neutre, et une approche par apprentissage automatique sur descripteurs tabulaires et géométriques, qui sert de référence comparative pour situer la performance des modèles physiques.

La construction de tels modèles substitutifs repose sur une décomposition thermodynamique du potentiel redox en contributions distinctes : affinité électronique (EA) ou potentiel d'ionisation (IP) verticaux, énergie de relaxation géométrique (E_{relax}), contribution thermique interne ($\Delta\Delta U$) et terme entropique ($T\Delta S$). Cette décomposition est formalisée comme suit :

$$\Delta G_{\text{red}} = -\text{EA} + E^{\text{red}}_{\text{relax}} + \Delta\Delta U - T\Delta S \qquad (1)$$

$$\Delta G_{\text{ox}} = \text{IP} + E^{\text{ox}}_{\text{relax}} + \Delta\Delta U - T\Delta S \qquad (2)$$

Dans ces équations, EA et IP désignent l'affinité électronique et le potentiel d'ionisation verticaux, définis positifs par convention :

$$\text{EA} = E^{\text{neutre}} - E^{\text{réduit,sp}}, \qquad \text{IP} = E^{\text{oxydé,sp}} - E^{\text{neutre}},$$

où $E^{\text{ion,sp}}$ représente l'énergie de l'état ionique (réduit ou oxydé) évaluée à la géométrie d'équilibre du neutre (calcul *single point*, sans réoptimisation). EA et IP mesurent ainsi le coût énergétique d'un transfert électronique à géométrie figée. L'énergie de relaxation, indicée par l'état ionique correspondant,

$$E^{\text{ion}}_{\text{relax}} = E^{\text{ion,opt}} - E^{\text{ion,sp}} \qquad (\text{ion} \in \{\text{red, ox}\})$$

est alors la stabilisation associée à la réoptimisation géométrique de l'état ionique vers son propre minimum. Enfin, $\Delta\Delta U$ regroupe les corrections d'énergie interne (énergie de point zéro et énergie thermique) entre formes neutre et ionique, tandis que $T\Delta S$ est la contribution entropique à l'énergie libre de Gibbs.

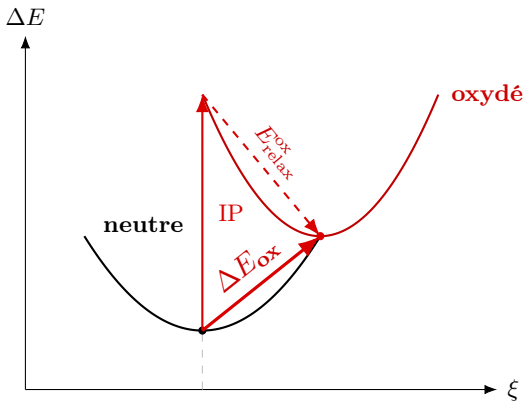


FIGURE 1 – Décomposition du transfert électronique pour l'oxydation, le long d'une coordonnée généralisée ξ. À la géométrie d'équilibre du neutre, IP est le coût énergétique d'un transfert vertical d'un électron vers l'état oxydé ; $E^{\text{ox}}_{\text{relax}}$ est la stabilisation associée à la réoptimisation géométrique de cet état. Le schéma équivalent pour la réduction s'obtient en remplaçant chaque terme « ox » par son analogue « red » (état oxydé par état réduit, IP par $-$EA, et $E^{\text{ox}}_{\text{relax}}$ par $E^{\text{red}}_{\text{relax}}$).

Cette décomposition isole les contributions dominantes au potentiel redox et identifie E_{relax}, $\Delta\Delta U$ et $T\Delta S$ comme cibles privilégiées des modèles substitutifs : si chacun de ces termes peut être estimé à partir de propriétés de l'état neutre, les optimisations géométriques des états ioniques deviennent superflues pour le criblage. Nous développons ces modèles sur une base de données de catéchols et de quinones substitués calculés en acétonitrile, avant d'en éprouver la transférabilité sur neuf autres solvants couvrant deux ordres de grandeur de polarité. Les parties qui suivent retracent cette construction, terme par terme, dans l'ordre où nous l'avons menée.

2 Description du Workflow

2.1 Vue d'ensemble

Le programme prend en entrée le code SMILES d'une molécule et produit en sortie la décomposition thermodynamique de son potentiel redox (équations 1 et 2), accompagnée des descripteurs nécessaires aux modèles prédictifs développés dans la suite de ce rapport. L'enchaînement

est organisé en deux pipelines de calculs successifs (figure 2), suivis d'un module d'analyse. L'ensemble repose sur l'Amsterdam Modeling Suite (AMS 2025) et est orchestré par la bibliothèque PLAMS, qui pilote le moteur ADF via une API Python permettant la composition modulaire des étapes et la propagation des fichiers RKF entre calculs.

Un choix de conception, que nous avons retenu dès l'origine, structure l'ensemble du workflow : *l'état neutre est le pivot*. Sa géométrie d'équilibre, son fichier de résultats RKF et les poids de Boltzmann calculés à son niveau sont produits une seule fois par le pipeline conformères, puis réutilisés sans recalcul par le pipeline redox (qui ne re-optimise pas le neutre) et par le module d'analyse (qui prédit la décomposition de ΔG depuis les seules propriétés du neutre). Ce choix nous évite la duplication des calculs les plus coûteux et garantit la cohérence des géométries de référence entre tous les calculs en aval.

L'ensemble du code, des scripts SLURM et de la documentation technique est disponible à l'adresse `https://github.com/LucasDelav/PLAMS`.

2.2 Pipeline conformères

Le pipeline conformères transforme un code SMILES en un petit ensemble de conformères stables, validés au niveau DFT et prêts à être propagés au pipeline redox. Il est structuré en entonnoir sur quatre étapes, chacune éliminant les structures qui ne valent pas le coût de l'étape suivante :

1. **Génération** : 1000 conformères initiaux sont produits par RDKit avec la méthode de *distance geometry* ETKDG, puis pré-optimisés avec le champ de force UFF intégré au moteur `ConformersJob` d'AMS. Cette étape échantillonne largement l'espace conformationnel des molécules flexibles à un coût négligeable.
2. **Optimisation semi-empirique** : les 1000 conformères sont réoptimisés en GFN1-xTB, méthode *tight-binding* qui capture les effets électroniques essentiels (liaisons hydrogène, conjugaison, encombrement stérique) tout en restant plusieurs ordres de grandeur plus rapide qu'une optimisation DFT. Cette étape resserre les groupes de conformères dupliqués et fournit un premier classement énergétique réaliste.
3. **Filtre Boltzmann (xTB)** : les conformères dont le poids de Boltzmann à 298.15 K reste inférieur à $w = 0.05$ sont écartés. Le seuil est volontairement lâche : on élimine ici uniquement les structures statistiquement marginales, qui ne contribueraient pas aux moyennes pondérées sur les propriétés observables, sans risquer d'écarter un conformère qui remonterait après réordonnancement DFT.
4. **DFT (opt + freq + solvant)** : les conformères survivants sont optimisés au niveau PBE0/DZP avec analyse vibrationnelle complète et solvatation implicite COSMO. Un second filtre de Boltzmann, cette fois à $w \geq 0.10$ sur les énergies libres de Gibbs G_{DFT}, élimine les conformères dont le rang a chuté avec le changement de niveau de théorie. L'analyse vibrationnelle vérifie également que chaque conformère retenu est un vrai minimum de la surface d'énergie potentielle (absence de fréquences imaginaires).

À la sortie de ce pipeline, deux à trois conformères par molécule sont conservés en pratique. Le chemin absolu de leur fichier RKF (résultat de l'étape 4) est inscrit dans `neutral_rkf_paths.json`, qui joue le rôle de pont vers le pipeline redox : ce dernier lit ce fichier pour récupérer les géométries neutres et leurs grandeurs thermodynamiques sans avoir à les recalculer.

2.3 Pipeline redox

Le pipeline redox prend en entrée les conformères validés du pipeline conformères et produit, pour chacun, les énergies nécessaires au calcul de ΔG_{red} et ΔG_{ox}. Deux choix de conception le distinguent d'un protocole naïf consistant à optimiser chaque état (neutre, réduit, oxydé) en bloc et au même niveau de théorie : la réutilisation du calcul neutre déjà effectué, et un schéma d'énergie composite à deux bases.

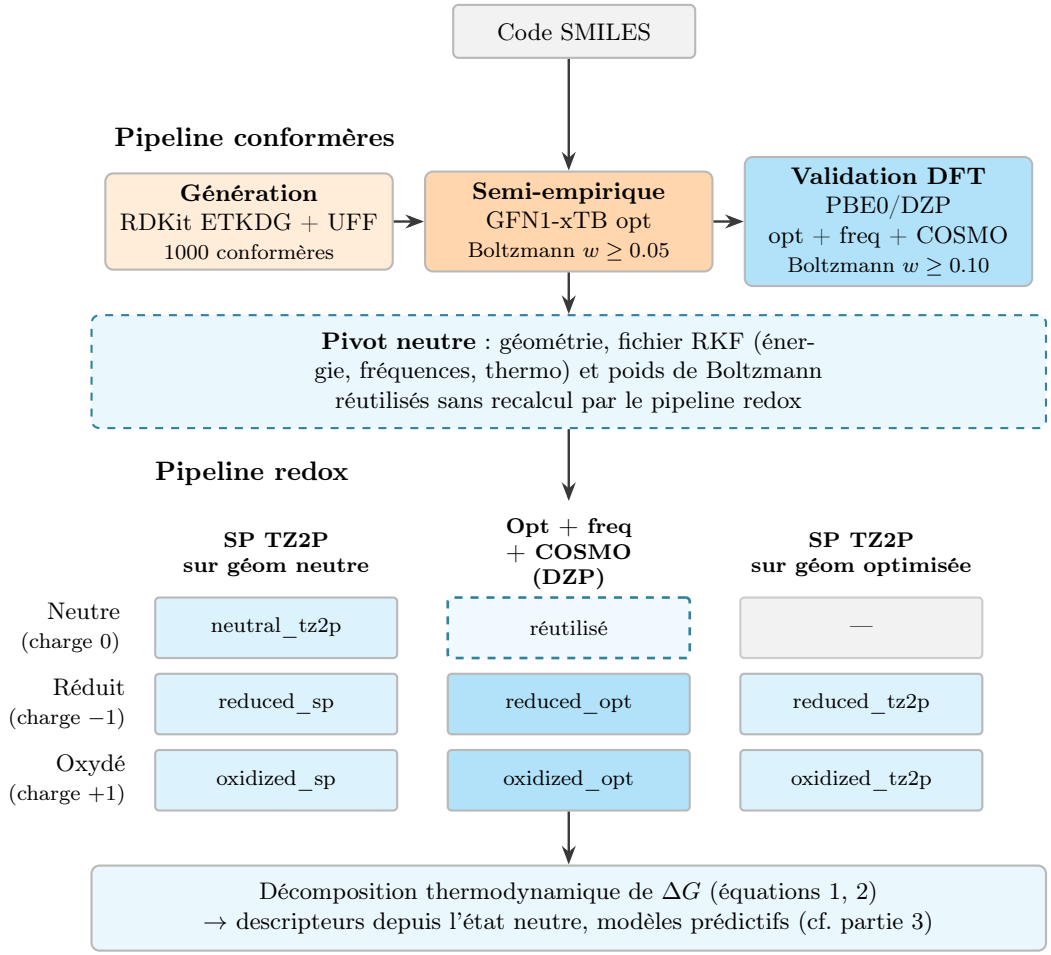


FIGURE 2 – Architecture du workflow. La couleur encode deux dimensions : la *teinte* indique la famille de méthode (orange = pré-DFT, cyan = DFT), et l'*intensité* indique le coût computationnel (clair = single point, foncé = optimisation + analyse vibrationnelle + solvant). **Pipeline conformères** : entonnoir en trois étapes (champ de force, semi-empirique, DFT/DZP opt + freq + COSMO) qui réduit 1000 conformères initiaux à quelques structures validées en vrais minima de la surface d'énergie potentielle. **Pipeline redox** : sept calculs DFT par conformère organisés en grille *charge* × *niveau de calcul*. Les single points TZ2P (cyan clair) fournissent les énergies électroniques de référence en bases cohérentes ; les optimisations DZP avec analyse vibrationnelle (cyan foncé, même intensité que l'étape DFT du pipeline conformères) fournissent les corrections thermodynamiques des états ioniques. La case en pointillé signale le calcul du neutre, réutilisé sans recalcul ; la cellule grisée rappelle que le single point TZ2P sur géométrie optimisée du neutre coïncide avec celui sur géométrie neutre. **Sortie** : décomposition thermodynamique de ΔG, exploitée pour construire les modèles prédictifs de la partie 3.

Schéma composite TZ2P+DZP. Les optimisations géométriques et les corrections thermodynamiques (énergie de point zéro, contributions thermiques, terme entropique) sont effectuées en base DZP, tandis que les énergies électroniques de référence sont raffinées par des *single points* (SP) en base TZ2P. L'énergie libre composite s'écrit

$$G_{\text{composite}} = E_e(\text{TZ2P}) + \big[\, G(\text{DZP}) - E_e(\text{DZP}) \,\big], \tag{3}$$

le terme entre crochets capturant les corrections thermodynamiques au niveau DZP. Ce schéma garantit que toutes les énergies électroniques comparées entre elles (EA, IP, E_{relax}) sont calculées en bases TZ2P cohérentes, tout en évitant le coût prohibitif d'une optimisation géométrique en TZ2P ; les corrections thermodynamiques, peu sensibles à la qualité de la base, peuvent en revanche être évaluées en DZP sans perte mesurable de précision.

Sept calculs par conformère. La géométrie du neutre n'est pas re-optimisée : le fichier RKF de l'étape 4 du pipeline conformères est directement réutilisé. Le pipeline réalise donc sept calculs DFT par conformère (tableau 1), répartis en trois familles symétriques (neutre, réduit, oxydé). Le potentiel redox est ensuite déduit de ΔG° par la relation $E^\circ = -\Delta G^\circ / nF$.

TABLE 1 – Les sept calculs DFT du pipeline redox par conformère. Le calcul neutre opt+freq est hérité du pipeline conformères et n'est pas refait. Les single points fournissent les énergies électroniques en TZ2P ; les optimisations + analyses vibrationnelles fournissent les corrections thermodynamiques en DZP.

Calcul	**Type**	**Charge**	**Base**	**Rôle dans la décomposition**
`neutral_tz2p`	SP	0	TZ2P	E_e^{neutre} de référence
`reduced_sp`	SP	-1	TZ2P	EA verticale (sur géom neutre)
`reduced_opt`	GeomOpt + freq	-1	DZP	Corrections thermo (réduit)
`reduced_tz2p`	SP	-1	TZ2P	$E_e^{\text{réduit,opt}}$ pour $E_{\text{relax}}^{\text{red}}$
`oxidized_sp`	SP	$+1$	TZ2P	IP verticale (sur géom neutre)
`oxidized_opt`	GeomOpt + freq	$+1$	DZP	Corrections thermo (oxydé)
`oxidized_tz2p`	SP	$+1$	TZ2P	$E_e^{\text{oxydé,opt}}$ pour $E_{\text{relax}}^{\text{ox}}$

Mode rapide `predict-dg`. Une option du pipeline redox, activée par le drapeau `--predict-dg`, remplace les sept calculs précédents par trois *single points* effectués sur la seule géométrie neutre (charges 0, -1, $+1$) : une analyse vibrationnelle sur l'état neutre, le gradient sur les états ioniques, et des descripteurs de DFT conceptuelle et topologique sur les trois. Ce mode est construit *a posteriori* des modèles développés à la partie 3 : dès lors que chaque terme de la décomposition de ΔG se prédit depuis les seules propriétés de l'état neutre, puis se corrige en fonction du solvant (§3.6), les optimisations des états ioniques deviennent superflues et le coût par molécule tombe de la dizaine d'heures à de l'ordre de l'heure. À ce coût, le mode `predict-dg` rend possible le criblage de plusieurs milliers de molécules candidates pour les batteries organiques : il permet d'explorer largement l'espace chimique sans le restreindre *a priori* par des intuitions qui, trop strictes, écarteraient de bons candidats.

2.4 Mécanismes transverses

Deux mécanismes s'appliquent uniformément aux deux pipelines.

Correction automatique des fréquences imaginaires. Lorsqu'une optimisation géométrique converge vers un point selle plutôt que vers un minimum, l'analyse vibrationnelle révèle une ou plusieurs fréquences imaginaires. Un algorithme correctif est alors déclenché : le mode

vibrationnel le plus négatif est identifié, la géométrie est perturbée le long de ce mode dans les deux sens, puis ré-optimisée à partir des deux structures perturbées. Le mode normal étant un vecteur de déplacement normé ($\sum_i x_i^2 = 1$), l'amplitude de perturbation s'exprime directement en Å : elle vaut 0.2 Å à la première tentative et croît à chaque essai (0.2 Å, 0.4 Å et 0.6 Å). La procédure est itérée jusqu'à obtention d'un vrai minimum, dans la limite de trois tentatives. La probabilité de converger initialement vers un point selle croît avec la flexibilité conformationnelle de la molécule : les structures portant des chaînes pendantes ou des degrés de liberté torsionnels multiples bénéficient le plus souvent de la correction.

Transfert des poids de Boltzmann. Les poids de Boltzmann calculés à l'étape 4 du pipeline conformères (sur les énergies libres de Gibbs PBE0/DZP+COSMO de l'état neutre) sont réutilisés tels quels par le pipeline redox pour pondérer les moyennes sur les conformères. Ce choix est préférable au recalcul des poids depuis les énergies des états ioniques optimisés : après ré-optimisation, les conformères réduits ou oxydés convergent fréquemment vers des géométries très proches, ce qui donne des poids artificiellement uniformes et masque la structure conformationnelle réelle de l'état neutre, qui est l'objet effectif du criblage. Conserver les poids du neutre garantit également la cohérence des moyennes pondérées entre tous les termes décomposés (EA, IP, E_{relax}, $\Delta\Delta U$, $T\Delta S$).

2.5 Récapitulatif des paramètres par défaut

L'ensemble des paramètres par défaut du workflow est rassemblé dans le tableau 2. Tous sont surchargeables via les arguments en ligne de commande des scripts `conformers_gen.py` et `redox_calc.py` ; les valeurs reportées ici sont celles utilisées pour l'intégralité des calculs présentés dans ce rapport, sauf mention explicite.

3 Résultats d'Analyse

Les pipelines décrits précédemment ont été appliqués à un ensemble de 73 molécules en acétonitrile, couvrant un large espace chimique : catéchols et quinones substitués, dérivés méthoxylés (guaïacol, syringol, vanilline), acides phénoliques (caféique, férulique, sinapique), catécholamines (dopamine, noradrénaline, L-DOPA) et hétérocycles indoliques.

Cinq molécules sont écartées du jeu d'analyse. Quatre dérivés halogénés (Br-DA, Br-HMC, I-DA, I-HMC) présentent un *attachement électronique dissociatif* (DEA) lors de la réduction : la liaison C–X se rompt ($\Delta d > 1.0$ Å), libérant un radical et un halogénure (Ar-X$+e^- \rightarrow$ Ar$^\bullet$+X$^-$). Cette instabilité chimique les rend inaptes aux batteries organiques, qui exigent la réversibilité du processus redox ; le pipeline les détecte automatiquement par comparaison des géométries neutre et réduite optimisées. La L-DOPA est exclue pour des raisons de convergence conformationnelle. Le jeu d'analyse compte donc 68 molécules, traitées au niveau du conformère (154 conformères en acétonitrile) afin de préserver la variabilité intramoléculaire que les modèles exploitent.

Pour chaque conformère, le potentiel redox se décompose selon les équations 1 et 2. Le schéma composite TZ2P+DZP garantit que EA, IP et E_{relax} sont obtenus en bases cohérentes TZ2P, tandis que $\Delta\Delta U$ et $T\Delta S$ proviennent des corrections DZP. Le tableau 3 résume l'amplitude de chaque terme sur le jeu acétonitrile.

Le but de cette partie est de prédire chacun de ces termes à partir des seules propriétés de l'état neutre, afin de remplacer les optimisations géométriques des états ioniques (la part coûteuse du pipeline redox) par des modèles évalués sur les single points du mode `predict-dg`.

3.1 Poids relatif des termes

Tous les termes ne pèsent pas également dans ΔG. Le tableau 4 donne la contribution relative moyenne de chacun, $|\text{terme}|/|\Delta G|$, sur le jeu acétonitrile.

TABLE 2 – Paramètres par défaut du workflow.

Paramètre	**Valeur par défaut**
Niveau de théorie DFT	
Fonctionnelle	PBE0 (hybride, 25% Hartree–Fock)
Base (optimisations et thermodynamique)	DZP (Slater double-ζ + polarisation)
Base (raffinement single-point)	TZ2P (Slater triple-ζ + 2 polarisations)
Qualité numérique	Good
Solvatation implicite (COSMO)	
Solvant par défaut	Acétonitrile
Cavité (espèces neutres)	CONJ
Cavité (espèces ioniques)	CONJ CORR
Pipeline conformères	
Génération initiale	RDKit ETKDG + UFF, 1000 conformères
Optimisation semi-empirique	GFN1-xTB
Seuil Boltzmann post-xTB	$w \geq 0.05$
Seuil Boltzmann post-DFT	$w \geq 0.10$
États électroniques	
Neutre (charge 0)	Couche fermée
Réduit (charge -1)	Couche ouverte, $S = 1/2$
Oxydé (charge $+1$)	Couche ouverte, $S = 1/2$
Thermodynamique	
Température	298.15 K
Correction des fréquences imaginaires	
Tentatives maximum	3
Amplitude de perturbation	0.2 Å, 0.4 Å et 0.6 Å (croissante par tentative)

TABLE 3 – Amplitude des termes de la décomposition de ΔG sur le jeu acétonitrile (68 molécules, 154 conformères). Moyenne ± écart-type, en kJ/mol. Schéma composite TZ2P+DZP.

Terme (kJ/mol)	**Oxydation**	**Réduction**
ΔG°	561 ($\pm$36)	$-$216 ($\pm$114)
IP (ox) / EA (red)	584 ($\pm$42)	177 ($\pm$122)
E_{relax}	$-$24 ($\pm$12)	$-$28 ($\pm$6)
$\Delta\Delta U$	$-$0.3 ($\pm$2.0)	$-$10.3 ($\pm$4.0)
$T\Delta S$	$-$1.7 ($\pm$3.4)	1.4 ($\pm$3.0)

TABLE 4 – Poids relatif moyen de chaque terme dans $|\Delta G|$ (jeu acétonitrile, 154 conformères).

	EA/IP	$\lvert E_{\mathbf{relax}}\rvert$	$\lvert\Delta\Delta U - T\Delta S\rvert$
Oxydation	∼104%	∼4%	< 1%
Réduction	∼75%	∼17%	∼8%

Les deux processus ne sont pas symétriques. En oxydation, l'IP domine totalement (∼104 % ; elle excède $|\Delta G|$ parce que E_{relax}, négatif, en réduit l'amplitude), E_{relax} ne contribue que modérément (∼4%) et les corrections thermiques sont négligeables (< 1%) : $\Delta G_{\text{ox}} \approx \text{IP} + E_{\text{relax}}$ à quelques kJ/mol près. En réduction, l'EA reste dominante (∼75%) mais E_{relax} (∼17%) et les corrections thermiques (∼8%) prennent un poids appréciable : les quatre termes doivent tous être pris en compte.

Étalon : la précision intrinsèque de la DFT. Il faut garder à l'esprit la précision limitée de la DFT elle-même. Au niveau PBE0/DZP utilisé ici, l'erreur absolue moyenne (MAE) typique sur les énergies de réaction est de l'ordre de 1–2 kcal/mol, soit 4 kJ/mol à 8 kJ/mol[17]. Tout modèle dont la MAE passe sous cette barre est donc aussi fiable que le calcul DFT complet. C'est l'étalon auquel nous comparons systématiquement les modèles des sections suivantes, plutôt que de viser des R^2 élevés : un terme de faible amplitude (comme $\Delta\Delta U$ ou $T\Delta S$, ∼1–3 kJ/mol) aura mécaniquement un R^2 modeste sans que cela traduise un défaut du modèle.

Les sections suivantes traitent chaque terme dans l'ordre de son poids : EA/IP (§3.2), E_{relax}, puis les corrections thermiques $\Delta\Delta U$ et $T\Delta S$, le tout sur l'acétonitrile, notre solvant de référence. Nous généralisons ensuite aux dix solvants (§3.6) avant d'assembler la prédiction complète de ΔG° (§3.7).

3.2 Affinité électronique et potentiel d'ionisation verticaux

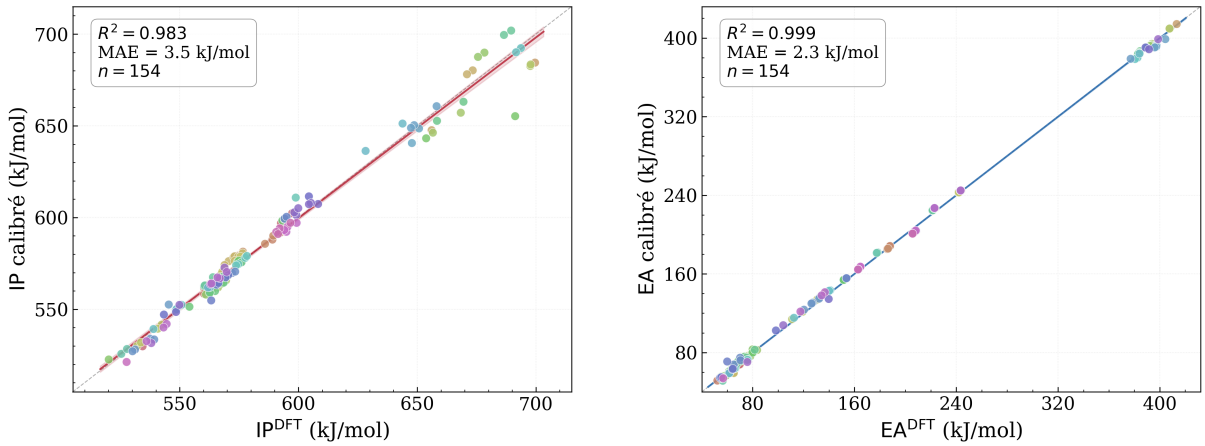
EA et IP verticaux dominent la décomposition de ΔG (tableau 4) : c'est par eux que nous avons commencé. Précisons d'emblée la logique modulaire qui sous-tend toute cette partie, articulée autour de deux niveaux de coût.

Au niveau le plus complet, le mode `predict-dg` calcule trois single points sur la géométrie neutre : l'état neutre avec ses modes normaux (Hessien neutre), puis les états réduit et oxydé en gradient seul. EA et IP s'y obtiennent alors exactement, sans modèle, par simple différence d'énergie ($\text{EA} = E^{\text{neutre}} - E^{\text{réduit,sp}}$ et $\text{IP} = E^{\text{oxydé,sp}} - E^{\text{neutre}}$), et l'on dispose de tout le nécessaire pour les autres termes, y compris le descripteur vibronique de E_{relax} (§3.3), qui ne réclame que le Hessien du neutre et les gradients ioniques, jamais les Hessiens ioniques.

Au niveau le plus économique d'un unique single point neutre, les états ioniques ne sont pas calculés du tout : EA, IP et l'ensemble des termes doivent alors être prédits à partir des seules propriétés de l'état neutre. C'est ce niveau qui justifie nos modèles. Si nous consacrons malgré tout un modèle à EA et IP, par ailleurs exacts au niveau supérieur, c'est pour deux raisons : rendre le schéma utilisable jusqu'à ce palier minimal, et, surtout, parce que le chemin parcouru pour les prédire est celui qui nous a le plus appris.

Le point de départ : Koopmans. L'approximation de Koopmans[1] relie l'EA à $-\varepsilon_{\text{LUMO}}$ et l'IP à $-\varepsilon_{\text{HOMO}}$. Rigoureuse en Hartree–Fock, où elle constitue un théorème, cette relation n'est qu'approchée une fois transposée aux énergies de Kohn–Sham, comme c'est le cas ici puisque nos calculs sont en DFT et non en Hartree–Fock ; elle reste néanmoins un lien éprouvé pour les grandeurs redox[6], et c'était le point de départ naturel. Une simple régression calibrée sur ces énergies orbitalaires confirme la robustesse de l'idée (figure 3) : l'EA est reproduite presque parfaitement ($R^2 = 0.999$, MAE 2.3 kJ/mol), portée par la seule LUMO. L'IP, en revanche, est bonne mais imparfaite ($R^2 = 0.98$, MAE 3.5 kJ/mol) : la dispersion résiduelle, visible sur le

parity plot, trahit une information manquante. Cette asymétrie entre les deux processus appelait un examen plus poussé.

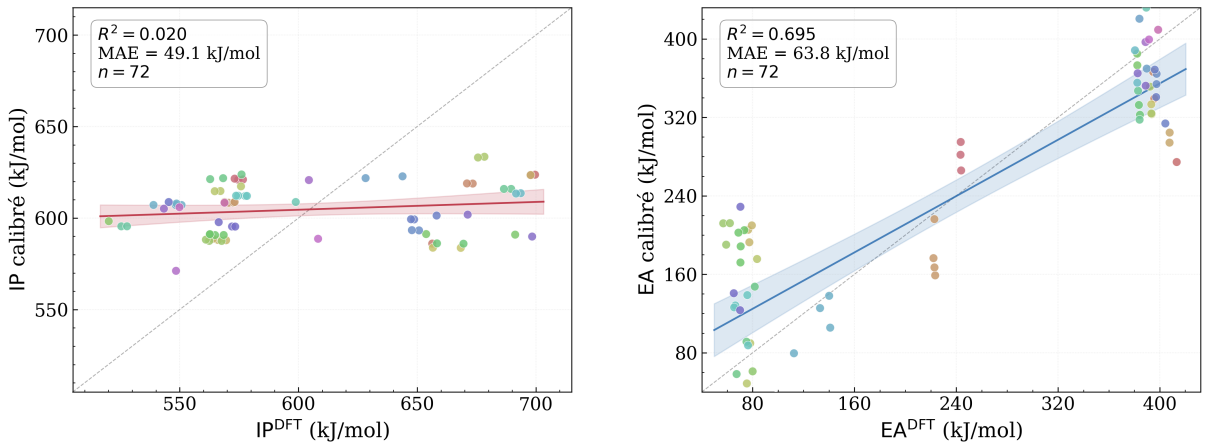


(a) IP (oxydation).

(b) EA (réduction).

FIGURE 3 – Approximation de Koopmans calibrée ($-\varepsilon_{\mathrm{HOMO}}$ pour l'IP, $-\varepsilon_{\mathrm{LUMO}}$ pour l'EA), validation croisée *vs* DFT. L'EA est quasi parfaite, l'IP nettement plus dispersée, indice qu'une seule orbitale ne suffit pas pour l'IP.

Une alternative plus complète : Politzer et Murray. Intrigués par cette imperfection, nous avons voulu pousser plus loin avec une approche réputée plus complète : l'énergie d'ionisation locale moyenne (ALIE) de Politzer et Murray[3], évaluée sur l'isosurface de densité de van der Waals. Là où Koopmans ne regarde qu'une orbitale, l'ALIE mobilise toutes les orbitales occupées et fournit en prime une information spatiale (le site le plus faiblement lié). L'approche paraissait prometteuse, mais le résultat fut sans appel (figure 4) : après calibration, l'IP affiche une MAE de l'ordre de 49 kJ/mol et un R^2 effondré à 0.02, soit un nuage de points sans la moindre corrélation avec la valeur DFT. Une analyse rétrospective a pointé notre implémentation (potentiel coulombien employé au lieu du potentiel électrostatique total, résolution de grille) : nous ne pouvons donc pas trancher sur la validité intrinsèque de la méthode, mais, en l'état et pour notre système, elle ne tenait pas la comparaison. Nous sommes revenus aux orbitales frontières.



(a) IP (oxydation). (b) EA (réduction).

FIGURE 4 – Approche de Politzer–Murray calibrée ($\bar{I}_{S,\min}$, moyenne sur les orbitales occupées, pour l'IP ; $-V_{S,\min}$, minimum du potentiel électrostatique, pour l'EA). La prédiction de l'IP est décorrélée de la référence ($R^2 = 0.02$) : dans notre implémentation, l'échec est sans équivoque. Échelles identiques aux figures 3 et 5. Le post-traitement DENSF de l'ALIE étant coûteux, il n'a été mené que sur un sous-ensemble antérieur de 34 molécules (72 conformères), non réétendu au jeu complet après l'abandon de cette piste.

La DFT conceptuelle. La solution est venue en reliant nos deux essais précédents par une même question : au-delà de l'unique orbitale de Koopmans (la HOMO pour l'IP), quelles autres orbitales mobiliser ? Politzer répondait « toutes les occupées » : l'ALIE moyenne les contributions de la HOMO, de la HOMO−1, jusqu'aux couches profondes, pondérées par la densité. Mais, par construction, cette voie ne regarde que les orbitales occupées et ignore les virtuelles. Or l'imperfection de Koopmans sur l'IP venait précisément de là : l'information manquante n'était pas dans les couches profondes, mais dans la LUMO, c'est-à-dire dans le gap HOMO–LUMO, qui n'est autre que la dureté chimique. La DFT conceptuelle[18] apporte exactement cette pièce. Le potentiel chimique électronique[19] et la dureté[20],

$$\mu = \frac{\varepsilon_{\mathrm{HOMO}} + \varepsilon_{\mathrm{LUMO}}}{2}, \quad \eta = \frac{\varepsilon_{\mathrm{LUMO}} - \varepsilon_{\mathrm{HOMO}}}{2}, \quad \omega^{\pm} = \frac{(\eta \pm 2\mu)^2}{8\eta}, \tag{4}$$

forment une bijection exacte du couple $(\varepsilon_{\mathrm{HOMO}}, \varepsilon_{\mathrm{LUMO}})$. Là où Koopmans n'exploitait qu'une orbitale, et où Politzer en empilait beaucoup mais toutes occupées, (μ, η) marie les deux frontières, la HOMO et la LUMO. C'est précisément cette LUMO, absente de l'ALIE, qui redresse l'IP : l'asymétrie observée plus haut (EA quasi parfaite, IP dispersée) s'explique alors, puisque seule l'IP était privée de sa frontière complémentaire. Jusqu'où enrichir cette description ? Nous avons testé d'ajouter les orbitales voisines (HOMO−1, LUMO+1) : le gain s'est révélé marginal pour deux paramètres supplémentaires, et au-delà de la paire frontière on glisse vers le surapprentissage sans bénéfice réel. La paire (μ, η) constitue donc le bon arrêt. Nous l'avons complétée d'un descripteur de réactivité spécifique à chaque cible, tiré du même cadre symétrique (les pouvoirs électroniques directionnels de Gázquez[24]) : le pouvoir électro-accepteur ω^+ pour l'EA, et la nucléophilie $1/\omega^-$ (inverse du pouvoir électrodonneur) pour l'IP[25], ainsi que d'une correction de Fukui[21] locale :

$$\mathrm{EA} = \left(\theta_\mu\,\mu + \theta_\eta\,\eta + \theta_{\omega^+}\,\omega^+\right)\left(1 + a\,f^2_{\max}\right), \tag{5}$$

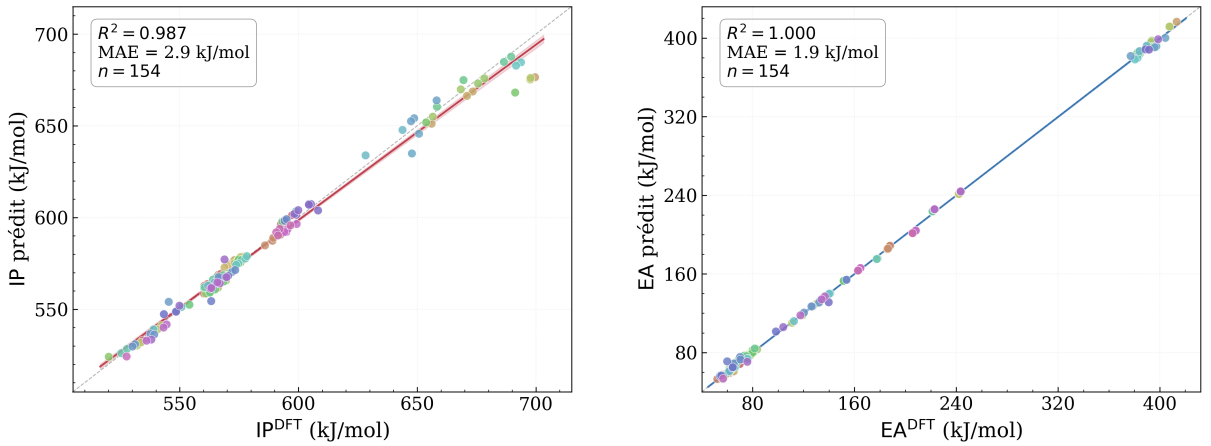
$$\mathrm{IP} = \left(\theta_\mu\,\mu + \theta_\eta\,\eta + \theta_n\,\tfrac{1}{\omega^-}\right)\left(1 + a\,f^2_{\min}\right), \tag{6}$$

où $f^2 = f^+ - f^-$ est la fonction de Fukui duale de Morell[23]. Les coefficients (tableau 5) sont ajustés par minimisation de la MAE en validation croisée à 5 plis groupée par molécule ($n = 154$ conformères, 68 molécules).

TABLE 5 – Coefficients des modèles EA et IP (éqs. 5–6). Descripteurs $\mu, \eta, \omega^+, 1/\omega^-$ en eV, cibles en kJ/mol.

	θ_μ	θ_η	θ_{ω^+} / θ_n	a	**Fukui**
EA	−91.5	−43.0	5.0	0.17	$f^2_{\max}$
IP	−85.0	50.4	−156.5	−0.06	$f^2_{\min}$

Le gain est net (figure 5) : MAE 1.91 kJ/mol ($R^2 = 1.00$) pour l'EA et 2.94 kJ/mol ($R^2 = 0.99$) pour l'IP, toutes deux sous la barre d'erreur intrinsèque de la DFT (4 kJ/mol à 8 kJ/mol). L'amélioration la plus parlante est celle de l'IP, qui passe de 3.5 (Koopmans) à 2.9 kJ/mol, précisément le terme que la double orbitale devait redresser.



(a) IP (oxydation). (b) EA (réduction).

FIGURE 5 – Modèle CDFT final pour IP et EA en acétonitrile (validation croisée *vs* DFT). Chaque point est un conformère, colorié par molécule (68 molécules, 154 conformères) ; régression et bande de confiance à 95 %, diagonale $y = x$ en pointillés. À comparer aux figures 3 (Koopmans) et 4 (Politzer) : le resserrement est net, surtout pour l'IP.

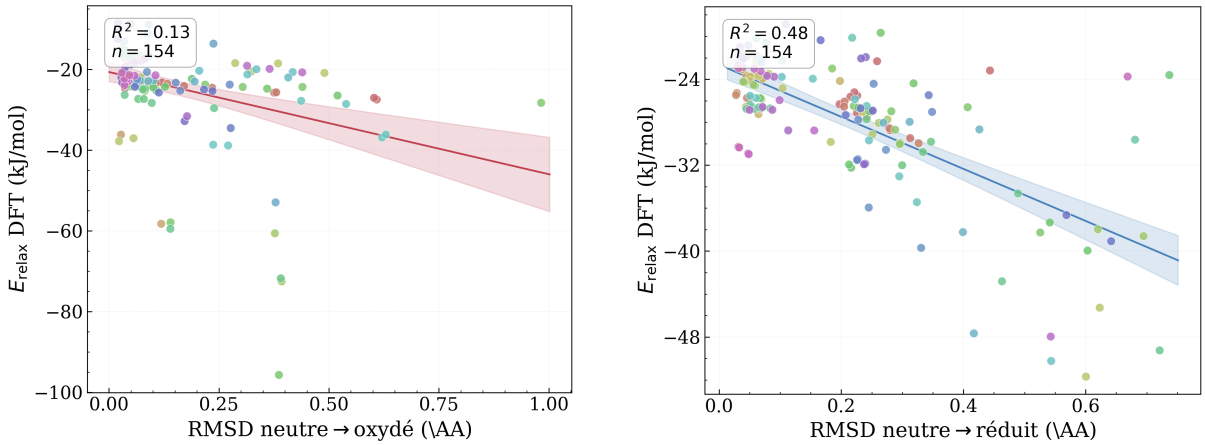
Ce que la réactivité apporte. Le troisième descripteur n'a rien de décoratif. L'ablation le confirme : le passage de (μ, η) à (μ, η, ω^+) abaisse la CV-MAE de l'EA de 2.18 à 1.91 kJ/mol (−12%), et l'ajout de $1/\omega^-$ celle de l'IP de 3.32 à 2.94 kJ/mol (−11%). L'interprétation est physique : μ indique la tendance au transfert d'électron et η la résistance à ce transfert, mais aucun des deux ne mesure la capacité effective de la molécule à réaliser l'échange. C'est précisément ce que quantifie le pouvoir électro-accepteur ω^+ de Gázquez, forme directionnelle de l'électrophilie de Parr[22] : l'énergie de stabilisation gagnée lorsque la molécule se sature en électrons, c'est-à-dire sa puissance à attirer un électron (pour l'EA) ; l'inverse du pouvoir électrodonneur $1/\omega^-$ joue le rôle symétrique pour la propension à céder un électron (pour l'IP). Nous avons d'ailleurs comparé ce descripteur aux autres indices de nucléophilie de la littérature (ω^- direct, $N = 1/\omega$ de Chattaraj, indice récent N_G de Hoffmann fondé sur l'hyperdureté[25]) : aucun ne surpasse $1/\omega^-$ pour notre IP. Ces indices combinent μ et η de façon non linéaire, apportant une information que le couple seul, en régression linéaire, ne peut reproduire.

3.3 Énergie de relaxation E_{relax}

E_{relax} est l'énergie que l'ion libère en relaxant sa géométrie, du point vertical (figé sur la structure du neutre) jusqu'à son propre minimum ; c'est, au sens de la théorie de Marcus, l'énergie de réorganisation interne[32]. C'est le terme le plus difficile à prédire, et pour une raison de fond : contrairement à EA et IP, aucun théorème ne le relie aux propriétés de l'état neutre. La relaxation

est un effet vibronique, le couplage entre le déplacement des noyaux et la réorganisation de la structure électronique. En DFT, l'obtenir impose d'optimiser la géométrie de l'ion, optimisation que nous doublons systématiquement d'un calcul de fréquences pour confirmer qu'il s'agit bien d'un minimum, et non d'un point selle. Ce sont ces deux étapes, optimisation puis fréquences, répétées pour chaque état de charge, qui alourdissent le coût : un facteur 5 à 10 par rapport à un simple single point. Prédire E_{relax} sans engager ce coût est l'enjeu central de ce travail.

La relaxation est-elle une affaire de géométrie ? Puisque E_{relax} accompagne un réarrangement des noyaux, notre première question fut la plus simple : cette énergie se résume-t-elle à l'ampleur du déplacement ? Nous l'avons confrontée au RMSD entre la géométrie neutre et la géométrie ionique optimisée, sur les 154 conformères (figure 6). La réponse est instructive par sa faiblesse : le RMSD n'explique que ∼48 % de la variance en réduction, et à peine ∼13 % en oxydation. Si la relaxation se réduisait à la distance parcourue par les atomes, le nuage serait serré le long de la diagonale ; il ne l'est pas. Un même déplacement structural peut libérer des énergies fort différentes selon la raideur des modes le long desquels la molécule se réorganise. C'est précisément l'effet vibronique annoncé en ouverture : E_{relax} dépend à la fois de l'amplitude du mouvement et de la courbure de la PES ionique ; le RMSD ne capture que la première et reste aveugle à la seconde. Cette observation, plus qu'un échec, est un diagnostic : elle écarte d'emblée tout proxy purement structural et indique qu'un bon prédicteur devra intégrer explicitement les constantes de force des modes. Au demeurant, le RMSD ne ferait de toute façon pas un prédicteur : il suppose connue la géométrie ionique optimisée, le résultat même que nous cherchons à éviter.



(a) Oxydation.

(b) Réduction.

FIGURE 6 – E_{relax} DFT en fonction du RMSD neutre→ion (Kabsch) sur les 154 conformères, coloriés par molécule ; régression et bande de confiance à 95 %. La corrélation est faible, modérée en réduction ($R^2 \approx 0.48$) et ténue en oxydation ($R^2 \approx 0.13$) : le déplacement structural ne suffit pas à expliquer E_{relax}, signature de son caractère vibronique.

Un descripteur du neutre, alors ? Restait à chercher, du côté du seul état neutre, une signature de la relaxation à venir. Nous avons passé au crible un large éventail de grandeurs accessibles avant tout calcul ionique : orbitales frontières et gap, charges de Bader[31] atome par atome, énergies IQA intra- et inter-atomiques, et un ensemble de statistiques fréquentielles (moyenne, écart-type, étendue du spectre, ZPE, densité de modes par bande). Aucune ne se détachait : corrélations faibles, nuages dispersés. Avec le recul, l'échec était prévisible : la relaxation est un phénomène collectif, réparti sur de nombreux modes couplés, qu'aucune grandeur scalaire du neutre ne résume.

Un modèle physique de la relaxation. Le diagnostic du RMSD nous avait laissé une consigne claire : il fallait un modèle mêlant déplacement et raideur des modes, donc cesser de deviner la relaxation pour la modéliser. Le couplage vibronique linéaire (LVC)[26] fait précisément cela : il estime E_{relax} par un développement quadratique de la surface d'énergie potentielle (PES) ionique autour de la géométrie neutre R_0. Projeté sur les modes normaux :

$$E_{\text{relax}}^{\text{LVC}} = -\sum_i \frac{F_i^2}{2k_i}, \qquad F_i = \boldsymbol{g} \cdot \mathbf{N}_i, \tag{7}$$

où $\boldsymbol{g} = \nabla V_{\text{ion}}(R_0)$ est le gradient de la PES ionique à R_0 (obtenu d'un single point de l'ion sur la géométrie neutre), et $\mathbf{N}_i, k_i$ les modes normaux et constantes de force du Hessien neutre. On y retrouve exactement les deux ingrédients que le RMSD séparait mal : le couplage F_i joue le rôle du déplacement, et les constantes de force k_i celui de la raideur qui lui manquait. Le choix du Hessien neutre n'est pas arbitraire : c'est un vrai minimum de la PES, propre et bien conditionné, et il est déjà disponible (le calcul de fréquences du neutre sert aussi à la thermochimie). Une subtilité demeure : la somme (7) diverge sur les modes mous des molécules flexibles, où $k_i \to 0$ fait diverger la contribution $F_i^2/2k_i$. Nous restreignons donc la somme aux modes de fréquence $\omega \geq 100\,\text{cm}^{-1}$; un balayage du seuil entre 50 et $300\,\text{cm}^{-1}$ place l'optimum à $100\,\text{cm}^{-1}$, juste au-dessus des réorganisations torsionnelles parasites et juste en-dessous des modes qui portent la vraie physique.

Peut-on faire mieux ? Notre LVC repose sur deux choix : le Hessien neutre, et un développement autour de R_0 (piloté par le gradient). Rien ne les imposait, et nous avons éprouvé les alternatives sur les 154 conformères (tableau 6), réparties en deux familles.

Variantes à gradient, dans l'esprit du LVC (développement autour de R_0). LVC2 remplace le Hessien neutre par le Hessien ionique évalué à R_0, dans l'espoir d'une meilleure cohérence, gradient et courbure étant alors lus sur « la même PES ». Mais c'est oublier ce qu'est le LVC : dans ce modèle, la PES ionique est précisément celle du neutre, décalée d'un couplage linéaire (le gradient). La courbure du neutre n'y est donc pas une approximation commode mais l'hypothèse fondatrice ; et le neutre, lui, est un puits propre et bien défini. LVC2 prétend lire la « vraie » courbure ionique ; or, à un point non stationnaire, cette courbure n'a pas le sens d'un puits (d'où ses modes imaginaires), et la filtrer ($\omega < 100\,\text{cm}^{-1}$, comme pour le LVC) ne reconstruit aucune PES physique. On finit par projeter le gradient ionique sur une surface tronquée qui n'est ni la PES ionique ni rien de bien défini ; le défaut ne vient pas des modes imaginaires écartés, mais des modes réels retenus, hérités de ce point hors équilibre. QVC (*quadratic vibronic coupling*) ajoute au LVC une correction du premier ordre sur la variation des fréquences, $\lambda_{\text{QVC}} = \lambda_{\text{LVC}}\,[1 + \sum_i (\Delta\omega_i/\omega_i)(\lambda_i/\lambda)]$. En définitive, ni l'une ni l'autre n'améliore le LVC. QVC, simple multiple de LVC, lui est numériquement identique ; LVC2 fait moins bien (MAE 3.5 contre 2.7 kJ/mol en réduction) et de façon erratique : il surestime fortement certaines oxydations (F-DOPA : -144 contre -59 kJ/mol réels, l'écart provenant de modes raides bien au-dessus du seuil) et en sous-estime d'autres. Le succès du Hessien neutre n'a donc rien de paradoxal : il n'est pas un pis-aller, mais le fondement même du LVC.

Variantes à déplacement réel, qui développent l'énergie jusqu'au minimum ionique. L'approche Duschinsky / Huang–Rhys[27;28] projette le déplacement géométrique réel sur les modes ioniques, $E = -\frac{1}{2}\,\Delta R^{\top} H_{\text{ion}}\,\Delta R = -\frac{1}{2}\sum_i \omega_i^2\,\Delta q_i^2$, incorporant la rotation des modes et les facteurs de Huang–Rhys ; Morse–Duschinsky et VPT2-cubique y greffent l'anharmonicité (potentiel de Morse[29], terme cubique[30]). Ces méthodes échouent lourdement (MAE de 65 kJ/mol à 1000 kJ/mol). La raison tient à la pondération : contrairement au gradient (terme $F_i^2/2k_i$, atténué par les grands k_i), la forme en déplacement $\frac{1}{2}\omega_i^2\Delta q_i^2$ est amplifiée par les modes raides. Or le déplacement réel, décomposé, possède des composantes le long des étirements de liaison de haute fréquence (O–H, C–H, 1500–3650 cm^{-1}) : un infime changement de longueur de liaison y coûte

une énergie démesurée (sur HMC, un seul mode O–H à $3650\,\mathrm{cm}^{-1}$ contribue $-128\,\mathrm{kJ/mol}$). L'anharmonicité (Morse, VPT2) atténue sans corriger, et le filtre des basses fréquences n'y change rien puisque le problème vient du haut du spectre. Le développement au gradient, lui, est insensible à ces modes raides.

La conclusion est nette : le LVC le plus simple, gradient ionique à R_0 et Hessien neutre, est le meilleur estimateur vibronique de notre jeu de données. C'est lui que nous retenons comme cœur physique.

TABLE 6 – Estimateurs vibroniques bruts de E_{relax} (sans enrichissement CDFT) face à la référence DFT, sur les 154 conformères acétonitrile (seuil $100\,\mathrm{cm}^{-1}$, implémentation par diagonalisation du Hessien masse-pondéré). MAE en kJ/mol. Les méthodes *à gradient* (développement autour de R_0) prédisent E_{relax} à $\sim$3 kJ/mol ; les méthodes *à déplacement réel* (extrapolation jusqu'au minimum ionique) divergent sur les modes raides de haute fréquence.

	Réduction		**Oxydation**	
Méthode	MAE	R^2	MAE	R^2
À gradient (développement autour de R_0)				
LVC (Hessien neutre), retenu	**2.7**	**0.26**	**2.8**	**0.69**
LVC2 (Hessien ionique à R_0)	3.5	-0.04	3.3	0.34
QVC	2.6	0.30	2.6	0.70
À déplacement réel (jusqu'au minimum ionique)				
Duschinsky / Huang–Rhys	1006	$\ll 0$	645	$\ll 0$
Morse–Duschinsky	92	$\ll 0$	65	$\ll 0$
VPT2-cubique	328	$\ll 0$	210	$\ll 0$

Le modèle final. LVC fournit le cœur physique de la prédiction ; un seul descripteur frontière vient le compléter, la dureté η, avec la correction de Fukui duale :

$$E_{\mathrm{relax}} = \big(\theta_\eta\,\eta + \theta_{\mathrm{L}}\,\mathrm{LVC}\big)\big(1 + a\,f^2\big), \tag{8}$$

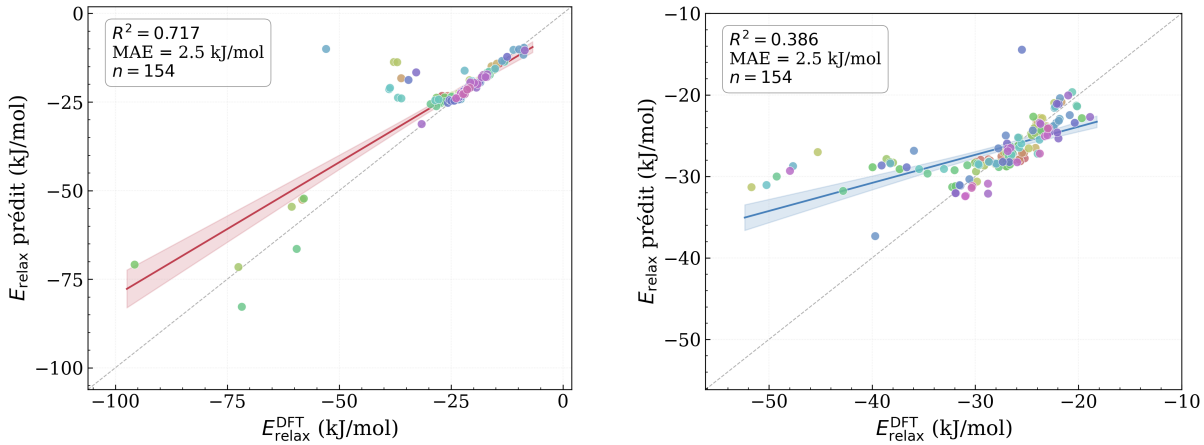
où LVC (seuil $100\,\mathrm{cm}^{-1}$) est exprimé en kJ/mol comme la cible, de sorte que tous les coefficients (tableau 7) soient d'ordre comparable. Le potentiel chimique μ, pourtant pilier des modèles d'EA, d'IP, de $\Delta\Delta U$ et de $T\Delta S$, est ici absent : son coefficient s'annule à l'ajustement. Loin d'être une anomalie, ce fait est physiquement attendu.

Pourquoi μ ne prédit pas E_{relax}. Le potentiel chimique $\mu = (\varepsilon_{\mathrm{HOMO}} + \varepsilon_{\mathrm{LUMO}})/2$ mesure la position des niveaux frontières, c'est-à-dire l'énergie (et le sens) du transfert électronique. C'est exactement ce dont EA et IP ont besoin : ils sont ces énergies de transfert ($-\mathrm{EA} \approx \varepsilon_{\mathrm{LUMO}}$, $\mathrm{IP} \approx -\varepsilon_{\mathrm{HOMO}}$), et $\Delta\Delta U$ comme $T\Delta S$ suivent la redistribution de charge que μ gouverne. Mais E_{relax} ne relève pas de cette variation d'énergie liée à l'ajout ou au retrait d'un électron. Ce qui le détermine, c'est le rééquilibrage des forces, entre les électrons eux-mêmes et entre électrons et noyaux, une fois la charge modifiée : le gradient de la PES ionique $\boldsymbol{g} = \nabla V_{\mathrm{ion}}(R_0)$, c'est-à-dire le couplage vibronique. Ces forces dépendent du caractère liant ou antiliant de l'orbitale sur chaque liaison, non de sa position énergétique : deux molécules d'électronégativité μ très différente peuvent relaxer de façon identique, et inversement. μ est donc, par construction, orthogonal à E_{relax} : toute l'information pertinente est déjà portée par LVC, qui est ce gradient. La dureté η, en revanche, subsiste pour une raison complémentaire : en tant que gap HOMO–LUMO, elle traduit l'ancrage et la stabilité de la structure électronique, à quel point la charge en place est solidement tenue. Plus cet ancrage est fort, plus il freine la réorganisation ; η module ainsi l'amplitude de la relaxation sans jamais en être le moteur.

TABLE 7 – Coefficients du modèle E_{relax} (éq. 8), ajustés en validation croisée à 5 plis groupée par molécule. LVC et E_{relax} sont exprimés en kJ/mol, η en eV : tous les coefficients sont d'ordre comparable.

	θ_η	θ_{L}	a	**Fukui**
$E^{\mathrm{ox}}_{\mathrm{relax}}$	-1.22	0.61	-0.976	f^2_{min}
$E^{\mathrm{red}}_{\mathrm{relax}}$	-0.46	0.92	0.128	f^2_{max}

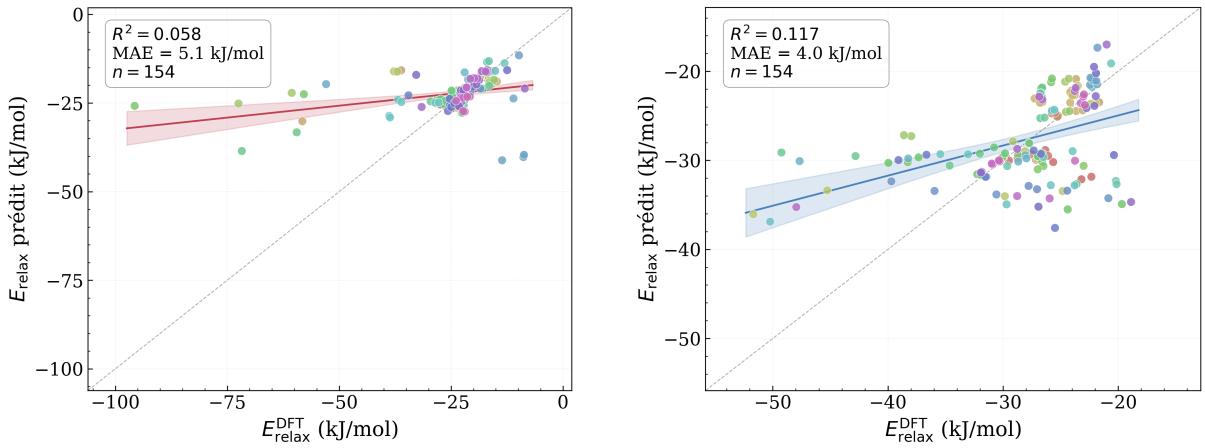
Sur les 154 conformères : MAE = 2.45 kJ/mol ($R^2 = 0.72$) en oxydation, 2.53 kJ/mol ($R^2 = 0.39$) en réduction (figure 7). η et la correction de Fukui n'améliorent que légèrement le LVC brut (oxydation : 2.8 kJ/mol à 2.5 kJ/mol ; réduction : 2.7 kJ/mol à 2.5 kJ/mol) : le gain est réel mais reste sous la barre DFT, comme on pouvait s'y attendre d'un terme que LVC porte déjà presque seul. Quant au R^2 plus modeste en réduction, il ne trahit pas le modèle mais l'étroitesse de la cible (E_{relax} de variance limitée, ∼20 kJ/mol à 30 kJ/mol) : sur une grandeur aussi resserrée, c'est la MAE, bien en deçà de la barre DFT, qui fait foi.



(a) Oxydation. (b) Réduction.

FIGURE 7 – Parity plots du modèle E_{relax} en acétonitrile (validation croisée *vs* DFT). Points coloriés par molécule (68 molécules, 154 conformères) ; régression et bande de confiance à 95 %, diagonale $y = x$ en pointillés.

Apport du terme vibronique. Le terme LVC porte-t-il une information absente du descripteur frontière ? L'ablation est sans ambiguïté : en le retirant, le modèle se réduit à $(\eta) \times (1 + a\, f^2)$ et sa CV-MAE se dégrade de 2.53 kJ/mol à 4.03 kJ/mol en réduction (+1.50) et, surtout, de 2.45 kJ/mol à 5.11 kJ/mol en oxydation (+2.66). À l'inverse, retrancher η ou la correction de Fukui ne coûte que quelques centièmes de kJ/mol ; l'asymétrie est nette. La figure 8 l'illustre : sans le terme vibronique, la prédiction en oxydation s'effondre (R^2 négatif, régression quasi plate), le modèle ne distinguant plus les fortes réorganisations (famille DOPA, en bas à gauche, sévèrement sous-prédites).



(a) Oxydation. (b) Réduction.

FIGURE 8 – Parity plots de E_{relax} *sans* le terme vibronique : modèle réduit $(\eta) \times (1 + a\, f^2)$, descripteur frontière seul. À comparer avec la figure 7 (avec LVC). La dégradation est marquée en oxydation (MAE 5.1 kJ/mol) et en réduction (4.0 kJ/mol).

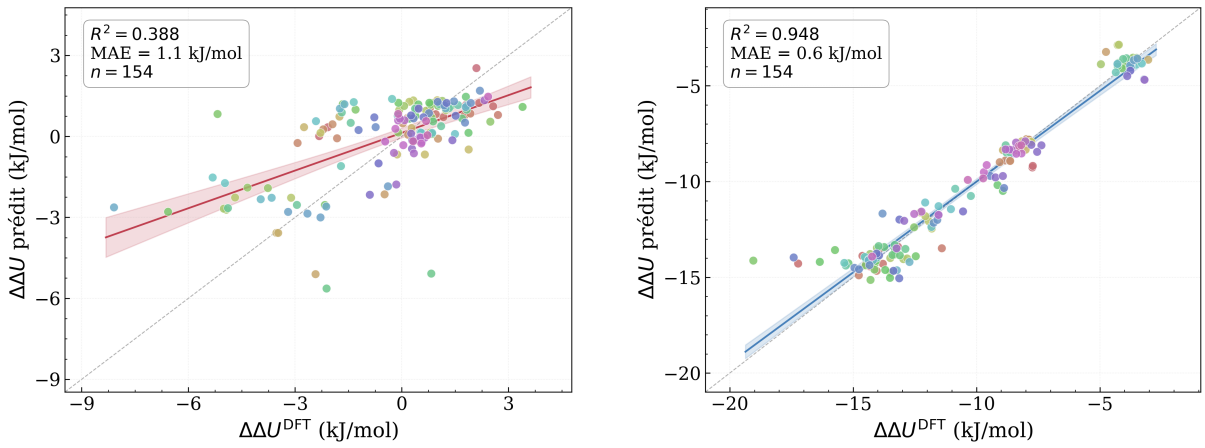
3.4 Énergie interne thermique $\Delta\Delta U$

Après EA, IP et E_{relax}, nous arrivons aux deux termes thermiques, plus petits mais que la barre DFT ne nous autorise pas à négliger. Le premier, $\Delta\Delta U = [U(\text{ion}) - E_e(\text{ion})] - [U(\text{neutre}) - E_e(\text{neutre})]$, est la correction d'énergie interne (pour l'essentiel la variation d'énergie de point zéro, ZPE) qui accompagne le changement d'état de charge. Son amplitude dit déjà l'essentiel : nettement négatif en réduction ($-10.3(40)$ kJ/mol, la structure s'assouplit en accueillant l'électron), quasi nul en oxydation ($-0.3(20)$ kJ/mol).

Premier réflexe : la ZPE. Le réflexe semblait tout tracé : puisque $\Delta\Delta U$ est une affaire de ZPE, corrélons-le à la ZPE de l'état neutre. L'échec est immédiat ($R^2 < 0.01$). Notre erreur, avec le recul, était de confondre une valeur et une différence : $\Delta\Delta U$ ne dépend pas de la ZPE absolue (qui ne fait guère que suivre la taille de la molécule), mais du décalage des fréquences entre neutre et ion. Ce n'est pas combien la molécule vibre qui compte, mais de combien sa vibration change.

Le bon descripteur, et pourquoi nous l'avons écarté. Or ce décalage, nous savions l'écrire exactement. Au premier ordre, $\Delta\Delta U \approx \frac{1}{2}\sum_i \hbar\,(\omega_i^{\text{ion}} - \omega_i^{\text{neutre}})$: la somme, mode à mode, des décalages de fréquence, que la formule RRHO quantique[33] $U_{\text{vib}}(\omega) = \frac{1}{2}\hbar\omega + \hbar\omega/(e^{\hbar\omega/kT} - 1)$ évalue à partir des fréquences verticales de l'ion (Hessien ionique à la géométrie neutre). Nous l'avons calculée (descripteur noté ΔU_{RRHO}) et la corrélation s'est révélée excellente : 0.90 avec $\Delta\Delta U_{\text{red}}$, MAE 0.61 kJ/mol ($R^2 = 0.95$, figure 9) contre 0.87 sans lui. Nous tenions enfin le bon descripteur. Il n'a d'ailleurs rien d'*ad hoc* : ΔU_{RRHO} réalise, par différences finies en nombre d'électrons, la rigidité nucléaire $\partial k/\partial N$ (la réponse des constantes de force à l'ionisation, formalisée en DFT conceptuelle[34;35]), dont le Hessien ionique évalué à R_0 est l'expression directe.

Mais il nous reconduisait droit au problème que nous venions de contourner pour E_{relax}. Les fréquences ioniques réclament le Hessien de chaque état ionique, soit les ∼6N évaluations de gradient par état que nous nous étions promis d'épargner. Et le gain, mesuré honnêtement, restait faible : 0.18 kJ/mol en réduction, 0.04 en oxydation, loin sous la barre DFT. Rétablir les Hessiens ioniques pour si peu aurait trahi tout l'esprit du schéma. Nous avons donc écarté ce descripteur idéal, tout en le conservant comme référence (figure 9), borne qu'un calcul plus lourd atteindrait, pour repartir en quête d'un substitut tiré du seul état neutre.



(a) Oxydation. (b) Réduction.

FIGURE 9 – $\Delta\Delta U$ avec le descripteur physique ΔU_{RRHO} ajouté : borne de référence non retenue, car elle exige les Hessiens ioniques. En réduction, l'apport est net (MAE 0.61 *vs* 0.87 kJ/mol, $R^2 = 0.95$) ; en oxydation, marginal (1.14 *vs* 1.18 kJ/mol). À comparer au modèle retenu (figure 10).

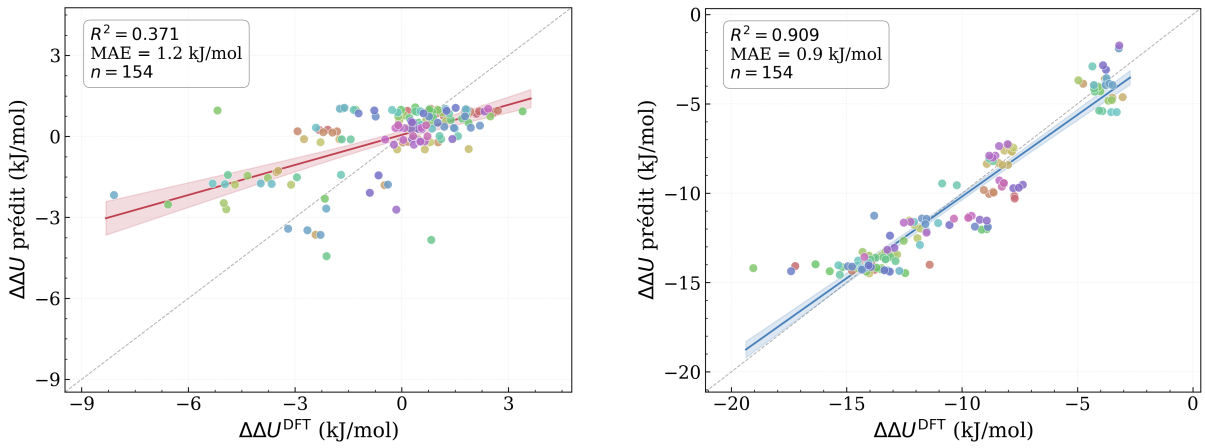
Le retour au neutre : la dureté. Nous voilà ramenés, une fois encore, au seul état neutre. Pour approcher le décalage de fréquences sans jamais calculer de fréquence ionique, la dureté chimique $\eta = (\mathrm{IP} - \mathrm{EA})/2$ s'est imposée presque d'elle-même : une molécule dure (grand gap) tient ses électrons fermement, ses liaisons encaissent l'ajout ou le retrait d'un électron avec peu de réorganisation vibrationnelle, et $|\Delta\Delta U|$ s'en trouve réduit. Et cette fois, contrairement à E_{relax} où il restait muet, le potentiel chimique μ a toute sa place : il suit l'ampleur de la redistribution de charge, celle-là même qui décale les fréquences. Avec la correction de Fukui :

$$\Delta\Delta U = \left(\theta_\mu\,\mu + \theta_\eta\,\eta\right)\left(1 + a\,f^2\right). \tag{9}$$

TABLE 8 – Coefficients du modèle $\Delta\Delta U$ (éq. 9), μ et η en eV. La même forme symétrique s'applique aux deux processus ; les coefficients, ε-constants, sont ajustés sur le jeu complet (1336 conformères, dix solvants) en validation croisée à 5 plis groupée par molécule. Le terme de Fukui de l'oxydation est déterminé sur l'ensemble des solvants, la seule tranche acétonitrile ($n = 154$) étant trop étroite pour le fixer sans surajustement.

	θ_μ	θ_η	a	**Fukui**
$\Delta\Delta U_{\mathrm{red}}$	−1.34	−3.49	−0.66	f^2_{max}
$\Delta\Delta U_{\mathrm{ox}}$	0.33	0.27	−6.57	f^2_{min}

En réduction, là où le signal est ample, le modèle tient ses promesses : MAE = 0.84 kJ/mol sur les dix solvants (0.87 en acétonitrile, $R^2 = 0.91$), la correction de Fukui apportant un gain net (−6%). En oxydation, $\Delta\Delta U$ est de très faible amplitude et de moyenne quasi nulle (−0.3(20) kJ/mol) : sur la seule tranche acétonitrile (154 conformères), la correction de Fukui manque de signal et surajuste, mais déterminée sur l'ensemble des dix solvants elle gagne autant qu'en réduction (1.16 kJ/mol à 1.09 kJ/mol, −6%, figure 10). Nous retenons donc la même forme symétrique des deux côtés, ses coefficients (table 8) étant ε-constants et ajustés sur le jeu complet. Au bilan, rester au neutre ne coûte que 0.18 kJ/mol de plus que le descripteur physique : un prix négligeable pour ne jamais ouvrir un Hessien ionique.



(a) Oxydation. (b) Réduction.

FIGURE 10 – Modèle $\Delta\Delta U$ retenu (éq. 9), descripteurs du seul état neutre, en validation croisée *vs* DFT. Points coloriés par molécule (68 molécules, 154 conformères).

3.5 Entropie $T\Delta S$

Reste le dernier terme, et le plus ingrat. L'entropie $T\Delta S = T[S(\text{ion}) - S(\text{neutre})]$, dominée par l'entropie vibrationnelle, est modeste et de signe variable : 1.4(30) kJ/mol en réduction, −1.7(34) kJ/mol en oxydation.

Le réflexe de l'entropie absolue. Le premier réflexe répète celui de $\Delta\Delta U$ et bute sur la même confusion entre une valeur et une différence. L'entropie vibrationnelle RRHO de l'état neutre[33], $S_{\text{vib}} = R\sum_k [u_k/(e^{u_k}-1) - \ln(1-e^{-u_k})]$ avec $u_k = \hbar\omega_k/k_BT$, mesure une entropie absolue qui suit surtout la taille de la molécule ; or $T\Delta S$ dépend de la manière dont les modes se réorganisent à l'ionisation. La corrélation est quasi nulle, comme attendu.

Le descripteur de $\Delta\Delta U$, ici inopérant. Nous avions pourtant un atout en main : ΔU_{RRHO}, le descripteur physiquement exact qui avait si bien fonctionné pour $\Delta\Delta U$ (corrélation 0.90, §3.4). Son pendant entropique, $\Delta(TS)_{\text{RRHO}} = TS^{\text{ion}}_{\text{vib}} - TS^{\text{neutre}}_{\text{vib}}$ évalué sur les mêmes fréquences verticales, devait logiquement transposer ce succès. Il n'en fut rien : la corrélation s'effondre à 0.22 en réduction, 0.10 en oxydation, et l'ajouter au modèle ne rapporte rien (−0.01 kJ/mol). Le revers est instructif. $\Delta\Delta U$ est une somme de $\frac{1}{2}\hbar\omega$: chaque mode y pèse selon sa fréquence, et ce sont les modes raides, bien décrits même verticalement, qui dominent. L'entropie, à l'inverse, est dominée par les modes mous ($< 200\,\text{cm}^{-1}$), précisément ceux que l'absence de relaxation ionique déforme le plus dans nos fréquences verticales. Le même proxy, fiable pour la ZPE, devient trompeur pour l'entropie.

Un plafond intrinsèque. Ce constat dépasse le seul $\Delta(TS)_{\text{RRHO}}$. $T\Delta S$ compare l'entropie de l'ion relaxé à celle du neutre, alors que toute notre information est lue sur la géométrie neutre : la part du signal qui réside dans la relaxation géométrique post-ionisation, l'essentiel, nous reste structurellement inaccessible. Nous l'avons vérifié jusqu'au bout. En perturbant les fréquences saines du neutre par la réponse de courbure $\partial k/\partial N$[35], plutôt qu'en diagonalisant le Hessien ionique vertical corrompu par ses modes imaginaires, la corrélation avec $T\Delta S_{\text{red}}$ bondit de 0.22 à 0.57 : nous avions bien visé la bonne physique. Mais ce descripteur, coûteux car requérant les Hessiens ioniques, reste redondant avec (μ, η) : les ∼33 % de variance qu'il explique sont précisément ceux que le couple frontière capte déjà, si bien que l'ajouter au modèle ne gagne que 0.03 kJ/mol. Les ∼67 % restants relèvent de la relaxation ionique, hors d'atteinte. Le plafond

n'est donc pas un défaut de descripteur : il est intrinsèque au paradigme « sans optimisation ionique ».

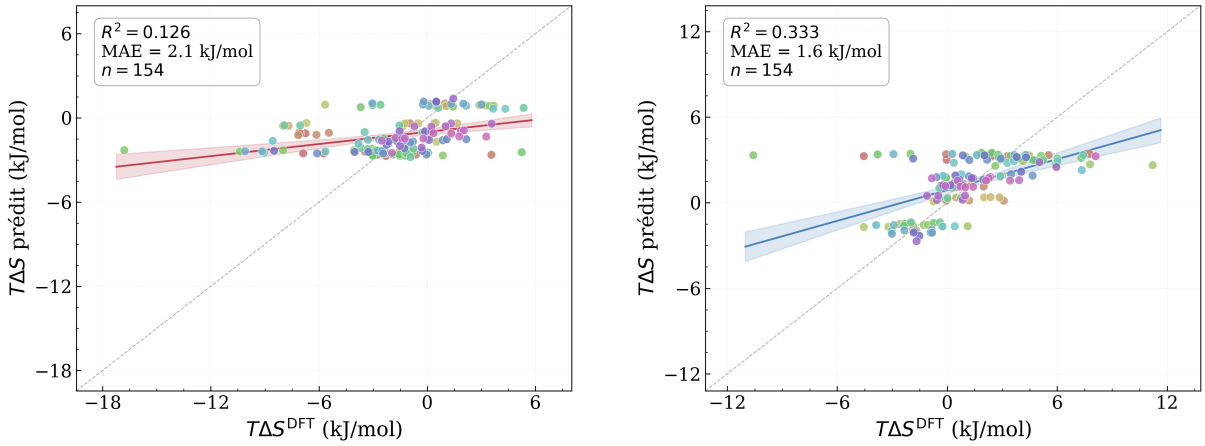
Le modèle retenu. Faute de mieux, nous nous en tenons au couple frontière (μ, η), en régression purement linéaire : ici la correction de Fukui ne se contente pas d'être marginale, elle nuit légèrement, et nous l'écartons.

$$T\Delta S = \theta_\mu \, \mu + \theta_\eta \, \eta. \tag{10}$$

TABLE 9 – Coefficients du modèle $T\Delta S$ (éq. 10), validation croisée à 5 plis groupée par molécule, μ et η en eV. C'est le plus parcimonieux des quatre modèles, avec deux descripteurs et aucune correction.

	θ_μ	θ_η
$T\Delta S_{\mathrm{red}}$	0.96	1.08
$T\Delta S_{\mathrm{ox}}$	−0.64	−0.78

Le modèle ne fait pas de miracle, mais il bat nettement la simple prédiction par la moyenne : MAE = 1.63 kJ/mol ($R^2 = 0.33$) en réduction contre 2.32 pour la constante (−30%), et 2.14 kJ/mol ($R^2 = 0.13$) en oxydation contre 2.47 (−13%, figure 11). Les R^2 trahissent le plafond plus que le modèle. $T\Delta S$ reste de toute façon un terme secondaire de ΔG° : son imprécision y pèse bien moins que celle d'EA/IP ou d'E_{relax}.



(a) Oxydation. (b) Réduction.

FIGURE 11 – Modèle $T\Delta S$ retenu (éq. 10), validation croisée *vs* DFT. Points coloriés par molécule (68 molécules, 154 conformères). La dispersion résiduelle reflète la composante de relaxation ionique, inaccessible depuis le seul état neutre.

3.6 Généralisation aux dix solvants

Tout ce qui précède a été établi dans un seul solvant, l'acétonitrile. Reste la question qui décide de l'utilité réelle du schéma : se transpose-t-il aux autres milieux ? Nous reprenons donc l'intégralité du jeu, soit 1336 conformères, 68 molécules et dix solvants couvrant deux ordres de grandeur de polarité, de l'hexane ($\varepsilon = 1.9$) à l'eau ($\varepsilon = 78.4$).

Le jeu de données et le cas de l'eau. Les cibles proviennent du pipeline redox DFT complet, les descripteurs du mode `predict-dg`, dans chacun des dix solvants COSMO. Trois filtres sont appliqués : les cinq molécules écartées du jeu d'analyse (DEA halogénés + L-DOPA, §3) ;

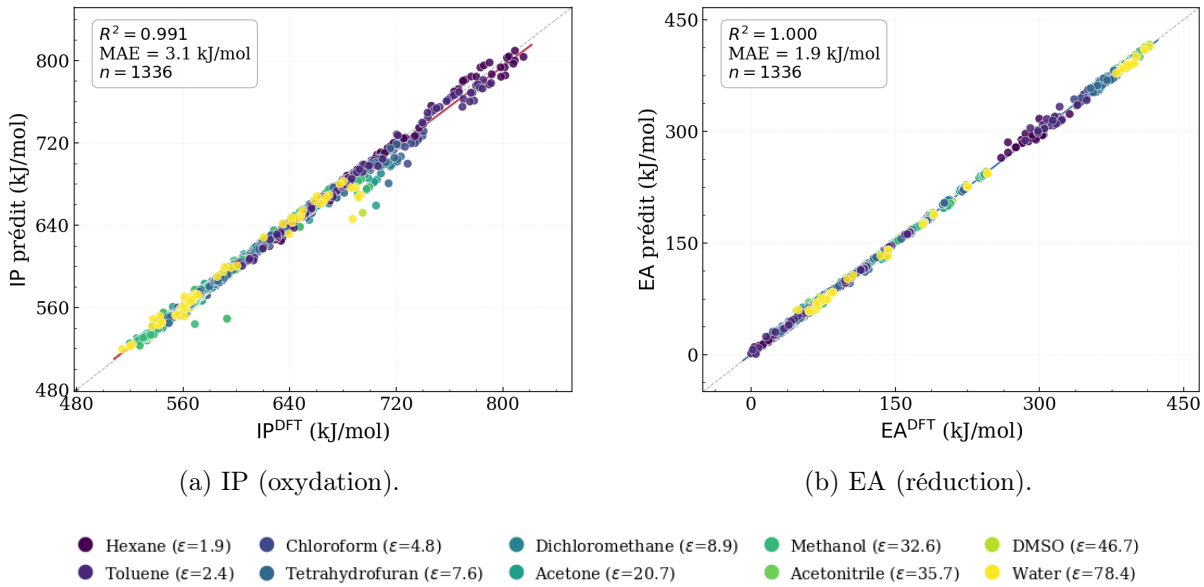
les conformères à EA verticale négative, où le solvant trop apolaire ne stabilise plus l'anion (essentiellement dans l'hexane) ; et, enfin, les calculs dans l'eau initialement corrompus. Un audit a révélé qu'environ 43 % des fichiers « Water » étaient en réalité des copies de leur homologue chloroforme (énergies identiques au bit près), vestige d'un mauvais routage lors de la récupération sur le cluster. Ces doublons ont été détectés (test d'égalité des énergies neutres) et retirés ; seuls les calculs aqueux authentiques sont conservés. Cette correction change la lecture de l'eau (voir plus bas) par rapport aux versions antérieures de ce travail.

Une dépendance au solvant, mais où ? Le solvant n'entre dans nos modèles que de deux façons. Implicitement, d'abord : tous les descripteurs (μ, η, LVC, Fukui) sont calculés en COSMO et portent donc déjà la marque du milieu. Explicitement, ensuite, si les coefficients eux-mêmes varient avec la constante diélectrique. Nous écrivons donc chaque coefficient comme une fonction de ε :

$$Y = \sum_X \beta_X(\varepsilon)\, X \times (1 + a\, f^2), \qquad g = \frac{\varepsilon - 1}{2\varepsilon + 1} \tag{11}$$

où la somme porte sur les deux ou trois descripteurs CDFT X propres à chaque terme (μ, η, et selon le cas ω^+, $1/\omega^-$ ou la LVC, c'est-à-dire ceux des modèles mono-solvant des sections précédentes, par ex. éq. 5, 10), le coefficient $\beta_X(\varepsilon)$ y remplaçant la constante θ_X. Le facteur $g = (\varepsilon - 1)/(2\varepsilon + 1)$ est le champ de réaction de Born (il sature à $1/2$ quand $\varepsilon \to \infty$, comme la solvatation continue elle-même). Pour chaque coefficient $\beta_X(\varepsilon)$ nous avons testé dix familles de fonctions, de la plus parcimonieuse (constante) aux formes saturantes physiquement motivées (linéaire en g, Onsager, Padé[1/1] et [2/1] en g) jusqu'aux formes purement empiriques (logarithme, exponentielle saturante, sigmoïde, tangente hyperbolique, loi de puissance), chacune ajustée par le même protocole que précédemment (objectif MAE, validation croisée à 5 plis groupée par molécule).

IP et EA : le solvant est décisif. Pour les deux énergies de transfert de charge, le solvant n'est pas un détail : à molécule fixée, l'IP se déplace de $\sim$38 kJ/mol et l'EA de $\sim$35 kJ/mol d'un solvant à l'autre. Sans dépendance explicite en ε, le modèle s'effondre : MAE 21.7 (IP) et 22.3 kJ/mol (EA). Le balayage exhaustif (tableau 10) confirme qu'une forme saturante est indispensable, et que toutes se valent à 0.05 kJ/mol près au sommet du classement : puissance, Padé[2/1] et Padé[1/1] sont statistiquement indiscernables. À égalité numérique, nous retenons le Padé[1/1]-Born $\beta_X(\varepsilon) = (a_0 + a_1 g)/(1 + b_1 g)$, pour sa motivation physique : il reproduit exactement la saturation du champ de réaction diélectrique, là où la loi de puissance ou le logarithme n'ont aucun ancrage. Une fois cette correction appliquée, les dix solvants se rabattent sur la diagonale (figure 12, MAE 1.9 pour l'EA et 3.1 kJ/mol pour l'IP) ; les familles non saturantes (logarithme surtout, MAE $\sim$9 kJ/mol) restent nettement distancées.



(a) IP (oxydation). (b) EA (réduction).

FIGURE 12 – IP et EA verticaux prédits sur les dix solvants par le modèle CDFT à correction Padé[1/1]-Born (validation croisée *vs* DFT, $n = 1336$; mêmes panneaux qu'au §3.2, mais points coloriés par *solvant*). La correction en ε rabat tous les solvants sur la diagonale (MAE 3.1 pour l'IP, 1.9 kJ/mol pour l'EA) ; à coefficients constants, la MAE atteindrait 21 kJ/mol à 22 kJ/mol.

(a) IP vertical (oxydation)

Famille	MAE kJ/mol	RMSE kJ/mol	R^2	n_{par}	AIC
Puissance	3.1	5.5	0.991	10	4575
Padé[2/1]-Born	3.1	5.5	0.991	13	4600
Padé[1/1]-Born ⋆	3.1	5.5	0.991	10	4594
Linéaire-Born	3.2	5.7	0.991	7	4649
Exp. saturante	3.6	6.1	0.990	10	4833
Sigmoïde	3.9	6.5	0.988	13	5008
Onsager-linéaire	5.1	7.9	0.982	7	5528
Tanh	6.6	10.7	0.967	13	6367
Logarithme	9.8	15.1	0.936	7	7260
Constante	21.7	32.4	0.703	4	9301

(b) EA verticale (réduction)

Famille	MAE kJ/mol	RMSE kJ/mol	R^2	n_{par}	AIC
Puissance	1.9	2.6	1.000	10	2616
Padé[2/1]-Born	1.9	2.7	1.000	13	2639
Padé[1/1]-Born ⋆	1.9	2.7	1.000	10	2669
Linéaire-Born	2.2	3.0	0.999	7	2954
Exp. saturante	2.3	3.1	0.999	10	3023
Sigmoïde	2.8	4.0	0.999	13	3719
Tanh	2.8	4.2	0.999	13	3865
Onsager-linéaire	4.2	6.0	0.998	7	4794
Logarithme	9.3	15.1	0.985	7	7270
Constante	22.3	33.6	0.925	4	9398

TABLE 10 – Screen des 10 familles de correction de solvant pour l'IP et l'EA verticaux ($n = 1336$), classées par MAE croissante. ⋆ : famille retenue (Padé[1/1]-Born, physiquement motivée). MAE et RMSE en kJ/mol.

La supériorité des formes saturantes a un sens physique limpide : $\beta_X(\varepsilon) = (a_0 + a_1 g)/(1 + b_1 g)$ tend vers une asymptote finie a_1/b_1 quand $\varepsilon \to \infty$, exactement comme la stabilisation continue d'une charge plafonne une fois le solvant suffisamment polaire. Le logarithme et la puissance non bornée, qui ne saturent pas, paient cette infidélité physique aux grands ε.

Les termes intramoléculaires : le solvant n'agit qu'implicitement. Pour E_{relax}, $\Delta\Delta U$ et $T\Delta S$, le constat est inverse et tout aussi net. À molécule fixée, changer de solvant ne déplace ces termes que de 0.3 kJ/mol à 1.3 kJ/mol, trente à cinquante fois moins que pour IP/EA, et bien en deçà de la barre DFT. Le balayage le confirme : aucune famille ne bat la constante de plus de 0.05 kJ/mol sur les six cibles. La dépendance solvant n'est pas rigoureusement nulle (elle compte par exemple pour ∼20–45 % de la variance, déjà faible, de $T\Delta S$), mais ce qu'il en reste est déjà

porté implicitement par les descripteurs calculés en COSMO : le résidu en ε après le modèle constant est ténu ($|r| \lesssim 0.18$). Paramétrer ε explicitement par-dessus n'apporterait donc rien sous le bruit. Nous gardons des coefficients constants pour ces trois termes, ce qui est cohérent avec leur nature intramoléculaire : c'est la réorganisation de l'ion, pas le champ du solvant, qui les fixe.

TABLE 11 – Bilan multi-solvant par composante : forme de dépendance en ε retenue et MAE en validation croisée ($n = 1336$, dix solvants). MAE en kJ/mol.

Composante	**Dépendance en ε**	**MAE (ox)**	**MAE (red)**
EA / IP	Padé[1/1]-Born	3.14	1.92
E_{relax}	constante	3.14	2.58
$\Delta\Delta U$	constante	1.09	0.84
$T\Delta S$	constante	1.87	1.42

3.7 Prédiction combinée de ΔG°

Il reste à assembler les quatre pièces. Chacune prédite depuis le seul état neutre, ΔG° se reconstitue par sa décomposition thermodynamique :

$$\Delta G_{\mathrm{ox}} = \mathrm{IP} + E_{\mathrm{relax}}^{\mathrm{ox}} + \Delta\Delta U_{\mathrm{ox}} - T\Delta S_{\mathrm{ox}} \tag{12}$$

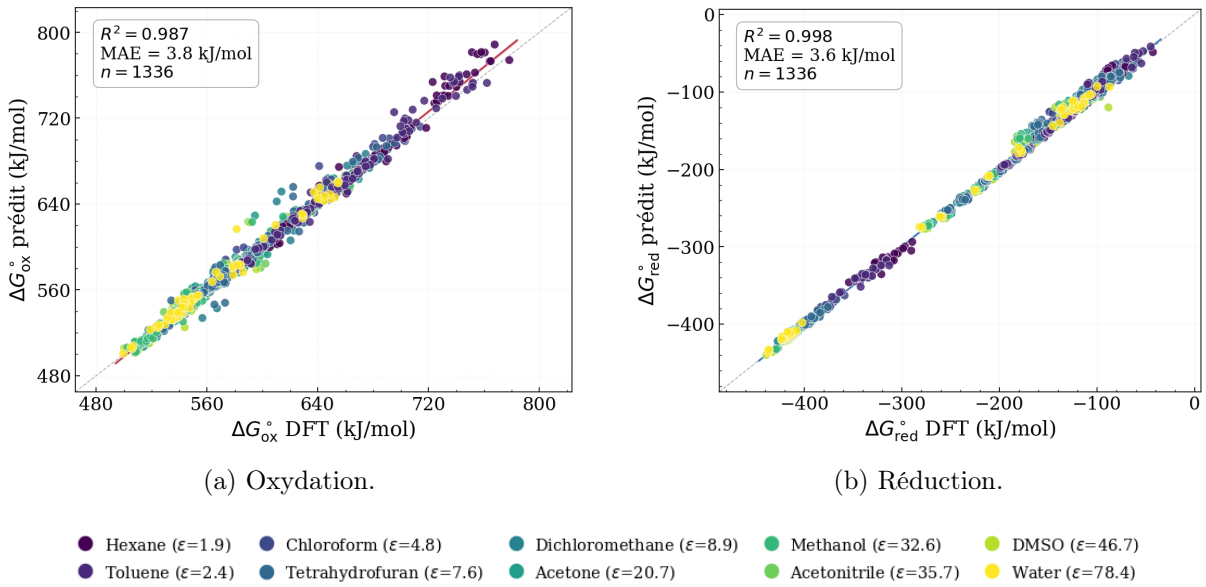
$$\Delta G_{\mathrm{red}} = -\mathrm{EA} + E_{\mathrm{relax}}^{\mathrm{red}} + \Delta\Delta U_{\mathrm{red}} - T\Delta S_{\mathrm{red}} \tag{13}$$

sans qu'aucune géométrie ionique n'ait été optimisée. Nous l'évaluons d'abord sur notre solvant de référence, l'acétonitrile, puis sur les dix solvants ; le tableau 12 compare les deux, composante par composante.

TABLE 12 – Précision par composante, de l'acétonitrile seul aux dix solvants (MAE en validation croisée à 5 plis groupée par molécule, kJ/mol). La généralisation préserve l'ordre de précision. Pour EA/IP, le passage au multi-solvant inclut la correction de solvant Padé[1/1]-Born (§3.6) ; les trois termes intramoléculaires gardent des coefficients constants.

		Acétonitrile ($n = 154$)		**Dix solvants** ($n = 1336$)	
Composante	**Modèle**	ox	red	ox	red
EA / IP	CDFT $(\mu, \eta, X_3) \times (1 + a\,f^2)$	2.94	1.91	3.14	1.92
E_{relax}	$(\eta, \mathrm{LVC}) \times (1 + a\,f^2)$	2.45	2.53	3.14	2.58
$\Delta\Delta U$	$(\mu, \eta) \times (1 + a\,f^2)$	1.18	0.87	1.09	0.84
$T\Delta S$	(μ, η) linéaire	2.14	1.63	1.87	1.42
ΔG°	**Combiné**	**3.61**	**3.65**	**3.84**	**3.59**

Résultat. Sur l'acétonitrile, ΔG° est reconstruit à 3.61 (ox) et 3.65 kJ/mol (red). Surtout, et c'est ce qui valide la démarche, l'assemblage des modèles de composantes multi-solvant tient sur les dix solvants avec la même précision : MAE 3.84 kJ/mol ($R^2 = 0.99$) en oxydation et 3.59 kJ/mol ($R^2 = 1.00$) en réduction (figure 13, tableau 12). Dans les deux cas, ΔG° est reconstitué sous la barre des 4 kJ/mol à 8 kJ/mol de la DFT elle-même (§3.1), à partir de simples single points sur la géométrie neutre et sur tout l'éventail de polarité. C'est de surcroît un net progrès sur l'approche antérieure de ce travail (5.7 kJ/mol à 6.0 kJ/mol), gagné en corrigeant les formes des composantes plutôt qu'en complexifiant la dépendance solvant.



(a) Oxydation. (b) Réduction.

FIGURE 13 – Prédiction combinée de $\Delta G°$ sur les dix solvants (validation croisée *vs* DFT, $n = 1336$), reconstruite par sommation des quatre composantes prédites. Points coloriés par solvant (violet = apolaire, jaune = polaire) ; diagonale $y = x$ en pointillés.

Une qualité homogène, sauf en milieu apolaire. La décomposition par solvant (figure 14) est rassurante : sur huit des dix solvants, la MAE se tient entre 3.2 kJ/mol à 3.8 kJ/mol, sans tendance avec la polarité. Le seul écart notable est l'oxydation en milieu apolaire (hexane, MAE 6.9 ; toluène, 4.8 kJ/mol) : là, le cation est mal stabilisé et les conformères, plus rares, peuplent peu le bas de la courbe de Born. C'est le point dur du schéma, et il est physiquement sensé. L'eau ($\varepsilon = 78.4$), elle, se prédit normalement (MAE 3.7 kJ/mol), alors qu'elle était soupçonnée d'être le cas-limite du COSMO : les ∼18 kJ/mol rapportés dans nos versions antérieures n'étaient pas une limite physique du modèle continu, mais l'artefact des données aqueuses corrompues (§3.6). Une fois ces données purgées, l'eau ne se distingue plus des autres solvants.

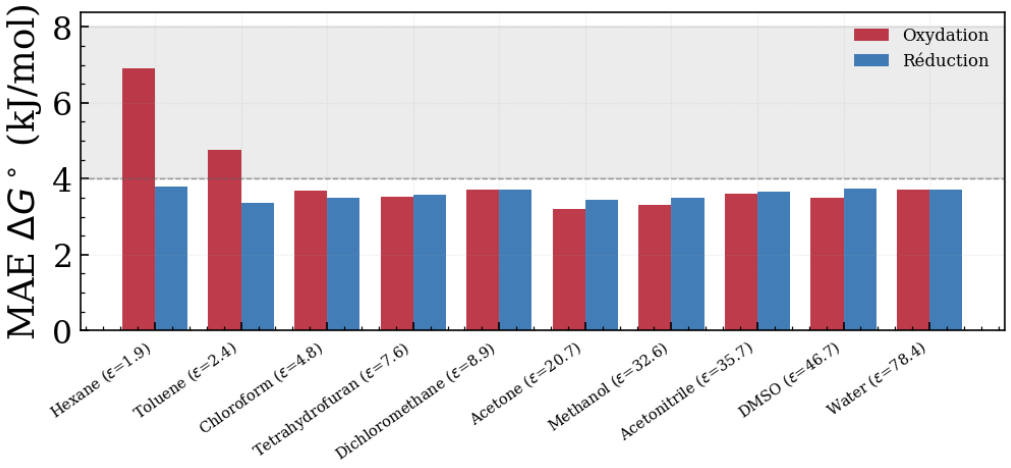


FIGURE 14 – MAE de $\Delta G°$ par solvant (oxydation en rouge, réduction en bleu), solvants rangés par ε croissant. La bande grise marque la barre d'erreur intrinsèque de la DFT (4 kJ/mol à 8 kJ/mol). L'eau ($\varepsilon = 78.4$) est dans la norme ; le cas le plus difficile est l'oxydation en milieu apolaire (hexane, toluène).

Budget d'erreur. La somme bénéficie d'une compensation partielle des erreurs de composantes. Les contributions dominantes restent EA/IP (2.9 ox, 1.9 red) et E_{relax} ($\sim$2.5 sur les deux processus) ; $\Delta\Delta U$ et $T\Delta S$, plus petits et déjà bien maîtrisés, ne pèsent qu'à la marge. Rien d'étonnant : c'est exactement la hiérarchie du tableau 4, et c'est là que nous avions porté l'effort de modélisation.

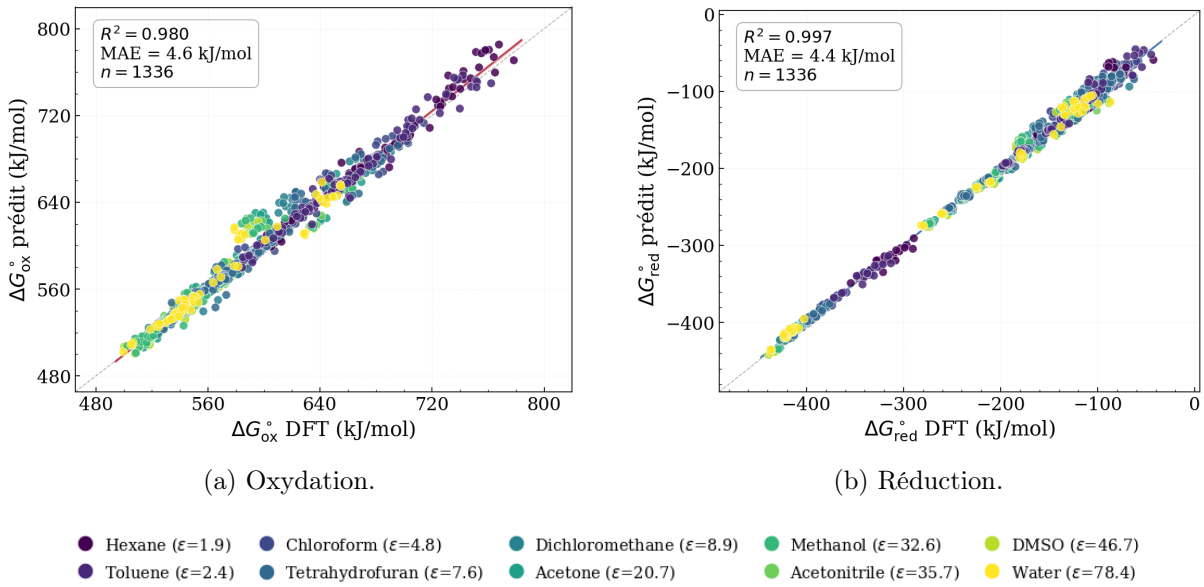
Quand se fier à la prédiction. La fiabilité n'est pas uniforme, et il faut être précis sur ce qui permet, ou non, de l'anticiper. Les erreurs résiduelles les plus grandes se concentrent sur les molécules à forte réorganisation structurale (la famille DOPA en tête), celles précisément où la relaxation géométrique post-ionisation, que nous ne calculons pas, est la plus marquée. Le déplacement structural (RMSD neutre→ion, §3.3) en porte effectivement la trace : il corrèle avec l'erreur sur ΔG ($r = 0.57$ en réduction). Mais il ne peut servir de critère de confiance au moment du criblage : le calculer exige précisément la géométrie ionique optimisée que le mode `predict-dg` cherche à éviter. C'est un diagnostic rétrospectif, utile pour valider la méthode sur un jeu de référence, non un filtre *a priori*.

Reste-t-il un signal disponible avant tout calcul ionique ? Nous avons passé en revue les descripteurs de l'état neutre (énergies orbitalaires frontière, indices de DFT conceptuelle, amplitude de E_{relax} prédite via notre descripteur LVC) : aucun ne dépasse une corrélation ténue avec l'erreur ($|r| \lesssim 0.3$, corrélation de rang plus faible encore). Il n'existe donc pas, à notre niveau, d'indicateur de confiance fiable conformère par conformère, et c'est cohérent : l'erreur résiduelle réside dans la relaxation géométrique de l'ion, par construction absente de tout descripteur du seul état neutre (la même raison qui empêche μ de prédire E_{relax}, §3.3). La confiance se juge donc plutôt à l'échelle de la famille chimique, identifiable dès le SMILES d'entrée : les familles fortement réorganisantes (catécholamines) appellent une vérification ponctuelle par le calcul complet, tandis que la garantie opérationnelle pour le criblage de masse reste statistique : une MAE globale sous la barre d'erreur de la DFT (§3.1).

Jusqu'où peut-on descendre en coût ? Le mode `predict-dg` admet un palier encore plus économe : ne calculer que le single point neutre, sans aucun état ionique, pas même les gradients. On ne perd alors qu'un seul descripteur, la LVC (qui, elle, exige les gradients ioniques) ; tous les autres (μ, η, $\omega^{\pm}$, fonctions de Fukui) se déduisent des seules orbitales et densités du neutre. Conséquence : seul E_{relax} en pâtit (il retombe sur sa forme frontière sans terme vibronique, $(\eta) \times (1 + a\, f^2)$), tandis qu'EA, IP, $\Delta\Delta U$ et $T\Delta S$ restent inchangés. Le tableau 13 chiffre le compromis : E_{relax} se dégrade nettement (de 3.1/2.6 à 4.6/3.9 kJ/mol), et ΔG° monte à 4.57 (ox) et 4.38 kJ/mol (red), au niveau du haut de la barre DFT (figure 15). C'est le prix d'un criblage à un seul calcul par conformère : une prédiction encore utile pour un premier tri grossier, qu'un calcul à trois SP affine ensuite sur les candidats retenus.

TABLE 13 – Compromis coût/précision entre les deux paliers du mode `predict-dg` (dix solvants, $n = 1336$, MAE en kJ/mol). Le palier « 1 SP neutre » ne calcule aucun état ionique ; seul E_{relax}, privé de la LVC, en souffre.

	3 SP (neutre + 2 ions)		**1 SP** (neutre seul)	
	ox	red	ox	red
E_{relax}	3.14	2.58	4.57	3.87
ΔG°	**3.84**	**3.59**	**4.57**	**4.38**



(a) Oxydation. (b) Réduction.

FIGURE 15 – Prédiction de $\Delta G°$ au palier le plus économique : un seul SP neutre, sans aucun calcul ionique (dix solvants, $n = 1336$, couleur = solvant). E_{relax} y est prédit sans la LVC. À comparer avec la figure 13 (trois SP).

Bilan. Le protocole tient sa promesse : à partir des trois single points du mode `predict-dg` (un seul portant les modes normaux, sur l'état neutre ; les deux ions en gradient seul), sans la moindre optimisation ionique, $\Delta G°$ est prédit à 3.6 kJ/mol à 3.8 kJ/mol dans les dix solvants, sous la barre DFT, pour un coût réduit d'environ un ordre de grandeur. C'est cette économie, doublée d'une transférabilité sur tout l'éventail de polarité, qui rend envisageable le criblage de milliers de candidats, sans le biais d'une présélection par l'intuition chimique.

4 Apprentissage automatique pour la prédiction de $\Delta G°$

La partie 3 a développé des modèles paramétriques — régressions calibrées par descripteur, puis correction de solvant par approximants de Padé — fondés sur des descripteurs physiques soigneusement sélectionnés (DFT conceptuelle μ et η, couplage vibronique LVC, fonctions de Fukui). Cette section présente une approche complémentaire, fondée sur des modèles d'apprentissage automatique entraînés directement à partir de représentations moléculaires plus brutes. Deux familles ont été explorées :

— l'**apprentissage classique** sur descripteurs tabulaires (forêts aléatoires, gradient boosting, machines à vecteurs de support), qui s'appuie sur une vectorisation *a priori* de chaque conformère ;
— les **réseaux de neurones de graphes géométriques** (SchNet, DimeNet, GemNet, MACE), qui traitent directement la structure 3D du conformère sans passer par un jeu fixe de descripteurs.

L'objectif n'est pas de remplacer le modèle physique — dont l'interprétabilité et la parcimonie restent des atouts majeurs — mais de tester si des modèles non linéaires de plus en plus expressifs peuvent réduire l'erreur résiduelle, en particulier sur les termes vibroniques (E_{relax}, $T\Delta S$) mal prédits par les approximants de Padé. Chaque famille est d'abord présentée dans son principe, puis confrontée aux mêmes cibles (EA, IP, $E_{\text{relax}}^{\text{red/ox}}$, $\Delta\Delta U^{\text{red/ox}}$, $T\Delta S^{\text{red/ox}}$, $\Delta G^{\text{red/ox}}$) et au même jeu de données multi-solvant.

4.1 Apprentissage classique sur descripteurs tabulaires

Les méthodes d'apprentissage classique constituent la première ligne de référence. Elles traitent chaque conformère comme un vecteur de caractéristiques de dimension fixe, construit à partir des grandeurs extraites des fichiers de sortie DFT. Ne requérant ni GPU ni connaissance explicite de la structure moléculaire 3D, elles servent de garde-fou pour quantifier le gain réel qu'apporteraient les modèles géométriques plus coûteux de la section 4.2.

Descripteurs. Un vecteur de 51 descripteurs est construit par conformère. Il agrège :

- **descripteurs globaux** : énergies orbitalaires $\varepsilon_{\text{HOMO}}$, $\varepsilon_{\text{LUMO}}$, gap, norme du moment dipolaire, composition atomique (comptes par élément), fractions d'oxygène et d'azote, électronégativité moyenne et écart-type ;
- **descripteurs agrégés par atome** : statistiques (moyenne, écart-type, min, max, étendue) des charges Hirshfeld, Mulliken et Voronoi, de la densité électronique et du potentiel électrostatique aux noyaux ;
- **descripteurs géométriques** : rayon de giration, extension maximale, statistiques des distances entre atomes lourds ;
- **descripteurs de solvant** : constante diélectrique ε_r ;
- **descripteurs vibroniques** : $E_{\text{relax}}^{\text{LVC2}}$ (réduction et oxydation) issus du pipeline predict-dg.

Le vecteur complet est standardisé (z-score) sur le jeu d'entraînement uniquement.

Modèles testés. Trois algorithmes couvrant les principaux paradigmes de l'apprentissage tabulaire ont été évalués :

- **Random Forest (RF)**[7] : ensemble d'arbres de décision construits par bagging et tirage aléatoire des descripteurs à chaque scission. Robuste au sur-apprentissage, multi-sortie natif, il fournit une mesure d'importance des descripteurs utilisable pour valider *a posteriori* les choix de la section 3.6.
- **Gradient Boosting (GB)**[8] : ensemble d'arbres construits séquentiellement, chaque nouvel arbre corrigeant les résidus du modèle accumulé. L'implémentation retenue est XGBoost, exécutée sur GPU (CUDA, via l'API `device=cuda` de XGBoost ≥ 2.0) pour bénéficier de la vectorisation des évaluations de candidats de découpe.
- **Support Vector Regression (SVR)**[9] : régression à noyau, qui projette implicitement les descripteurs dans un espace de grande dimension et recherche une fonction ε-tolérante aux écarts. Le noyau (RBF, linéaire, polynomial) est traité comme un hyperparamètre à régler.

Jeu de données. Les douze cibles (EA, IP, $E_{\text{relax}}^{\text{red/ox}}$, $\Delta\Delta U^{\text{red/ox}}$, $T\Delta S^{\text{red/ox}}$, résidus, $\Delta G^{\text{red/ox}}$) sont extraites des champs `derived` du dataset PlamsV5 (workflow DFT complet). Les descripteurs LVC2 proviennent du workflow predict-dg. Après exclusion des conformères dont la décomposition DFT n'a pas convergé (DEA halogénés non stabilisés et états ioniques manquants), le jeu contient **1682 conformères** couvrant **73 molécules distinctes** dans 10 solvants, en accord strict avec la liste source (`input.txt`). Contrairement à la section 3.6 qui filtre également les conformères à EA verticale négative ($n = 1336$), les baselines ML voient l'ensemble du jeu sans cette restriction : les modèles sont laissés libres d'apprendre la transition vers les régimes EA<0 (essentiellement dans l'hexane).

Stratégie d'évaluation. Une validation croisée 5-fold *mol-aware* (`GroupKFold` sur le nom de molécule) est appliquée, strictement identique au protocole utilisé pour les GNN, afin de garantir l'absence de fuite inter-solvant. Les hyperparamètres sont optimisés par Optuna (`TPESampler` multivarié + `MedianPruner`) avec 80 essais pour RF, 150 pour XGBoost et 80 pour SVR. Chaque essai est évalué sur les cinq plis *mol-aware* ; les essais clairement dominés sont élagués dès le

premier pli. Optuna est préféré à une recherche sur grille car la plupart des hyperparamètres sont continus (`learning_rate`, `C`, `reg_alpha`, …) et TPE atteint des valeurs comparables en ∼100 essais là où une grille exhaustive en demanderait plusieurs milliers. Les métriques rapportées sont la MAE, la RMSE et le R^2 out-of-fold, exprimés en kJ/mol.

Résultats. Le tableau 14 détaille la MAE par cible pour les trois modèles, et la figure 16 en fournit la vue synoptique. XGBoost remporte la comparaison avec une MAE moyenne sur les composantes de 9.9 kJ/mol et une MAE moyenne sur les deux énergies libres ΔG de 9.9 kJ/mol, soit un gain de ∼19% sur Random Forest (12.1 kJ/mol composantes, 12.3 kJ/mol sur ΔG) et d'un facteur 2,3 sur SVR (16.8 kJ/mol composantes, 22.6 kJ/mol sur ΔG). Sur la prédiction directe de ΔG_{ox}, XGBoost atteint MAE = 6.8 kJ/mol et $R^2 = 0{,}935$ — mais reste *en deçà* du modèle physique combiné (§3.7, MAE = 3.8 kJ/mol sur les mêmes dix solvants). Le modèle paramétrique guidé par la physique surpasse donc nettement ces baselines d'apprentissage générique sur descripteurs agrégés.

TABLE 14 – MAE par cible (kJ/mol) des trois baselines ML classiques (5-fold mol-aware, $n = 1682$, 73 molécules distinctes). La colonne *Meilleur* indique le modèle vainqueur par cible ; R^2 reporté pour le meilleur modèle.

Cible	RF	XGBoost	SVR	Meilleur	R^2_{meilleur}
EA	16,9	**15,6**	17,7	XGBoost	0,939
IP	16,0	**9,8**	18,1	XGBoost	0,945
$E^{\mathrm{red}}_{\mathrm{relax}}$	18,5	**17,7**	17,6	SVR	0,314
$E^{\mathrm{ox}}_{\mathrm{relax}}$	13,7	10,0	**7,4**	SVR	0,770
$\Delta\Delta U_{\mathrm{red}}$	15,1	**14,3**	27,4	XGBoost	0,957
$\Delta\Delta U_{\mathrm{ox}}$	12,1	**7,2**	18,8	XGBoost	0,922
$T\Delta S_{\mathrm{red}}$	1,6	**1,7**	2,1	RF	0,480
$T\Delta S_{\mathrm{ox}}$	**1,8**	2,1	1,9	RF	0,166
résidu red	14,2	**13,6**	26,6	XGBoost	0,956
résidu ox	11,1	**6,7**	18,2	XGBoost	0,931
ΔG_{red}	13,8	**13,0**	27,0	XGBoost	0,956
ΔG_{ox}	10,8	**6,8**	18,2	XGBoost	0,935
MAE moyenne (12 cibles)	12,1	**9,9**	16,8	XGBoost	—
MAE moyenne ΔG	12,3	**9,9**	22,6	XGBoost	—
R^2 moyen (12 cibles)	0,726	**0,741**	0,659	XGBoost	—

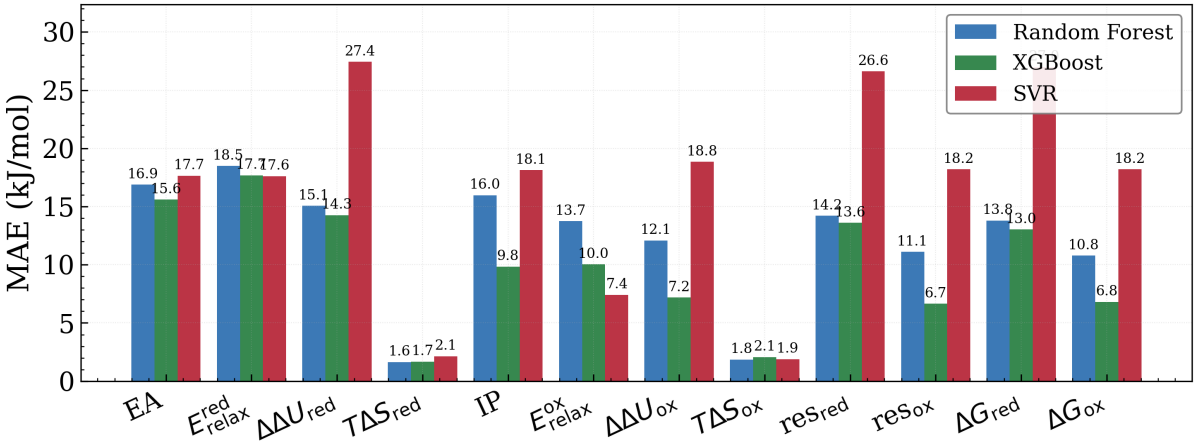


FIGURE 16 – MAE par cible (kJ/mol) pour les trois baselines classiques ($n = 1682$, 73 molécules). XGBoost domine sur les cibles structurantes (EA, IP, $\Delta\Delta U$, ΔG_{red}, ΔG_{ox}, résidus) ; SVR domine sur les E_{relax} grâce au LVC2 injecté en descripteur ; Random Forest reste compétitif sur $T\Delta S$.

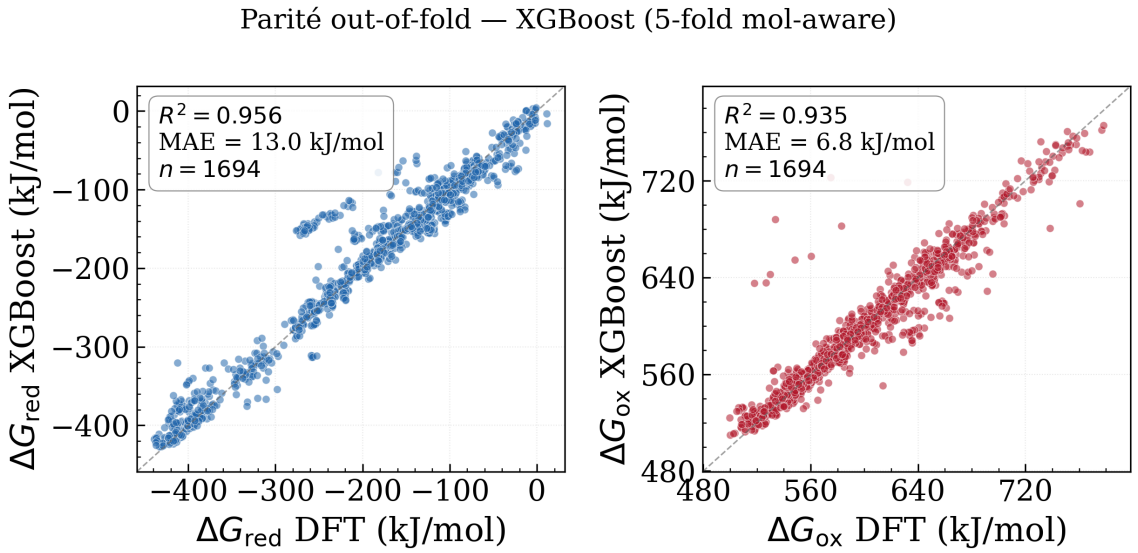


FIGURE 17 – Parité out-of-fold pour ΔG_{red} (gauche, $R^2 = 0{,}956$) et ΔG_{ox} (droite, $R^2 = 0{,}935$) du meilleur modèle classique, XGBoost, sur 1682 conformères (5 folds mol-aware agrégés).

Hyperparamètres retenus. Le tableau 15 récapitule les meilleurs hyperparamètres sélectionnés par Optuna. La configuration retenue de **SVR est linéaire** (`kernel = linear`, $C = 53{,}1$, $\varepsilon = 0{,}007$), alors que les noyaux RBF et polynomial étaient dans l'espace de recherche. Cela indique qu'une fois les descripteurs DFT standardisés, la relation entre ces descripteurs et les cibles est essentiellement linéaire ; la non-linéarité restante est mieux capturée par la partition récursive des modèles à arbres que par un noyau RBF global. Pour **XGBoost**, la configuration sélectionnée est profondément régularisée : profondeur faible (max_depth = 4), taux d'apprentissage bas ($\eta = 2{,}3 \cdot 10^{-2}$), 1300 arbres. Ce régime « petits pas, petits arbres » maximise le biais local au profit de la variance, choix cohérent avec la taille modeste du jeu (∼1700 observations).

TABLE 15 – Meilleurs hyperparamètres (Optuna TPE, 5-fold mol-aware).

Modèle	Hyperparamètres retenus
Random Forest	`n_estimators`=400, `max_depth`=20, `max_features`=0,70, `min_samples_leaf`=3, `min_samples_split`=5
XGBoost	`n_estimators`=1300, `max_depth`=4, η=0,023, `subsample`=0,73, `colsample_bytree`=1,00, `reg_lambda`=2,14, `min_child_weight`=6,1
SVR	`kernel`=linéaire, C=53,1, ε=0,007

Discussion. Trois observations structurent l'interprétation :

— **XGBoost reste loin du modèle physique sur** ΔG : 9.9 kJ/mol vs ∼3.7 kJ/mol pour le modèle physique combiné. L'écart est en partie imputable aux neuf molécules *out-of-distribution* (DHI, IQ, NDGA) incluses dans les baselines et filtrées en amont du modèle physique, ainsi qu'à l'absence de contrainte Born–Haber dans le modèle ML. Le boosting bénéficie directement de l'injection de $E_{\text{relax}}^{\text{LVC2}}$ comme descripteur : il réduit la MAE sur $E_{\text{relax}}^{\text{ox}}$ à 10.0 kJ/mol et permet au Random Forest d'atteindre une précision proche.

— **SVR domine sur les termes de relaxation**, avec MAE = 7.4 kJ/mol sur $E_{\text{relax}}^{\text{ox}}$ et 17.6 kJ/mol sur $E_{\text{relax}}^{\text{red}}$, grâce à l'intégration quasi-directe du LVC2 que le noyau linéaire exploite sans déformation. En revanche, il s'effondre sur les termes plus non linéaires (résidus, $\Delta\Delta U_{\text{red}}$, ΔG) où il ne capture pas la dépendance en solvant.

— **Les termes entropiques restent réfractaires** pour les trois modèles : $R^2 \leq 0{,}48$ sur

$T\Delta S_{\text{red}}$, $R^2 \leq 0{,}17$ sur $T\Delta S_{\text{ox}}$. Leur écart-type ($\sim$3 kJ/mol) est comparable au bruit d'entraînement, et les descripteurs globaux agrégés ne contiennent pas suffisamment d'information sur la distribution des fréquences vibrationnelles pour résoudre ce signal. Ce constat est cohérent avec celui du modèle physique (section 3.6), où $T\Delta S$ sature autour de $R^2 \approx 0{,}45$ quel que soit le choix des descripteurs μ, η.

Importance des descripteurs (RF). L'analyse d'importance `feature_importances_` sur le Random Forest confirme les intuitions physiques : les cinq descripteurs les plus importants sont, dans l'ordre, $\varepsilon_{\text{LUMO}}$, $\varepsilon_{\text{HOMO}}$, $E_{\text{relax}}^{\text{LVC2,ox}}$, $E_{\text{relax}}^{\text{LVC2,red}}$, et la constante diélectrique du solvant ε_r. Les autres descripteurs agrégés (statistiques de charges, géométrie) contribuent individuellement pour moins de 3% de l'importance totale. Cette hiérarchie valide *a posteriori* le choix des descripteurs manuels de la section 3.6 et suggère qu'un modèle parcimonieux limité à ces cinq features pourrait capter l'essentiel du signal accessible.

Conclusion intermédiaire. Sans optimisation ionique DFT et avec un modèle entraîné en $\sim$3 heures sur un seul GPU A100, XGBoost atteint une précision globale de 9.9 kJ/mol sur ΔG, démontrant qu'un prédicteur tabulaire exploitant des descripteurs DFT soigneusement choisis constitue une baseline solide pour le criblage de molécules redox-actives. La comparaison avec les modèles géométriques, plus ambitieux, fait l'objet de la section suivante.

4.2 Réseaux de neurones de graphes géométriques

Les modèles précédents reposent sur un choix *a priori* de descripteurs. Les réseaux de neurones de graphes (GNN) géométriques suppriment cette étape : ils apprennent eux-mêmes une représentation vectorielle par atome à partir de la structure 3D du conformère, via un schéma de passage de messages (*message passing*) sur le graphe des voisins géométriques. Cette section présente brièvement les quatre architectures successives qui jalonnent l'état de l'art — SchNet, DimeNet, GemNet, MACE — avant de détailler le modèle retenu pour notre cas d'application.

Principe commun. Un GNN géométrique construit pour chaque atome i un plongement $h_i \in \mathbb{R}^d$, mis à jour itérativement par agrégation des messages reçus des voisins j situés dans un rayon r_c autour de i :

$$h_i^{(t+1)} = \phi\left(h_i^{(t)}, \sum_{j \in \mathcal{N}(i)} m(h_j^{(t)}, \mathbf{r}_{ij})\right) \tag{14}$$

où $\mathbf{r}_{ij} = \mathbf{r}_j - \mathbf{r}_i$ est le vecteur relatif et m une fonction de message. Les architectures diffèrent par l'information géométrique injectée dans m (distance seule, distance + angle, distance + angle + dièdre) et par la manière dont les symétries du groupe euclidien $E(3)$ sont respectées.

4.2.1 Architectures historiques : SchNet, DimeNet, GemNet

Trois architectures successives jalonnent la montée en précision des GNN géométriques avant MACE. Chacune enrichit l'information géométrique injectée dans la fonction de message (14), d'où une complexité croissante.

SchNet[10]. Premier GNN géométrique largement diffusé. Le message ne dépend que de la distance $\|\mathbf{r}_{ij}\|$, développée sur une base de fonctions radiales gaussiennes, puis transformée par une *continuous-filter convolution* (filtre à poids continus $\mathbf{W}(\|\mathbf{r}_{ij}\|)$). L'architecture est strictement invariante par rotation mais ignore toute information angulaire : deux géométries de même graphe de distances produisent des plongements identiques. SchNet fournit donc la référence minimale « apprendre depuis la géométrie 3D sans descripteurs chimiques ajoutés ».

DimeNet[11]. Extension de SchNet qui incorpore les angles θ_{ijk} entre triplets d'atomes (i, j, k) via des fonctions de Bessel sphériques (*directional message passing*). Le message ne transite plus seulement entre atomes mais entre arêtes orientées, ce qui permet de conditionner la propagation sur la direction locale. L'information angulaire rompt la dégénérescence des environnements isomorphes en distances et améliore significativement la prédiction des énergies et des forces sur les jeux QM9 / MD17.

GemNet[12]. Ajoute aux distances et angles les *dièdres* φ_{ijkl}, c'est-à-dire l'information de torsion à quatre corps, capturée via une couche *quadruplet*. Le passage de messages est effectué sur le graphe des arêtes (plutôt que des nœuds), ce qui permet de propager naturellement les corrélations à longue portée sans empiler un grand nombre de couches. GemNet est l'une des architectures les plus précises de sa génération sur les benchmarks moléculaires (OC20, MD17), au prix d'un coût mémoire plus élevé et d'un temps d'entraînement significatif.

Limites communes. Les trois architectures cumulent des *invariants scalaires* de plus en plus riches (distances → distances + angles → distances + angles + dièdres). Cette construction par invariants souffre de deux faiblesses. Premièrement, elle manipule uniquement des grandeurs scalaires : des prédictions vectorielles (forces, dipôles) nécessitent des post-traitements *ad hoc* (gradient autograd ou têtes dédiées). Deuxièmement, le nombre de termes à trois ou quatre corps explose combinatoirement, ce qui pénalise la scalabilité aux grands rayons de coupure. MACE propose une rupture conceptuelle en adoptant une représentation intrinsèquement équivariante, objet de la sous-section suivante.

4.2.2 RedoxMACE : MACE avec injection de descripteurs chimiques

MACE[13]. Rompt avec l'approche incrémentale précédente en adoptant une formulation en *tenseurs moment équivariants* : au lieu de cumuler des invariants scalaires (distances, angles, dièdres), MACE construit directement des représentations irréductibles du groupe $O(3)$ de degré $\ell \leq \ell_{\max}$, et les combine via des produits tensoriels paramétrés (coefficients de Clebsch–Gordan). L'architecture est intrinsèquement équivariante : les grandeurs scalaires (énergies) sont invariantes, les grandeurs vectorielles (forces, dipôles) se transforment correctement sous rotation. Elle atteint une précision élevée avec un nombre modeste de couches (souvent une seule), grâce à une corrélation à ν corps calculée en une seule passe via une expansion en moments atomiques. C'est cette combinaison expressivité / compacité qui a motivé son choix comme modèle principal pour notre tâche ; sa déclinaison MACE-OFF pour les molécules organiques[16] confirme par ailleurs sa transférabilité sur le type de composés qui nous occupe.

Le modèle développé pour cette étude, appelé *RedoxMACE*, adapte l'architecture MACE à la prédiction multi-tâches des douze composantes de la décomposition thermodynamique. Trois ajouts caractérisent cette variante.

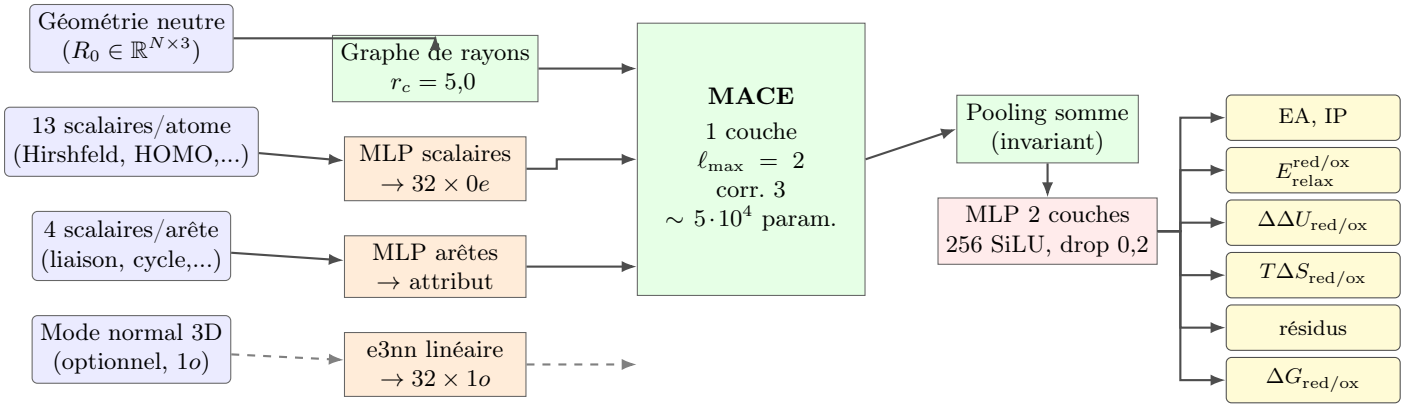
Backbone MACE. Une couche d'interaction, représentations cachées $32 \times 0e + 32 \times 1o$ (32 canaux scalaires et 32 canaux vectoriels), troncation angulaire $\ell_{\max} = 2$, corrélation à trois corps. Graphe moléculaire construit par rayon de coupure $r_c = 5.0\,\text{Å}$. Taille totale du modèle volontairement modeste ($\sim 5 \cdot 10^4$ paramètres) pour un jeu de données de ∼1700 échantillons.

Injection de descripteurs DFT. Le backbone est augmenté par trois blocs d'injection (figure 18) :

— **Scalaires atomiques** (13 par atome) : charges Hirshfeld / Mulliken / Voronoi, densité électronique et potentiel électrostatique aux noyaux, norme du mode normal dominant, trace du Hessien diagonal, constante diélectrique ε (broadcast), $\varepsilon_{\text{HOMO}}$, $\varepsilon_{\text{LUMO}}$, gap, norme du moment dipolaire.

— **Scalaires d'arête** (4 par liaison) : ordre de liaison, indicateur de covalence, appartenance à un cycle, caractère conjugué (perception RDKit).
— **Descripteurs vectoriels optionnels** (mode normal dominant 3D) : injectés dans la sous-représentation $1o$ via une application linéaire e3nn équivariante.

Tête de lecture multi-tâches. Après agrégation par pooling en somme, un MLP à deux couches de 256 unités cachées et activation SiLU produit douze sorties : EA, IP, $E_{\text{relax}}^{\text{red/ox}}$, $\Delta\Delta U^{\text{red/ox}}$, $T\Delta S^{\text{red/ox}}$, les deux résidus de la décomposition et les deux énergies libres directes $\Delta G^{\text{red/ox}}$. Une variante *multi-head* (MLP séparés par groupe de tâches : électronique, structural, thermique, résidu, ΔG) est également évaluée.



Perte multi-tâches : Huber pondéré + pénalité Born–Haber
$\mathcal{L} = \sum_t w_t \,\text{Huber}(\hat{y}_t, y_t) + \lambda_{thermo}\,(\mathcal{C}_{red} + \mathcal{C}_{ox})$

FIGURE 18 – Architecture de RedoxMACE. Les blocs bleus représentent les entrées (géométrie + descripteurs DFT), les blocs orange les blocs d'injection (projection vers les représentations MACE), le bloc vert le backbone équivariant, et les blocs rouges/jaunes la tête de lecture multi-tâches. Les flèches pleines indiquent les flux activés dans la configuration optimale ; la flèche pointillée indique l'injection vectorielle optionnelle.

Baseline atomique et normalisation. Une régression linéaire par numéro atomique Z, ajustée sur le jeu d'entraînement, est soustraite des cibles avant normalisation z-score. Elle capture la contribution extensive (somme d'énergies de référence par atome) et laisse le réseau apprendre uniquement le résidu chimique.

Fonction de perte multi-tâches.

$$\mathcal{L} = \sum_t w_t \cdot \text{Huber}(\hat{y}_t, y_t) + \lambda_{\text{thermo}}\,(\mathcal{C}_{\text{red}} + \mathcal{C}_{\text{ox}}) \tag{15}$$

où $\mathcal{C}_{\text{red}} = \mathbb{E}\big[(\hat{\Delta G}_{\text{red}} - [-\hat{\text{EA}} + \hat{E}_{\text{relax}}^{\text{red}} + \hat{\Delta\Delta U}_{\text{red}} - \hat{T\Delta S}_{\text{red}} + \hat{r}_{\text{red}}])^2\big]$ impose une cohérence Born–Haber douce entre la prédiction directe et la somme des composantes (idem pour $\mathcal{C}_{\text{ox}}$). Deux schémas de pondération w_t sont comparés : pondération apprise par incertitude[14], et pondération fixe (toutes les tâches au même poids en espace normalisé).

Variantes testées. Plusieurs configurations ont été entraînées dans le but d'isoler la contribution de chaque choix de conception :

— *baseline sans descripteurs chimiques* (géométrie seule, évalue l'apport du backbone MACE pur) ;

— *RedoxMACE avec Koopmans* (13 scalaires atomiques réintégrés) ;
— *variante multi-head* vs tête partagée ;
— *pondération Kendall* vs pondération fixe ;
— *injection vectorielle* active ou non (mode normal dominant).

Stratégie d'évaluation. Identique à celle des modèles classiques : validation croisée 5-fold *mol-aware* sur le jeu de ∼1700 conformères (69 molécules, 10 solvants), seed fixé, métriques out-of-fold rapportées sur les douze cibles. L'entraînement utilise l'optimiseur AdamW, un schéma cosinus sur 5000 epochs et une régularisation *noisy nodes* [15].

5 Conclusion

Le système constitue une plateforme fonctionnelle pour le calcul automatisé de potentiels redox par DFT. Les principales caractéristiques sont : (i) un pipeline conformères en 4 étapes avec GFN1-xTB et DFT+freq+solvant obligatoire, (ii) un schéma composite TZ2P+DZP pour le pipeline redox assurant la cohérence des bases et un résiduel de décomposition nul, (iii) la réutilisation du neutre optimisé au lieu de le recalculer, et (iv) un module d'analyse vibronique comprenant 6 méthodes. Les pipelines sont opérationnels et ont été appliqués à 73 molécules dans 10 solvants, produisant plus de 1300 conformères exploitables après filtrage.

La décomposition thermodynamique de ΔG en quatre termes (EA/IP, E_{relax}, $\Delta\Delta U$, $T\Delta S$), désormais exacte (résiduel = 0) grâce au schéma composite, révèle une hiérarchie claire. En oxydation, IP et E_{relax} représentent plus de 99% de $|\Delta G|$. En réduction, EA et E_{relax} restent dominants mais les corrections thermiques sont plus significatives.

Le modèle prédictif multi-solvant exprime chaque terme de la décomposition à partir de descripteurs de DFT conceptuelle (μ, η, fonctions de Fukui) et d'un descripteur vibronique de couplage linéaire (LVC, à Hessien neutre), avec une correction de solvant par approximant de Padé–Born réservée aux seules énergies de transfert de charge (EA/IP) ; les termes intramoléculaires (E_{relax}, $\Delta\Delta U$, $T\Delta S$) gardent des coefficients constants, le solvant n'y agissant qu'implicitement via les descripteurs COSMO. Le modèle prédit ΔG_{ox} avec MAE = 3.8 kJ/mol ($R^2 = 0{,}99$) et ΔG_{red} avec MAE = 3.6 kJ/mol ($R^2 = 1{,}00$) sur les dix solvants, sans optimisation géométrique ionique — sous la barre d'erreur intrinsèque de la DFT. La prédiction reste homogène sur tout l'éventail de polarité ; le cas le plus difficile est l'oxydation en solvant apolaire (hexane), tandis que l'eau — longtemps soupçonnée d'être le cas-limite du COSMO — se prédit normalement une fois ses données corrigées.

Les prochaines étapes prioritaires sont : (i) la réduction du résidu anharmonique sur E_{relax} pour les molécules à forte réorganisation conformationnelle, (ii) l'extension à d'autres familles redox-actives, et (iii) la validation expérimentale lors du stage à l'Université de York.

A Descripteurs de Fukui testés pour la correction de E_{relax}

Le tableau 16 récapitule l'ensemble des descripteurs de Fukui et de CDFT testés en corrélation avec le résidu $E_{\text{relax}} - E_{\text{relax}}^{\text{LVC2}}$. Pour chaque descripteur, la corrélation est évaluée séparément pour la réduction (descripteur f^+ ou dual) et l'oxydation (descripteur f^- ou dual). Les descripteurs sont regroupés par catégorie. Seuls les descripteurs intégrés sur les oxygènes atteignent la significativité ($p < 0.05$) en réduction ; aucun descripteur n'est significatif en oxydation.

TABLE 16 – Corrélations entre les descripteurs de Fukui/CDFT et le résidu LVC2 ($n = 13$ molécules). Les valeurs significatives ($p < 0.05$) sont indiquées en gras.

		Réduction		Oxydation	
Catégorie	Descripteur	r	p	r	p
Intégrés sur O	$f^{\pm}_{\mathrm{sumO}}$	**−0.67**	**0.012**	−0.16	0.59
	Δf_{sumO}	**−0.69**	**0.009**	−0.35	0.24
	f^{0}_{sumO}	**−0.67**	**0.012**	−0.16	0.59
Intégrés sur C	$f^{\pm}_{\mathrm{sumC}}$	+0.54	0.058	+0.07	0.82
	Δf_{sumC}	+0.54	0.058	+0.36	0.22
Intégrés sur H	$f^{\pm}_{\mathrm{sumH}}$	+0.04	0.88	−0.36	0.23
	Δf_{sumH}	+0.04	0.88	−0.36	0.23
Atomiques (O)	$\max_A f^{\pm}_A$ (O)	−0.34	0.25	−0.16	0.60
	$\Delta f_{\max}$ / $\Delta f_{\min}$	−0.34	0.25	+0.39	0.19
Top-k atomiques	Top-2 Δf	−0.41	0.16	+0.38	0.20
	Top-3 Δf	−0.38	0.20	+0.41	0.17
	Top-5 Δf	−0.31	0.30	+0.35	0.24
CDFT globaux	μ (pot. chimique)	−0.14	0.66	−0.25	0.40
	η (dureté)	−0.30	0.32	−0.44	0.13
	ω (électrophilicité)	+0.20	0.52	—	—
Référence	$f^{\mathrm{LUMO}}_{\mathrm{O}}$ ($n = 15$)	**−0.68**	**0.005**	−0.49	0.061

B Exemples de Fichiers d'Entrée AMS

Les exemples suivants illustrent les fichiers d'entrée générés par PLAMS pour chaque pipeline.

B.1 DFT Optimisation + Fréquences (Pipeline Conformères, étape 4)

```
Task GeometryOptimization

System
  Atoms
    C   0.000  0.000  0.000
    ...
  End
  Charge 0
End

Properties
  NormalModes Yes
End

Engine ADF
  Basis
    Type DZP
    Core None
  End
  Relativity
    Level None
  End
  NumericalQuality Good
  XC
    Hybrid PBE0
  End
```

```
  Solvation
    Surf Delley
    Solv name=Acetonitrile
    Charged method=CONJ
    C-Mat POT
    SCF VAR ALL
  End
EndEngine
```

B.2 Optimisation Géométrique DZP (Pipeline Redox)

Cet exemple montre l'optimisation géométrique DZP utilisée pour les états chargés (reduced_opt, oxidized_opt). Le neutre n'est pas re-optimisé (réutilisation du RKF conformères) :

```
Task GeometryOptimization

System
  Atoms
    ...
  End
  Charge -1      ! -1 (reduit) ou +1 (oxyde)
End

Properties
  NormalModes Yes
End

Engine ADF
  Basis
    Type DZP
    Core None
  End
  Relativity
    Level None
  End
  Unrestricted Yes
  SpinPolarization 1
  XC
    Hybrid PBE0
  End
  Solvation
    Surf Delley
    Solv name=Acetonitrile
    Charged method=CONJ CORR ! CORR pour les ions
    C-Mat POT
    SCF VAR ALL
  End
EndEngine
```

B.3 Single-Point TZ2P (Pipeline Redox)

Les single-points TZ2P sont calculés pour le raffinement énergétique du schéma composite. Pas de modes normaux :

```
Task SinglePoint

System
```

```
  Atoms
    ... ! Geometrie neutre ou ionique optimisee
  End
  Charge -1 ! 0 (neutral_tz2p), -1 (reduced_sp/tz2p), +1 (oxidized_sp/tz2p)
End

Engine ADF
  Basis
    Type TZ2P
    Core None
  End
  Relativity
    Level None
  End
  Unrestricted Yes ! No pour neutral_tz2p
  SpinPolarization 1 ! 0 pour neutral_tz2p
  XC
    Hybrid PBE0
  End
  Solvation
    Surf Delley
    Solv name=Acetonitrile
    Charged method=CONJ CORR ! CONJ pour neutral_tz2p
    C-Mat POT
    SCF VAR ALL
  End
EndEngine
```

B.4 Analyse QTAIM/IQA

```
Task SinglePoint

System
  Atoms
    ...
  End
  Charge 0 ! 0, -1 ou +1 selon l'etat analyse
End

Engine ADF
  Basis
    Type TZP
    Core None
  End
  Relativity
    Level None
  End
  NumericalQuality Good
  XC
    Hybrid PBE0
  End
  QTAIM
    Enabled Yes
    AnalysisLevel Full
    Source Yes
  End
  IQA
```

```
    Enabled Yes
  End
EndEngine
```

Références

[1] Koopmans, T. Über die Zuordnung von Wellenfunktionen und Eigenwerten zu den einzelnen Elektronen eines Atoms. *Physica* **1934**, *1*, 104–113. https://doi.org/10.1016/S0031-8914(34)90011-2.

[2] Janak, J. F. Proof That $\partial E/\partial n_i = \varepsilon_i$ in Density-Functional Theory. *Phys. Rev. B* **1978**, *18* (12), 7165–7168. https://doi.org/10.1103/PhysRevB.18.7165.

[3] Politzer, P.; Murray, J. S.; Bulat, F. A. Average Local Ionization Energy : A Review. *J. Mol. Model.* **2010**, *16* (11), 1731–1742. https://doi.org/10.1007/s00894-010-0709-5.

[4] Bartlett, R. J.; Lotrich, V. F.; Schweigert, I. V. Ab Initio Density Functional Theory : The Best of Both Worlds ? *J. Chem. Phys.* **2005**, *123* (6), 062205. https://doi.org/10.1063/1.1904585.

[5] Chan, B.; Bochevarov, D. Simple Linear Regression Models for Prediction of Ionization Energies, Electron Affinities, and Fundamental Gaps of Atoms and Molecules. *J. Chem. Theory Comput.* **2025**, *21* (7), 3382–3393. https://doi.org/10.1021/acs.jctc.4c01591.

[6] Zhan, C.-G.; Nichols, J. A.; Dixon, D. A. Ionization Potential, Electron Affinity, Electronegativity, Hardness, and Electron Excitation Energy : Molecular Properties from Density Functional Theory Orbital Energies. *J. Phys. Chem. A* **2003**, *107* (20), 4184–4195. https://doi.org/10.1021/jp0225774.

[7] Breiman, L. Random Forests. *Mach. Learn.* **2001**, *45* (1), 5–32. https://doi.org/10.1023/A:1010933404324.

[8] Friedman, J. H. Greedy Function Approximation : A Gradient Boosting Machine. *Ann. Stat.* **2001**, *29* (5), 1189–1232. https://doi.org/10.1214/aos/1013203451.

[9] Smola, A. J.; Schölkopf, B. A Tutorial on Support Vector Regression. *Stat. Comput.* **2004**, *14* (3), 199–222. https://doi.org/10.1023/B:STCO.0000035301.49549.88.

[10] Schütt, K. T.; Kindermans, P.-J.; Sauceda, H. E.; Chmiela, S.; Tkatchenko, A.; Müller, K.-R. SchNet : A Continuous-Filter Convolutional Neural Network for Modeling Quantum Interactions. *Adv. Neural Inf. Process. Syst.* **2017**, *30*, 991–1001.

[11] Klicpera, J.; Groß, J.; Günnemann, S. Directional Message Passing for Molecular Graphs. In *International Conference on Learning Representations (ICLR)* ; 2020.

[12] Gasteiger, J.; Becker, F.; Günnemann, S. GemNet : Universal Directional Graph Neural Networks for Molecules. *Adv. Neural Inf. Process. Syst.* **2021**, *34*, 6790–6802.

[13] Batatia, I.; Kovács, D. P.; Simm, G. N. C.; Ortner, C.; Csányi, G. MACE : Higher Order Equivariant Message Passing Neural Networks for Fast and Accurate Force Fields. *Adv. Neural Inf. Process. Syst.* **2022**, *35*, 11423–11436.

[14] Kendall, A.; Gal, Y.; Cipolla, R. Multi-Task Learning Using Uncertainty to Weigh Losses for Scene Geometry and Semantics. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)* ; 2018 ; pp 7482–7491.

[15] Godwin, J.; Schaarschmidt, M.; Gaunt, A.; Sanchez-Gonzalez, A.; Rubanova, Y.; Veličković, P.; Kirkpatrick, J.; Battaglia, P. Simple GNN Regularisation for 3D Molecular Property Prediction and Beyond. In *International Conference on Learning Representations (ICLR)*; 2022.

[16] Kovács, D. P.; Moore, J. H.; Browning, N. J.; Batatia, I.; Horton, J. T.; Kapil, V.; Witt, W. C.; Magdău, I.-B.; Cole, D. J.; Csányi, G. MACE-OFF23 : Transferable Machine Learning Force Fields for Organic Molecules. *arXiv* **2023**, arXiv :2312.15211. https://doi.org/10.48550/arXiv.2312.15211.

[17] Goerigk, L.; Hansen, A.; Bauer, C.; Ehrlich, S.; Najibi, A.; Grimme, S. A Look at the Density Functional Theory Zoo with the Advanced GMTKN55 Database for General Main Group Thermochemistry, Kinetics and Noncovalent Interactions. *Phys. Chem. Chem. Phys.* **2017**, *19* (48), 32184–32215. https://doi.org/10.1039/C7CP04913G.

[18] Geerlings, P.; De Proft, F.; Langenaeker, W. Conceptual Density Functional Theory. *Chem. Rev.* **2003**, *103* (5), 1793–1874. https://doi.org/10.1021/cr990029p.

[19] Parr, R. G.; Donnelly, R. A.; Levy, M.; Palke, W. E. Electronegativity : The Density Functional Viewpoint. *J. Chem. Phys.* **1978**, *68* (8), 3801–3807. https://doi.org/10.1063/1.436185.

[20] Parr, R. G.; Pearson, R. G. Absolute Hardness : Companion Parameter to Absolute Electronegativity. *J. Am. Chem. Soc.* **1983**, *105* (26), 7512–7516. https://doi.org/10.1021/ja00364a005.

[21] Parr, R. G.; Yang, W. Density Functional Approach to the Frontier-Electron Theory of Chemical Reactivity. *J. Am. Chem. Soc.* **1984**, *106* (14), 4049–4050. https://doi.org/10.1021/ja00326a036.

[22] Parr, R. G.; von Szentpály, L.; Liu, S. Electrophilicity Index. *J. Am. Chem. Soc.* **1999**, *121* (9), 1922–1924. https://doi.org/10.1021/ja983494x.

[23] Morell, C.; Grand, A.; Toro-Labbé, A. New Dual Descriptor for Chemical Reactivity. *J. Phys. Chem. A* **2005**, *109* (1), 205–212. https://doi.org/10.1021/jp046577a.

[24] Gázquez, J. L.; Cedillo, A.; Vela, A. Electrodonating and Electroaccepting Powers. *J. Phys. Chem. A* **2007**, *111* (10), 1966–1970. https://doi.org/10.1021/jp065459f.

[25] Hoffmann, G.; Chermette, H.; Morell, C. Revisiting Nucleophilicity : An Index for Chemical Reactivity from a CDFT Approach. *J. Mol. Model.* **2024**, *30* (7), 232. https://doi.org/10.1007/s00894-024-06020-0.

[26] Köppel, H.; Domcke, W.; Cederbaum, L. S. Multimode Molecular Dynamics Beyond the Born–Oppenheimer Approximation. *Adv. Chem. Phys.* **1984**, *57*, 59–246. https://doi.org/10.1002/9780470142813.ch2.

[27] Duschinsky, F. The Importance of the Electron Spectrum in Multi-Atomic Molecules. Concerning the Franck–Condon Principle. *Acta Physicochim. URSS* **1937**, *7*, 551–566.

[28] Huang, K.; Rhys, A. Theory of Light Absorption and Non-Radiative Transitions in F-Centres. *Proc. R. Soc. London, Ser. A* **1950**, *204* (1078), 406–423. https://doi.org/10.1098/rspa.1950.0184.

[29] Morse, P. M. Diatomic Molecules According to the Wave Mechanics. II. Vibrational Levels. *Phys. Rev.* **1929**, *34* (1), 57–64. https://doi.org/10.1103/PhysRev.34.57.

[30] Barone, V. Anharmonic Vibrational Properties by a Fully Automated Second-Order Perturbative Approach. *J. Chem. Phys.* **2005**, *122* (1), 014108. https://doi.org/10.1063/1.1824881.

[31] Bader, R. F. W. *Atoms in Molecules : A Quantum Theory* ; Oxford University Press : Oxford, 1990.

[32] Marcus, R. A. On the Theory of Oxidation-Reduction Reactions Involving Electron Transfer. I. *J. Chem. Phys.* **1956**, *24* (5), 966–978. https://doi.org/10.1063/1.1742723.

[33] McQuarrie, D. A. *Statistical Mechanics* ; Harper & Row : New York, 1976.

[34] Cohen, M. H. ; Ganduglia-Pirovano, M. V. ; Kudrnovský, J. Electronic and Nuclear Chemical Reactivity. *J. Chem. Phys.* **1994**, *101* (10), 8988–8997. https://doi.org/10.1063/1.468026.

[35] Cárdenas, C. ; Ayers, P. W. ; Chakraborty, D. ; Gómez, T. ; Echeverri, A. ; Muñoz, F. ; Fuentealba, P. On the Link Between the Reaction Force Constant and Conceptual DFT. *J. Mol. Model.* **2024**, *30* (10), 332. https://doi.org/10.1007/s00894-024-06137-2.